

Машинное обучение

Лекция 4

Линейная классификация. Логистическая регрессия.

Михаил Гущин

mhushchyn@hse.ru

НИУ ВШЭ, 2026

На прошлой лекции

- ▶ Модель линейной регрессии:

$$\hat{y} = Xw$$

- ▶ Функция потерь MSE с регуляризацией:

$$L(w) = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 + \alpha R(w)$$

- ▶ Мы хотим минимизировать L :

$$L \rightarrow \min_w$$

- ▶ Градиентный спуск:


$$w^{(k+1)} = w^{(k)} - \eta \nabla L(w^{(k)})$$

Линейная классификация




Задача

- ▶ Есть объекты двух классов
- ▶ Нужно разделить объекты по классам некоторой **гиперплоскостью**
- ▶ Эту гиперплоскость будем называть **линейным классификатором**




Гиперплоскость



Скалярное произведение

Результат — число, а не вектор



Скалярное произведение двух векторов равно произведению их длин на косинус угла между ними:

$$a \cdot b = |a| |b| \cos \theta$$

Также его можно понимать как произведение длины вектора a на проекцию вектора b на направление a :

Длина a $\times$ проекция b на направление a


Пример (для рисунка слева):

$$a \cdot b = 4 \times 3 \times \cos 60^\circ = 6$$


По координатам:

$$a \cdot b = a_1 b_1 + a_2 b_2$$


Острый угол




Прямой угол



Тупой угол



Гиперплоскость



$$f(x) = w^T x + b, \quad w \neq 0$$

1. Разделяет пространство

Два полупространства: $f(x) > 0$ и $f(x) < 0$.

2. Нормаль задаёт ориентацию

w перпендикулярен гиперплоскости и направлен в сторону $f(x) > 0$.

3. Свободный член задаёт сдвиг

При фиксированном w изменение b сдвигает границу параллельно самой себе. При $b = 0$ граница проходит через начало координат.

4. Расстояние от точки до границы

$$d = \frac{|w^T x + b|}{\|w\|}$$

В 2D — прямая • В 3D — плоскость • В n D — гиперплоскость размерности $n - 1$

Нормальный вектор к плоскости

- ▶ Возьмем такие $x_A, x_B \in \{x: w_{12}^T x + w_0 = 0\}$ на гиперплоскости
- ▶ Тогда:

$$w_{12}^T x_A + w_0 = 0$$

$$w_{12}^T x_B + w_0 = 0$$

- ▶ Найдем разность:

$$w_{12}^T (x_A - x_B) = 0$$

- ▶ Поскольку скалярное произведение равно 0, а $(x_A - x_B)$ лежат на гиперплоскости, то вектор w_{12} ортогонален к гиперплоскости

Расстояние до плоскости

- ▶ Расстояние от вектора x_D до плоскости $w_{12}^T x + w_0 = 0$ равно:

$$\frac{w_{12}^T x_D + w_0}{\|w_{12}\|} \sim Xw$$


- ▶ Докажем это. Пусть $x_D = t + h$, где t лежит в плоскости, а h - ортогонален ей. Тогда,

$$w_{12}^T t + w_0 = 0$$


$$w_{12}^T x_D + w_0 = w_{12}^T (t + h) + w_0 = w_{12}^T h$$

- ▶ Откуда получаем:

$$h = \frac{w_{12}^T x_D + w_0}{\|w_{12}\|}$$



Гиперплоскость



Векторная форма

- ▶ Пусть дан набор из n точек: $\{x_i, y_i\}_{i=1}^n$, где
 - $x_i = (x_{i1}, x_{i2}, \dots, x_{id})^T$ - вектор из d признаков объекта;
 - $y_i = \{-1, +1\}$ – метка класса объекта.
- ▶ Модель **линейной классификации**:

$$\hat{y}_i = \text{sign} \left(w_0 + \sum_{j=1}^d w_j x_{ij} \right)$$

- w_j - веса модели;
 - $\hat{y}_i$ - прогноз для объекта;
- ▶ Ошибка прогноза модели для объекта: $\hat{y}_i \neq y_i$

Матричная форма


- ▶ Модель **линейной классификации**:

$$\hat{y} = \text{sign}(Xw)$$

- $X = \begin{pmatrix} \mathbf{1} & x_{11} & \cdots & x_{1d} \\ \vdots & & \ddots & \vdots \\ \mathbf{1} & x_{n1} & \cdots & x_{nd} \end{pmatrix}$ - матрица признаков объектов;
- $w = (w_0, w_1, \dots, w_d)^T$ - вектор $(d + 1)$ весов модели;
- $\hat{y} = (\hat{y}_1, \hat{y}_2, \dots, \hat{y}_n)^T$ - вектор прогнозов модели для (n) объектов;

- ▶ Вектор ошибок прогнозов модели: $\hat{y}_i \neq y_i$

Обучение классификатора



Функция потерь

- ▶ Функция потерь (Loss function) для классификации:

$$L = \frac{1}{n} \sum_{i=1}^n [\hat{y}_i \neq y_i]$$

- ▶ Значение L – доля неправильных ответов
- ▶ Мы хотим минимизировать L :

$$L \rightarrow \min_w$$

Функция потерь

- ▶ Дискретная относительно весов модели
- ▶ Нет производной (0, либо не определена)
- ▶ Не можем использовать градиентный спуск
- ▶ Много глобальных минимумов (несколько способов разделить объекты на классы)

Повтор

- ▶ Модель линейной классификации:

$$\hat{y} = \text{sign}(Xw)$$

- ▶ Функция потерь, доля неправильных ответов:

$$L = \frac{1}{n} \sum_{i=1}^n [\hat{y}_i \neq y_i]$$

- ▶ Мы хотим минимизировать L :

$$L \rightarrow \min_w$$

- ▶ Решение: пока не знаем 😊

Отступы




Модель классификации

- ▶ Пусть дан набор из n точек: $\{x_i, y_i\}_{i=1}^n$, где
 - $x_i = (x_{i1}, x_{i2}, \dots, x_{id})^T$ - вектор из d признаков объекта;
 - $y_i = \{-1, +1\}$ – метка класса объекта.
- ▶ Модель **линейной классификации**:

$$\hat{y}_i = \text{sign} \left(w_0 + \sum_{j=1}^d w_j x_{ij} \right)$$

- w_j - веса модели;
 - $\hat{y}_i$ - прогноз для объекта;
- ▶ Ошибка прогноза модели для объекта: $\hat{y}_i \neq y_i$

Гиперплоскость



Отступ

- ▶ Отступ (margin) M :


$$z = Xw$$

$$M = yz$$

- ▶ Знак отступа говорит о корректности прогноза
 - $M_i > 0$ – верный прогноз
 - $M_i < 0$ – неправильный прогноз
- ▶ Абсолютная величина – степень уверенности классификатора
- ▶ Чем ближе M к 0, тем ближе объект к границе классов

Отступ

Margin



Новая функция потерь


- ▶ Функция потерь (Loss function) для классификации:

$$L = \frac{1}{n} \sum_{i=1}^n [M_i < 0]$$

- ▶ Значение L – доля неправильных ответов
- ▶ Мы хотим минимизировать L :

$$L \rightarrow \min_w$$

Верхние оценки



Задача

- ▶ Есть функция потерь для классификации:

$$L = \frac{1}{n} \sum_{i=1}^n [M_i < 0]$$

- ▶ Не можем использовать для градиентного спуска
- ▶ Хотим заменить ее на гладкую функцию

Верхние оценки

- ▶ Есть функция потерь для **одного произвольного** объекта:

$$L(M_i) = [M_i < 0]$$

- ▶ Хотим найти такую $\tilde{L}(M)$, что

$$L(M_i) \leq \tilde{L}(M_i)$$


- ▶ Тогда верхняя оценка выглядит так:

$$L = \frac{1}{n} \sum_{i=1}^n [M_i < 0] \leq \frac{1}{n} \sum_{i=1}^n \tilde{L}(M_i) \rightarrow \min_w$$


Примеры

- ▶ $\tilde{L}(M) = \log(1 + e^{-M})$ – логистическая функция потерь (рассмотрим подробно далее)
- ▶ $\tilde{L}(M) = \max(0, 1 - M)$ – кусочно-линейная функция потерь
- ▶ $\tilde{L}(M) = \max(0, -M)$ – кусочно-линейная функция потерь
- ▶ $\tilde{L}(M) = e^{-M}$ – экспоненциальная функция потерь
- ▶ $\tilde{L}(M) = 2(1 + e^M)^{-1}$ – сигмоидная функция потерь

Примеры




Логистическая регрессия



Задача

- ▶ Есть объекты двух классов
- ▶ Нужно разделить объекты по классам некоторой **гиперплоскостью**
- ▶ Эту гиперплоскость будем называть **линейным классификатором**



Матричная форма


- ▶ Пусть дан набор из n точек: $\{x_i, y_i\}_{i=1}^n$, где
 - $x_i = (x_{i1}, x_{i2}, \dots, x_{id})^T$ - вектор из d признаков объекта;
 - $y_i = \{0, 1\}$ – метка класса объекта.
- ▶ Модель **логистической регрессии**:

$$\hat{y}_i = \sigma(Xw)$$

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

- ▶ $\hat{y}_i$ - **вероятность класса 1** для объекта;

Сигмоида



Функция потерь


- ▶ Функция потерь для логистической регрессии (**log-loss**):

$$L = -\frac{1}{n} \sum_{i=1}^n (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i))$$

- ▶ Мы хотим минимизировать L :

$$L \rightarrow \min_w$$

Пример



Задание



Покажите, что при $y_i = \{0, 1\}$ функция потерь

$$L = -\frac{1}{n} \sum_{i=1}^n (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i))$$

эквивалентна функции потерь

$$L = \frac{1}{n} \sum_{i=1}^n \log(1 + e^{-M_i})$$

при $y_i = \{-1, +1\}$

Повтор

- ▶ Модель логистической регрессии:

$$\hat{y} = \sigma(Xw)$$

- ▶ Функция потерь log-loss:

$$L = -\frac{1}{n} \sum_{i=1}^n (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i))$$


- ▶ Мы хотим минимизировать L :

$$L \rightarrow \min_w$$

- ▶ Градиентный спуск:

$$w^{(k+1)} = w^{(k)} - \eta \nabla L(w^{(k)})$$

Вероятностная интерпретация



Правдоподобие (likelihood)

Правдоподобие (likelihood) - это мера того, насколько хорошо выбранная модель и её параметры объясняют уже наблюдаемые данные.

Оно тесно связано с вероятностью, но отличается направлением вопроса:

- ▶ **Вероятность:** если модель известна, какие данные мы можем получить?
- ▶ **Правдоподобие:** если данные уже получены, какие параметры модели лучше их объясняют?

Правдоподобие (likelihood)

Например, мы подбросили монету 10 раз и получили 8 орлов. Обозначим вероятность орла через p . Тогда правдоподобие этого результата:

$$L(p) = \frac{10!}{8!2!} p^8 (1-p)^2$$

Здесь данные (8 орлов из 10) зафиксированы, а p меняется.

- ▶ Какое значение p даёт наибольшее правдоподобие?
- ▶ Выбор параметров таким способом называется **методом максимального правдоподобия**.

Правдоподобие (likelihood)

В машинном обучении этот принцип часто используется для обучения: параметры модели подбирают так, чтобы наблюдаемые обучающие данные получали как можно большую вероятность!


Логистическая регрессия

- ▶ Вероятность класса 1:

$$p(y = \mathbf{1}|x_i) = \sigma(x_i^T w) = \hat{y}_i$$

- ▶ Вероятность класса 0:

$$p(y = \mathbf{0}|x_i) = 1 - \sigma(x_i^T w)$$



Правдоподобие

- ▶ Пусть дан набор из n точек: $\{x_i, y_i\}_{i=1}^n$, где
 - $x_i = (x_{i1}, x_{i2}, \dots, x_{id})^T$ - вектор из d признаков объекта;
 - $y_i = \{\mathbf{0}, \mathbf{1}\}$ – метка класса объекта.
- ▶ Тогда правдоподобие:

$$\text{Likelihood} = \prod_{i=1}^n p(y = \mathbf{1} | x_i)^{[y_i=1]} p(y = \mathbf{0} | x_i)^{[y_i=0]} \rightarrow \max_w$$

Логарифм правдоподобия

- ▶
- ▶ Правдоподобие:

$$\text{Likelihood} = \prod_{i=1}^n p(y = 1|x_i)^{[y_i=1]} p(y = 0|x_i)^{[y_i=0]}$$

- ▶ Логарифм правдоподобия:

$$\begin{aligned} \text{Log Likelihood} &= \sum_{i=1}^n y_i \log(p(y = 1|x_i)) + (1 - y_i) \log(p(y = 0|x_i)) = \\ &= \sum_{i=1}^n y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i) = -nL \end{aligned}$$

Заключение



Резюме

- ▶ Модель логистической регрессии:

$$\hat{y} = \sigma(Xw)$$

- ▶ Функция потерь log-loss:

$$L = -\frac{1}{n} \sum_{i=1}^n (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i))$$

- ▶ Мы хотим минимизировать L :

$$L \rightarrow \min_w$$

- ▶ Градиентный спуск:

$$w^{(k+1)} = w^{(k)} - \eta \nabla L(w^{(k)})$$

Вопросы

- ▶ Запишите формулу для линейной модели классификации. Что такое отступ? Как обучаются линейные классификаторы и для чего нужны верхние оценки пороговой функции потерь?
- ▶ Как в логистической регрессии выполняются предсказания для новых объектов? Запишите логистическую функцию потерь. Как она связана с методом максимума правдоподобия?