# Машинное обучение

Лекция 5

Метрики качества. Переобучение.

Многоклассовая классификация.

Михаил Гущин

mhushchyn@hse.ru

НИУ ВШЭ, 2026

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ

# На прошлой лекции

- Модель логистической регрессии:

$$\hat{y} = \sigma(Xw)$$

- Функция потерь log-loss:

$$L = -\frac{1}{n}\sum_{i=1}^{n}(y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i))$$

- Мы хотим минимизировать $L$:

$$L \to \min_w$$

- Градиентный спуск:

$$w^{(k+1)} = w^{(k)} - \eta \nabla L(w^{(k)})$$

# Метрики качества для классификации

# Задача

Рассмотрим задачу бинарной классификации для некоторого набора данных.

Цель – **оценить качество классификатора**, определить как хорошо он разделяет объекты разных классов.

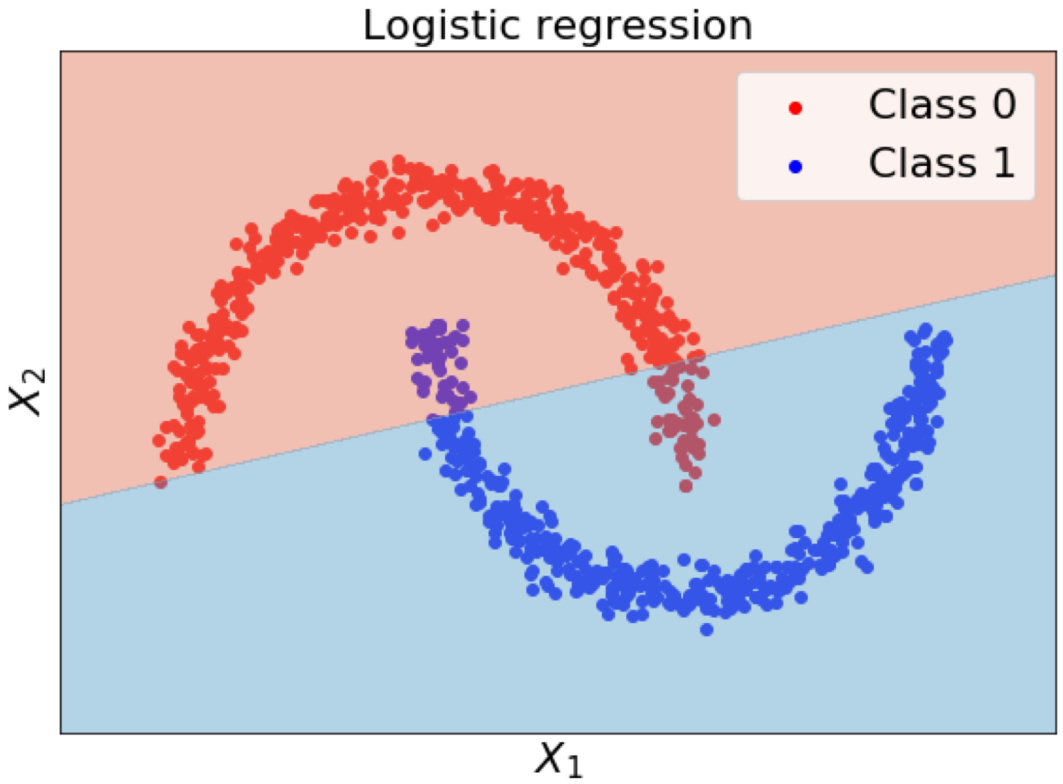

# Матрица ошибок (confusion matrix)

- **TP** (True Positive) – правильно предсказанные **1**
- **FP** (False Positive) – предсказанные как **1**, но правильно **0** (ошибка 1го рода)
- **TN** (True Negative) – правильно предсказанные **0**
- **FN** (False Negative) – предсказанные как **0**, но правильно **1** (ошибка 2го рода)

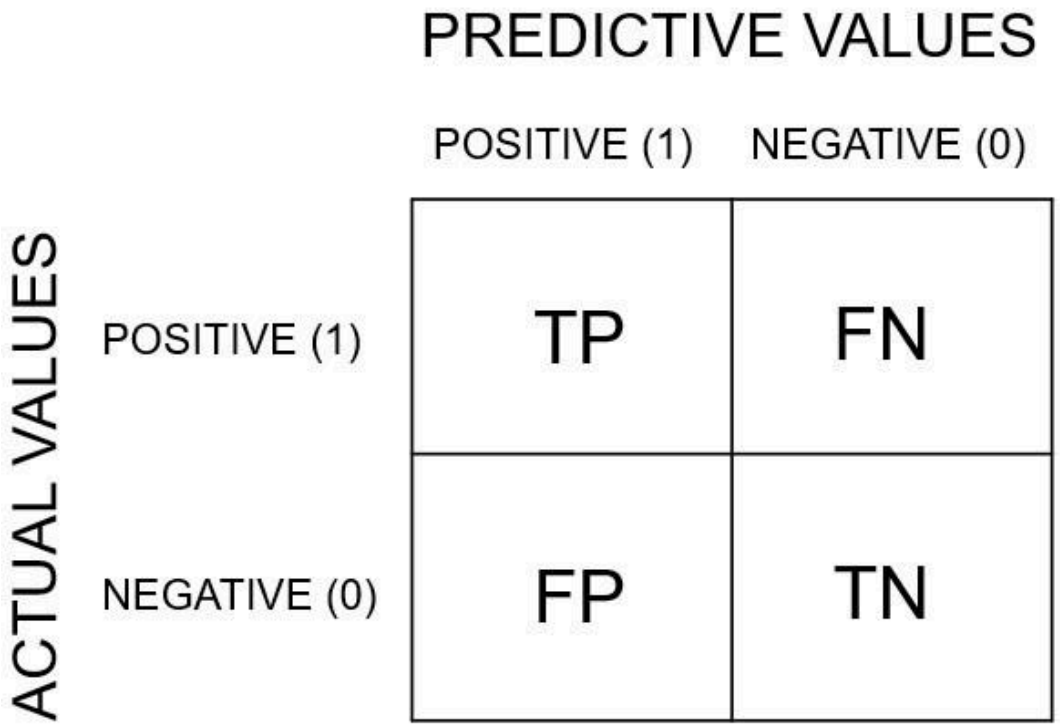

True positive
You're pregnant
True negative
You're not pregnant
False positive
(Type I error)
You're pregnant
False negative
(Type II error)
You're not pregnant

# Матрица ошибок (confusion matrix)

- **TP** (True Positive) – правильно предсказанные **1**
- **FP** (False Positive) – предсказанные как **1**, но правильно **0** (ошибка 1го рода)
- **TN** (True Negative) – правильно предсказанные **0**
- **FN** (False Negative) – предсказанные как **0**, но правильно **1** (ошибка 2го рода)

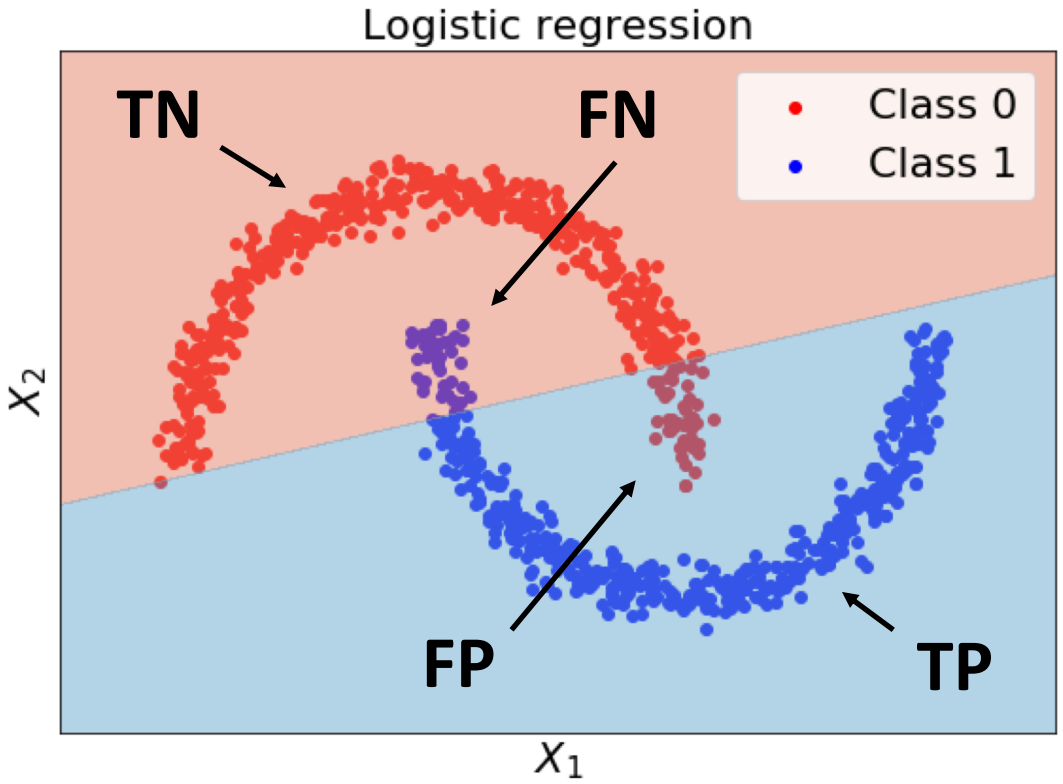

# Матрица ошибок (confusion matrix)

- Все **1** (***Pos***):

$$Pos = TP + FN$$

- Все **0** (***Neg***):

$$Neg = TN + FP$$

- Все прогнозы **1** (***PosPred***):

$$PosPred = TP + FP$$

- Все прогнозы **0** (***NegPred***):

$$NegPred = TN + FN$$

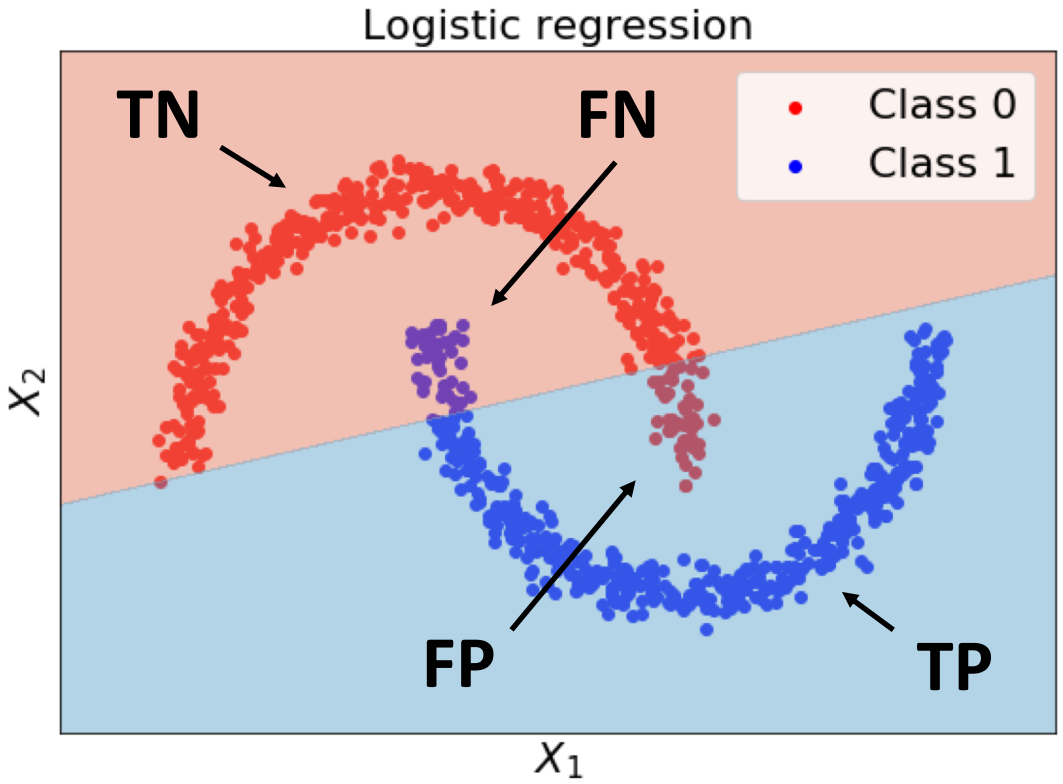

# Доля правильных ответов (accuracy)

- Accuracy:

$$\text{Accuracy} = \frac{TP + TN}{TP + FN + TN + FP} = \frac{TP + TN}{Pos + Neg}$$

- Error rate:

$$\text{Error rate} = 1 - \text{Accuracy}$$

- Измеряет долю верных прогнозов во всех классах

# Точность (precision)

- Precison:

$$\text{Precison} = \frac{TP}{TP + FP} = \frac{TP}{PosPred}$$

- Показывает какая доля прогнозов **1** правильная

**Пример:** предсказали 100 объектов класса 1, но только 90 прогнозов верны. Тогда точность = 0.9.

# Полнота (recall)

- Recall:

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{TP}{Pos}$$

- Показывает какую долю настоящих **1** классификатор предсказал правильно.

**Пример:** в данных 50 объектов класса 1, классификатор правильно предсказал 40 этих объектов. Тогда полнота = 0.8.

# F-мера

- $F_1$-score:

$$F_1 = \frac{2 \cdot \text{Precison} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

- Показывает среднее геометрическое точности и полноты

# Пример

| Metric | Value |
|---|---|
| Accuracy | 0.89 |
| Precision | 0.89 |
| Recall | 0.89 |
| $F_1$ | 0.89 |

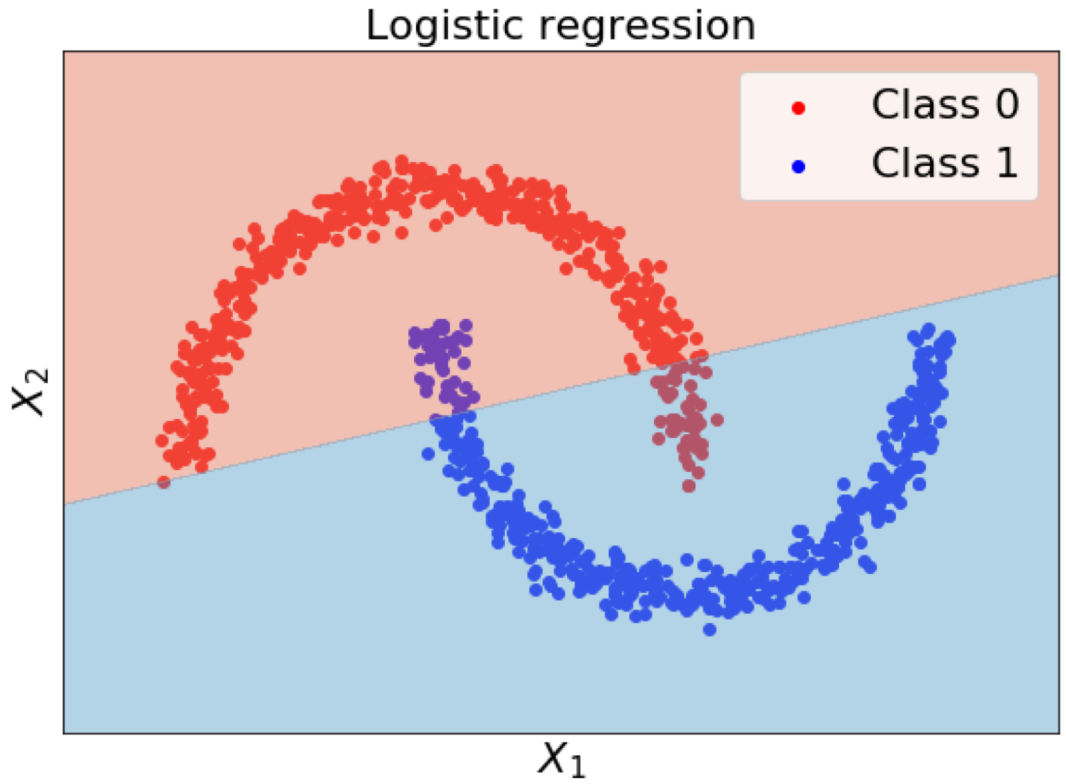


- В этом простом симметричном примере все метрики равны
- Далее увидим другие примеры

# Пример 2

- Допустим, модель выявляет брак: **положительный класс — бракованная деталь**. Она находит 80% брака и ошибочно отмечает как брак 10% исправных деталей.

| Брак — 50% | |
|---|---|
| TP 400 | FN 100 |
| FP 50 | TN 450 |

| Брак — 1% | |
|---|---|
| TP 8 | FN 2 |
| FP 99 | TN 891 |

| Метрика | Брак — 50% | Брак — 1% |
|---|---|---|
| Accuracy | 85% | 89,9% |
| Precision | 88,9% | 7,5% |
| Recall | 80% | 80% |
| F1 | 84,2% | 13,7% |

# ROC кривая

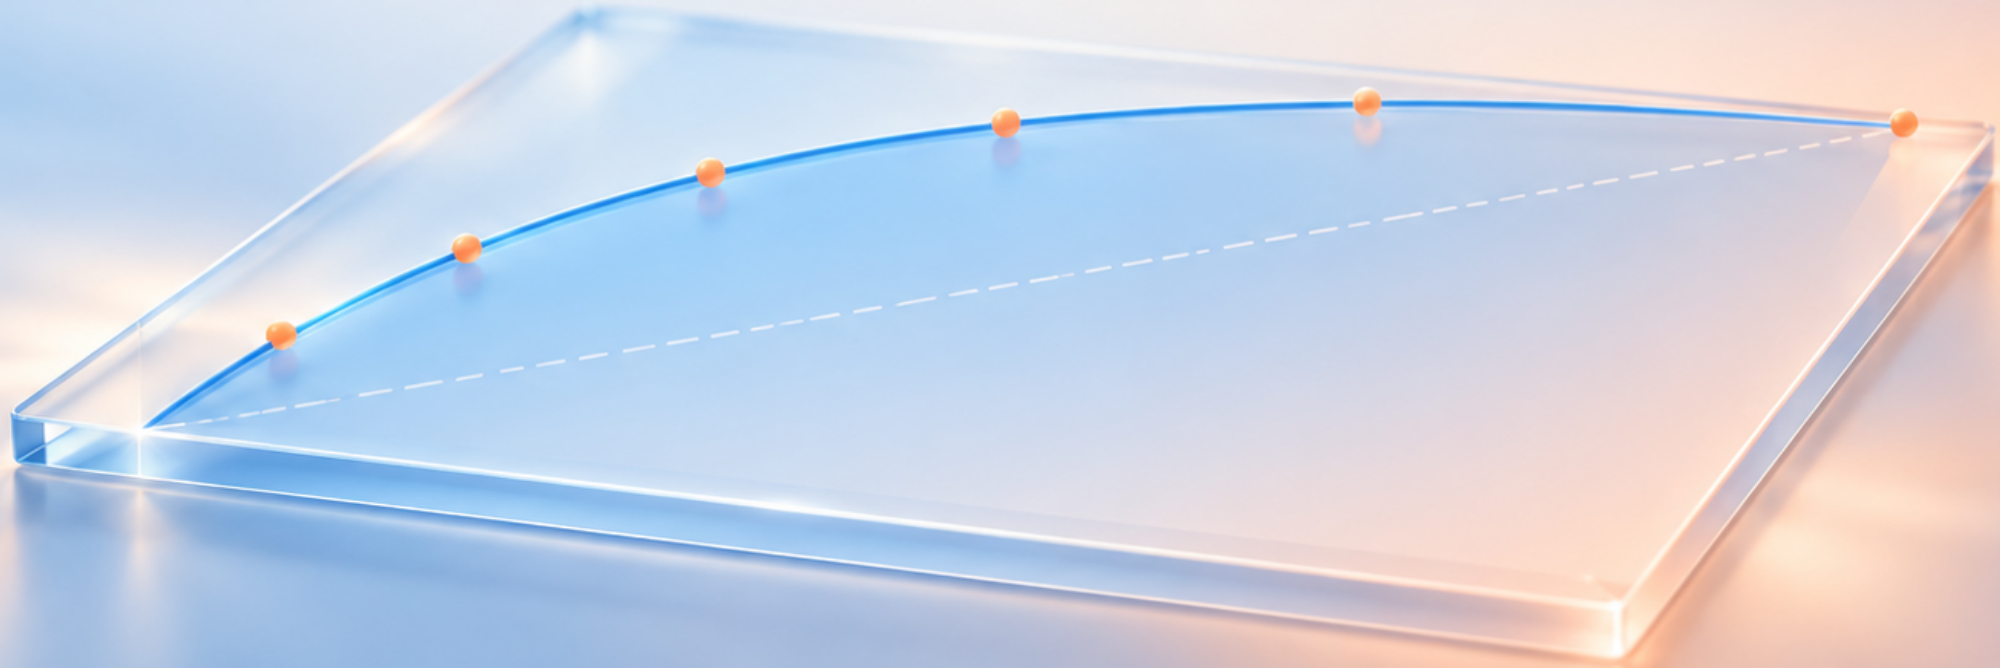

# Метка класса vs вероятность класса

Прогноз **1** если $p \geq 0.5$
Прогноз **0** если $p < 0.5$

Вероятность клааса **1** $p$:

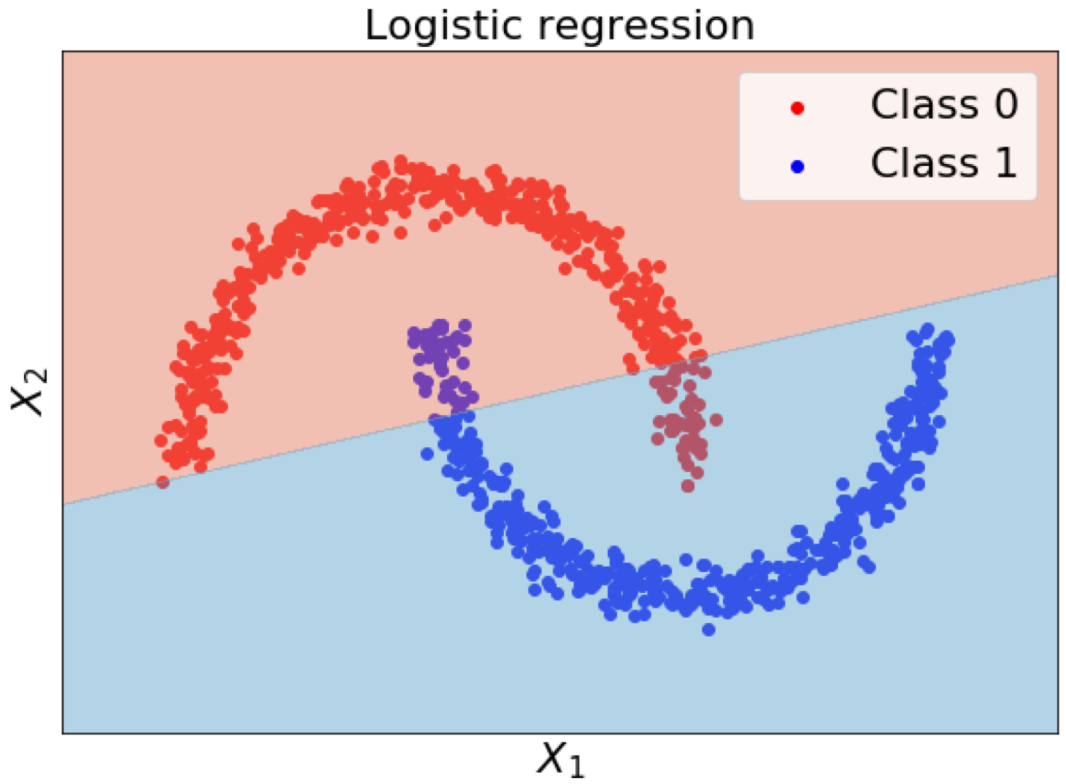


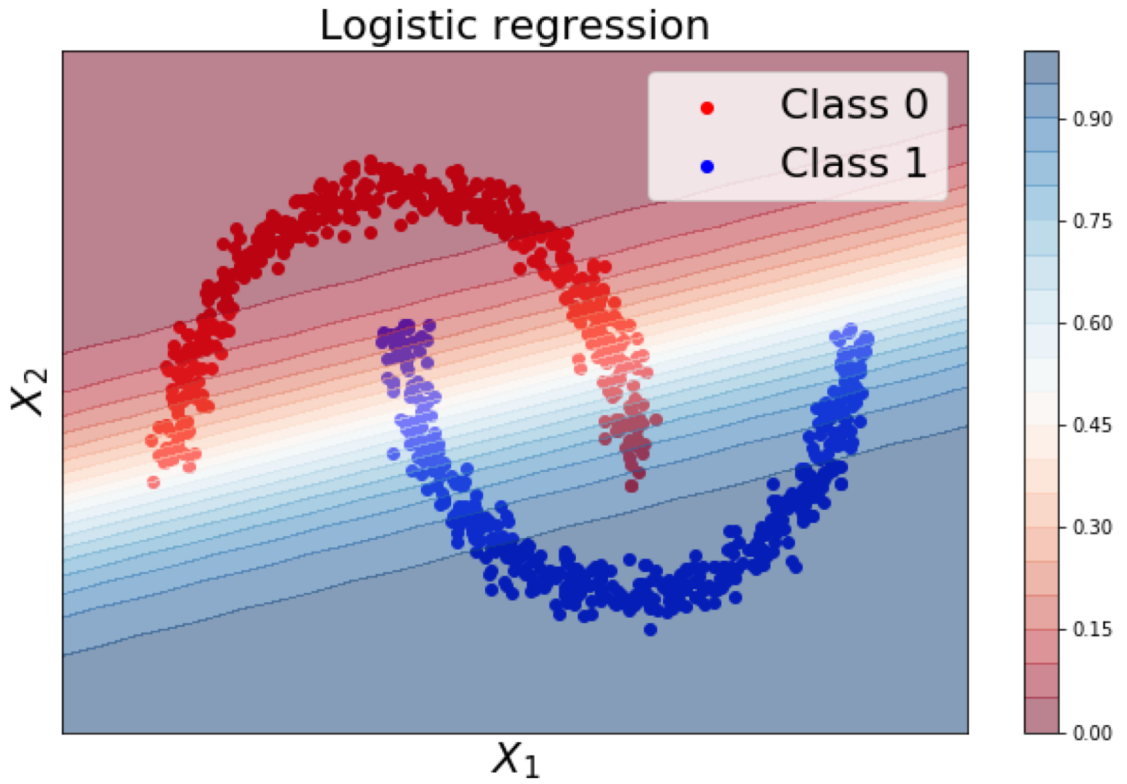

# ROC кривая

- ROC (Receiver operating characteristic) кривая – зависимость $\boldsymbol{TPR(\mu)}$ **от** $\boldsymbol{FPR(\mu)}$ для разных пороговых значений $\boldsymbol{\mu}$ вероятности $\boldsymbol{p}$

- $TPR(\mu)$ (True Positive Rate):

$$TPR(\mu) = \frac{1}{Pos} \sum_{i \in Pos} I[p_i \geq \mu] = \frac{TP(\mu)}{Pos}$$

- $FPR(\mu)$ (False Positive Rate):

$$FPR(\mu) = \frac{1}{Neg} \sum_{i \in Neg} I[p_i \geq \mu] = \frac{FP(\mu)}{Neg}$$

# ROC кривая

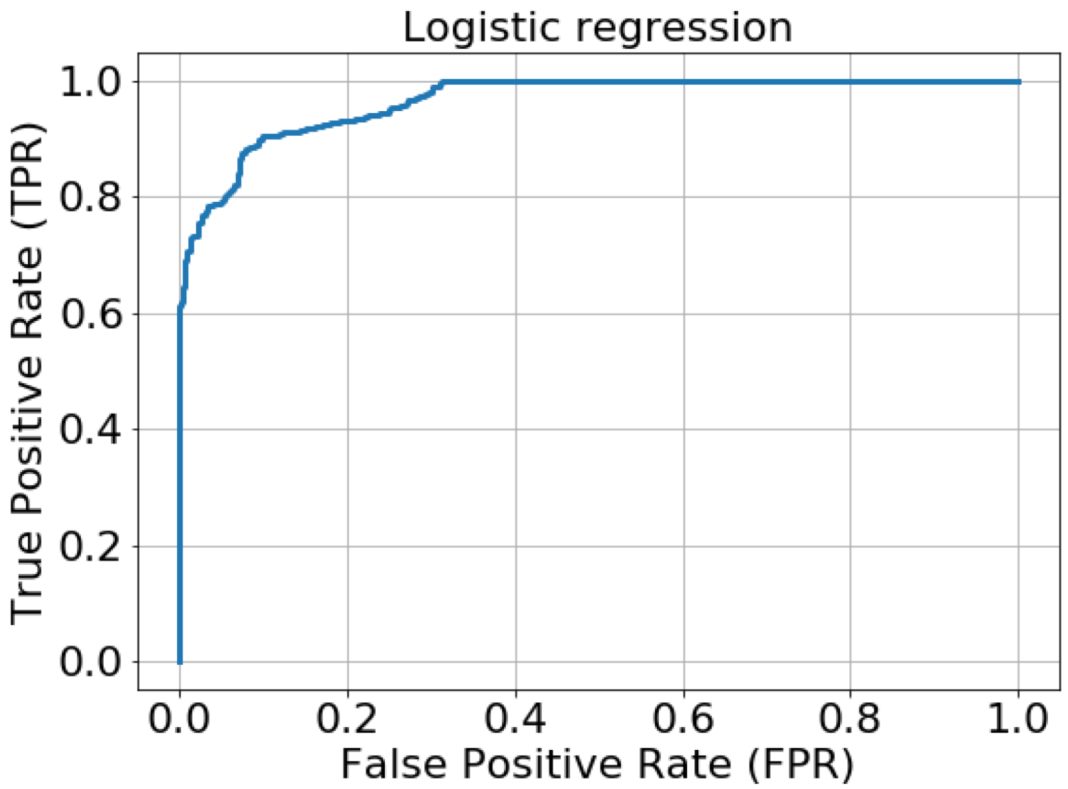
Logistic regression
True Positive Rate (TPR)
False Positive Rate (FPR)
0.0
0.2
0.4
0.6
0.8
1.0

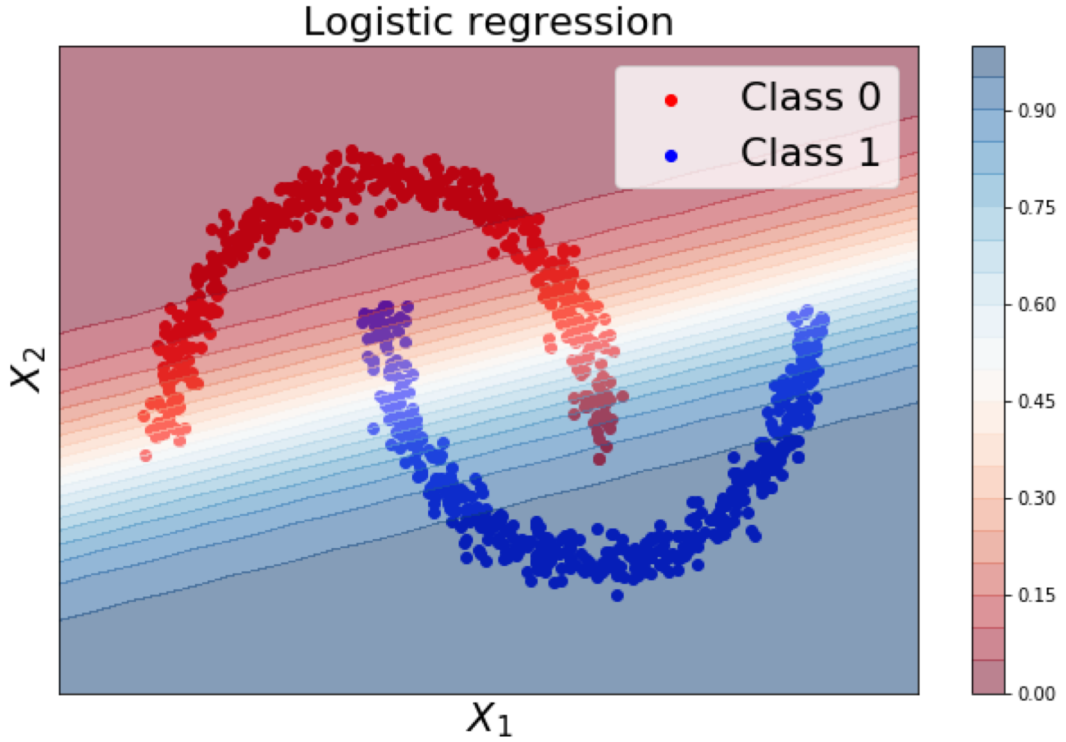
Logistic regression
Class 0
Class 1
$X_1$
$X_2$
0.00
0.15
0.30
0.45
0.60
0.75
0.90

# ROC AUC

- Можно сравнивать классификаторы с помощью площади под ROC кривой (ROC AUC)

- ROC AUC $\in [0, 1]$
- ROC AUC = 0.5 – случайные прогнозы
- ROC AUC = 1 – идеальный классификатор
- ROC AUC = 0 – тоже идеальный классификатор, но с противоположными ответами ☺

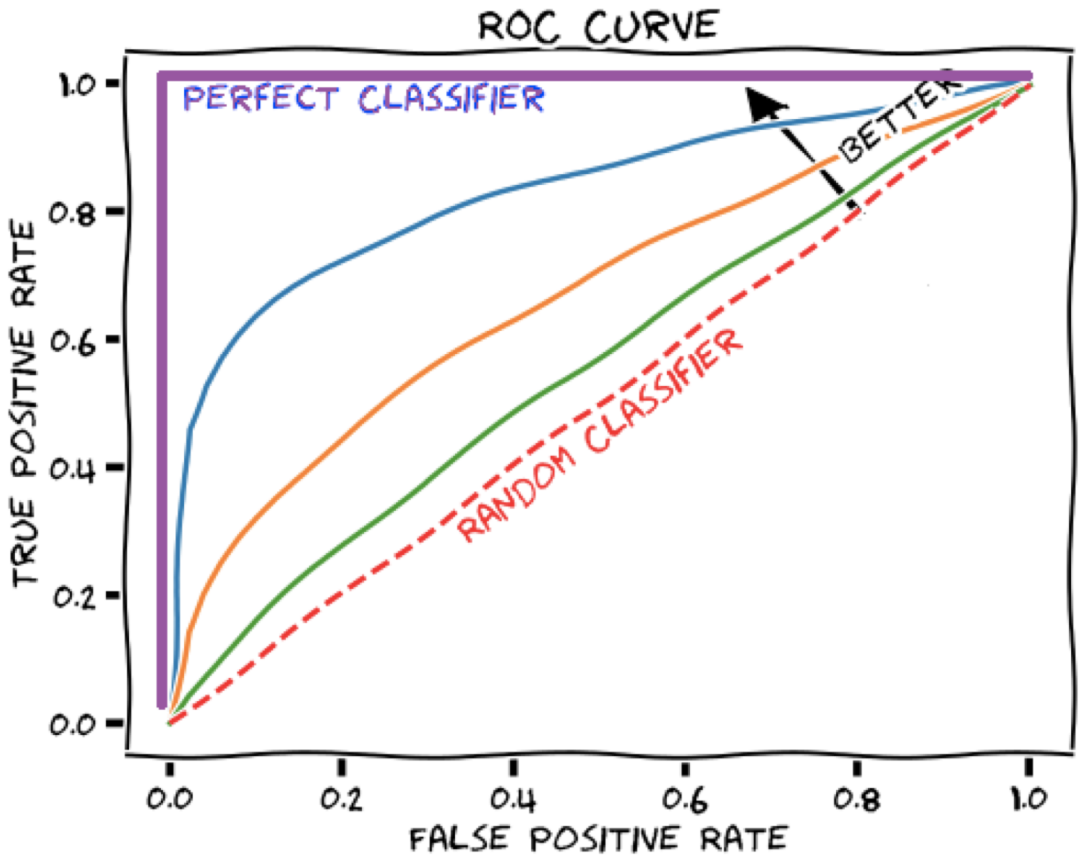


Img: https://glassboxmedicine.com/2019/02/23/measuring-performance-auc-auroc/

# Индекс Джини

- Gini:

$$Gini = 2\,(ROC\ AUC) - 1$$

- Измеряется в диапазоне от 0 до 1

# Precision-Recall кривая

- По аналогии с ROC кривой, можно построить Precision-Recall (PR) кривую
- PR – зависимость **Precision($\mu$) от Recall($\mu$)** для разных пороговых значений $\mu$ вероятности $p$

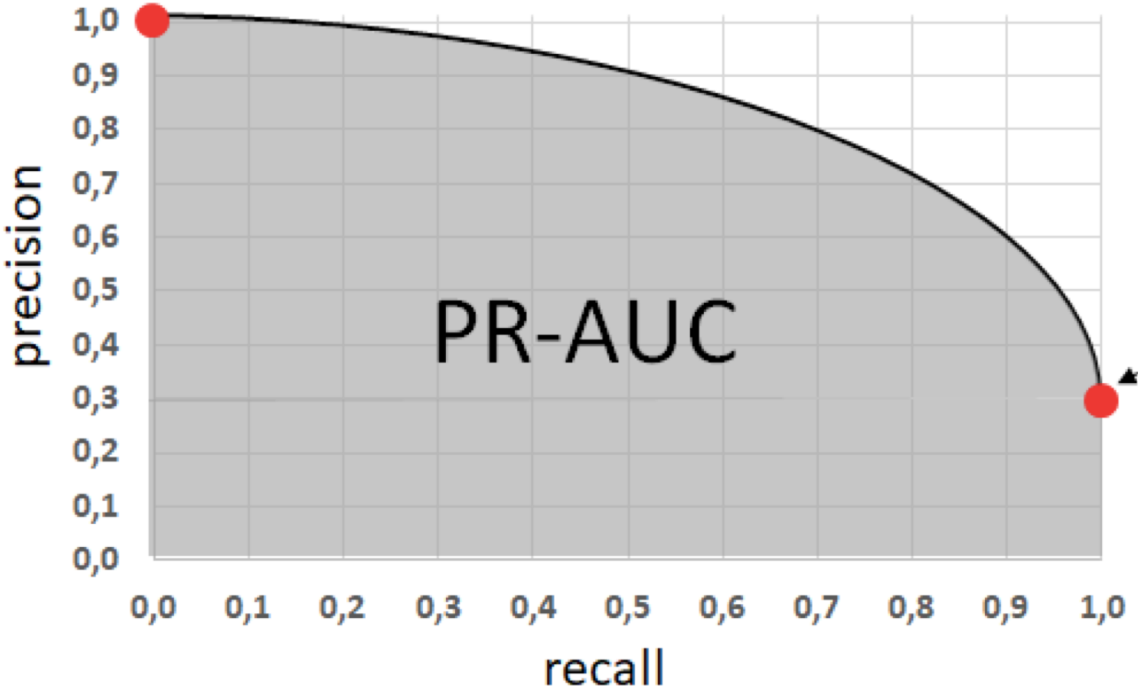

# Демонстрация

| Metric | 1:1 | 1:10 | 10:1 |
|---|---|---|---|
| Accuracy | 0.89 | | |
| Precision | 0.89 | | |
| Recall | 0.89 | | |
| $F_1$ | 0.89 | | |
| ROC AUC | 0.97 | | |

- Обучили модель на сбалансированной выборке
- **Фиксируем модель** и будем менять баланс классов

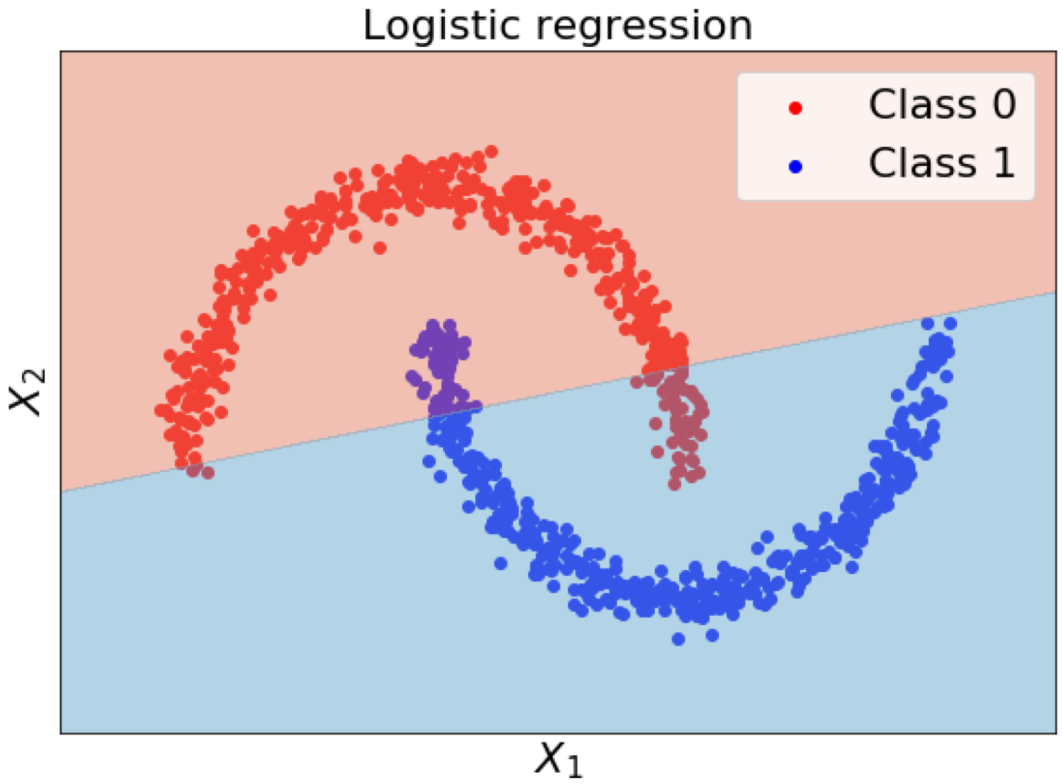

# Демонстрация

| Metric | 1:1 | 1:10 | 10:1 |
|---|---|---|---|
| Accuracy | 0.89 | 0.89 | |
| Precision | 0.89 | 0.99 | |
| Recall | 0.89 | 0.89 | |
| $F_1$ | 0.89 | 0.94 | |
| ROC AUC | 0.97 | 0.97 | |

- Значения некоторых метрик меняются при смене баланса классов

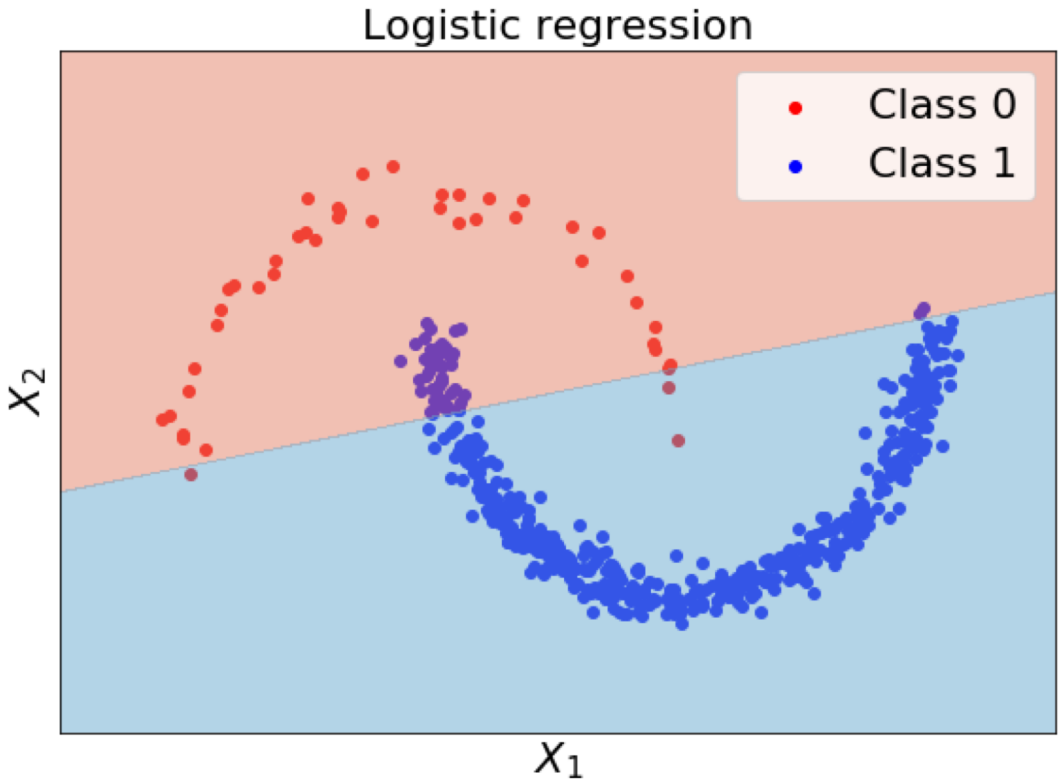

# Демонстрация

| Metric | 1:1 | 1:10 | 10:1 |
|---|---|---|---|
| Accuracy | 0.89 | 0.89 | 0.89 |
| Precision | 0.89 | 0.99 | 0.47 |
| Recall | 0.89 | 0.89 | 0.89 |
| $F_1$ | 0.89 | 0.94 | 0.61 |
| ROC AUC | 0.97 | 0.97 | 0.97 |

- **Recall** и **ROC AUC** устойчивы к дисбалансу классов
- Для **Accuracy** это не выполняется в общем случае

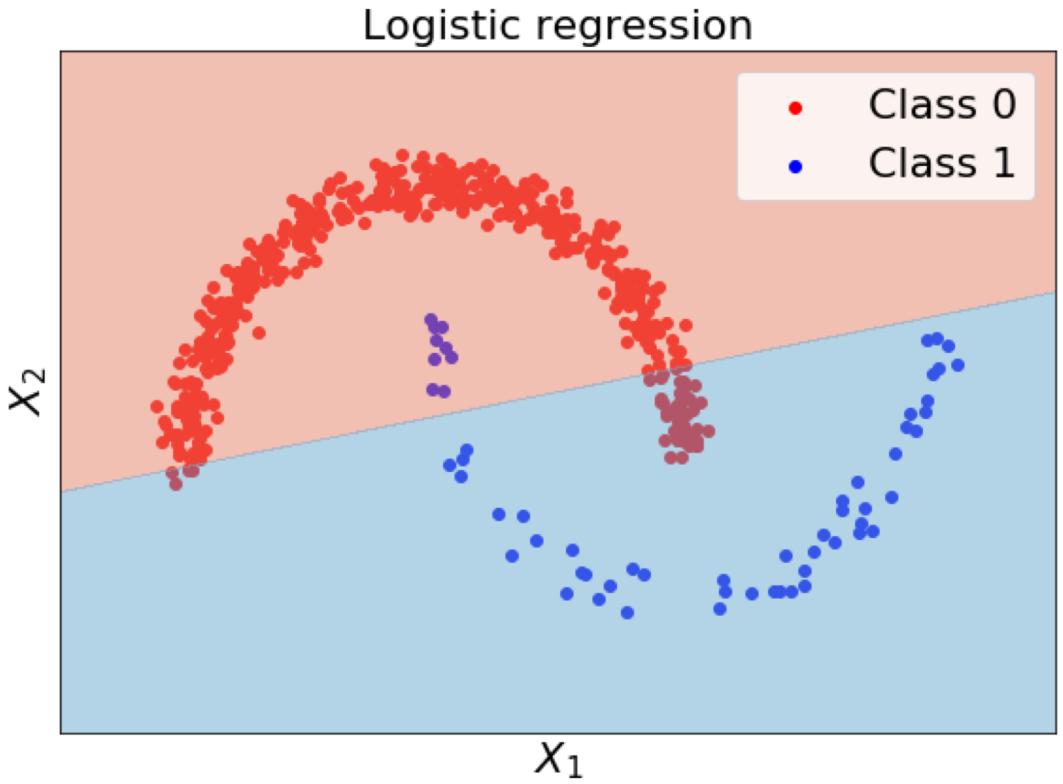

# Метрики качества для регрессии

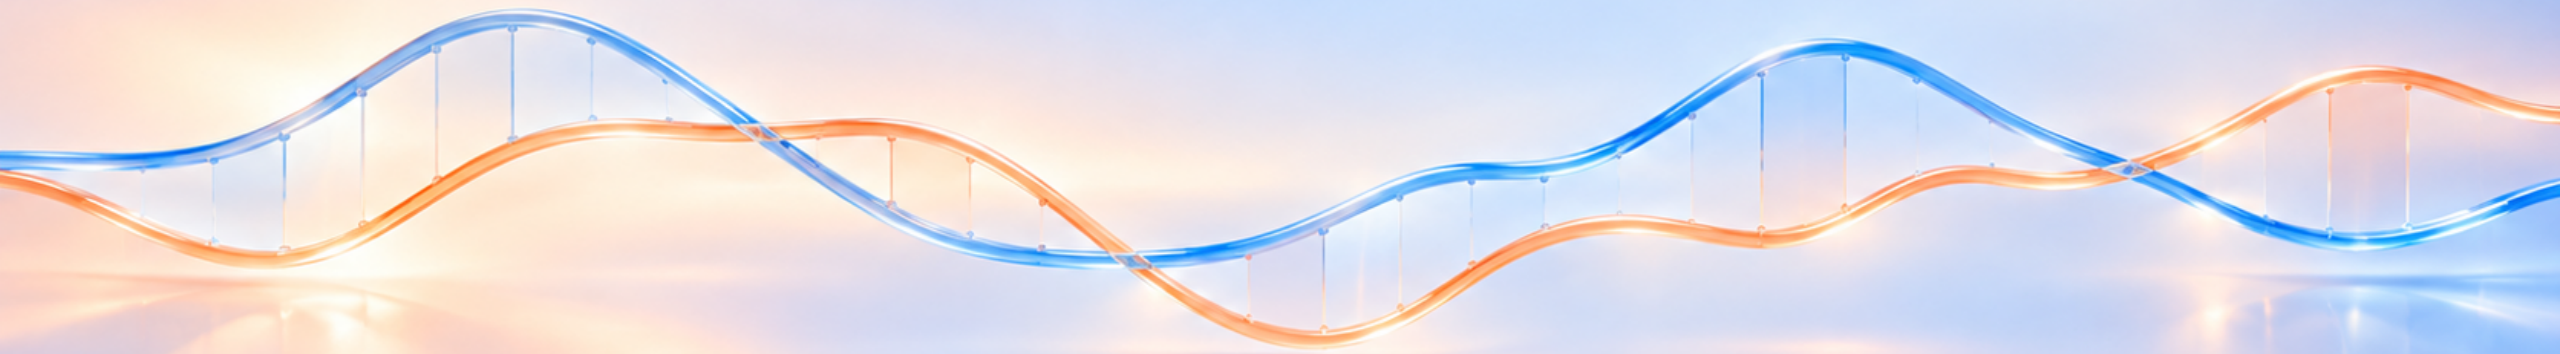

# Задача

Пусть даны $X, y$ и линейна модель:

$$\hat{y} = Xw$$

**Цель** – измерить **качество модели**, определить насколько блзки прогнозы $\hat{y}$ к реальным значениям $y$.

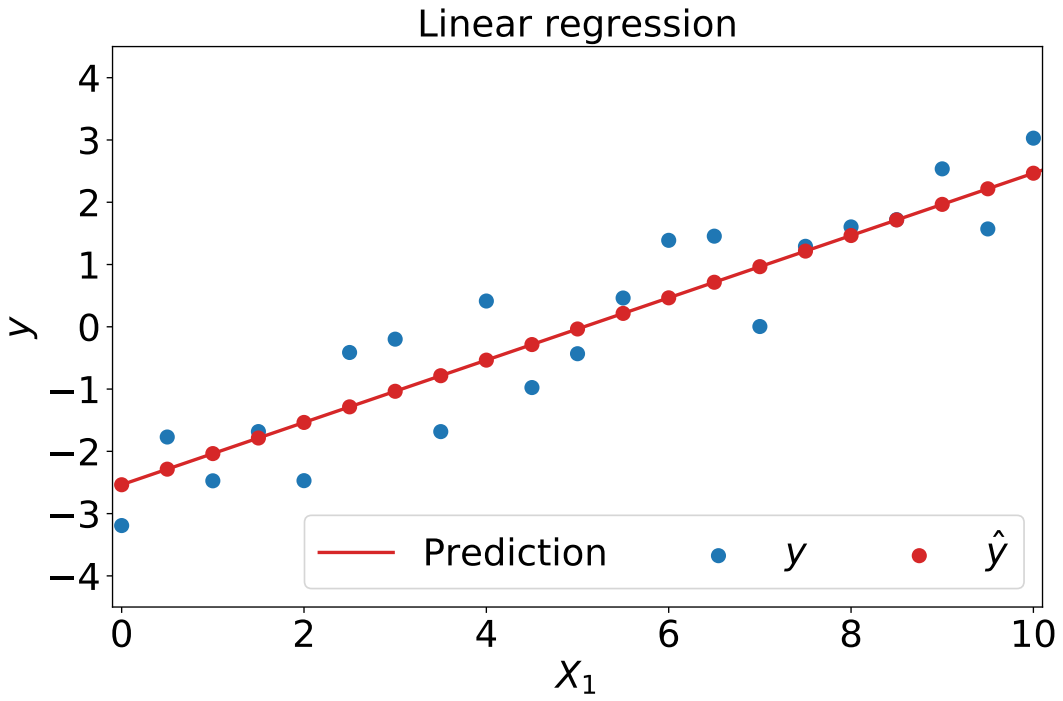

# Популярные метрики качества

- Root Mean Squared Error (RMSE):

$$RMSE = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2}$$

- Mean Absolute Error (MAE):

$$MAE = \frac{1}{N}\sum_{i=1}^{N}|\hat{y}_i - y_i|$$

- Трудно определить хорошую модель: $RMSE = 1$ выражает разное качество моделей при $\bar{y} = 100$ and $\bar{y} = 1$

# Другие метрики качества #1

- Mean Absolute Percentage Error (MAPE):

$$MAPE = \frac{100}{N}\sum_{i=1}^{N}\left|\frac{\hat{y}_i - y_i}{y_i}\right|$$

- Измеряем относительную ошибку модели
- Легко интерпретировать
- Чувствительна к масштабу $y$

# Другие метрики качества #2

- Relative Squared Error (RSE):

$$RSE = \sqrt{\frac{\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{N}(y_i - \bar{y})^2}}$$

- Relative Absolute Error (RAE):

$$RAE = \frac{\sum_{i=1}^{N}|y_i - \hat{y}_i|}{\sum_{i=1}^{N}|y_i - \bar{y}|}$$

- Робастны (мене чувствительны) к масштабу $y$

# Other quality metrics #3

- Root Mean Squared Logarithmic Error (RMSLE):

$$RMSLE = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(\log(y_i + 1) - \log(\hat{y}_i + 1))^2}$$

- Отличный выбор, когда $y_i$ меняется на несколько порядков: $y_i \in [0, 10^6]$

# Пример

| Metric | No outliers |
|---|---|
| RMSE | 0.67 |
| MAE | 0.59 |
| MAPE, % | 1035 |
| RSE | 0.39 |
| RAE | 0.40 |

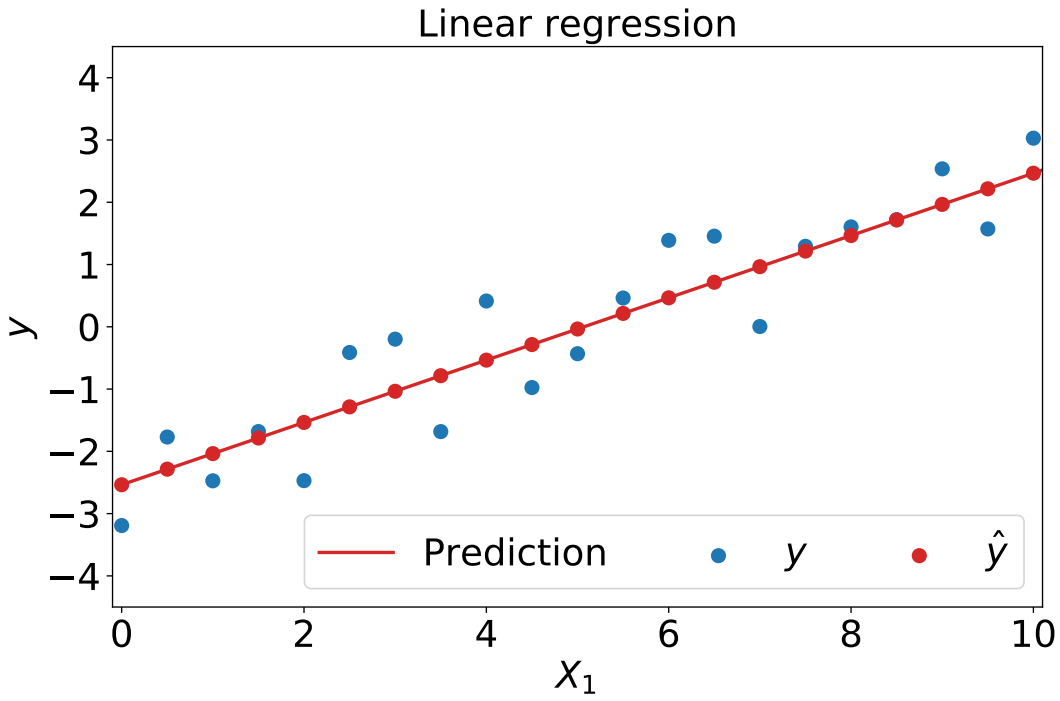


MAPE ведет себя плохо, потому что $y$ и $y_i$ близки к 0

# Demonstration

| Metric | No outliers | With outlier |
|---|---|---|
| RMSE | 0.67 | 1.93 |
| MAE | 0.59 | 0.96 |
| MAPE, % | 1035 | 1040 |
| RSE | 0.39 | 0.92 |
| RAE | 0.40 | 0.58 |

- Выбросы могут сместить метрики
- MAE и RAE более робастны

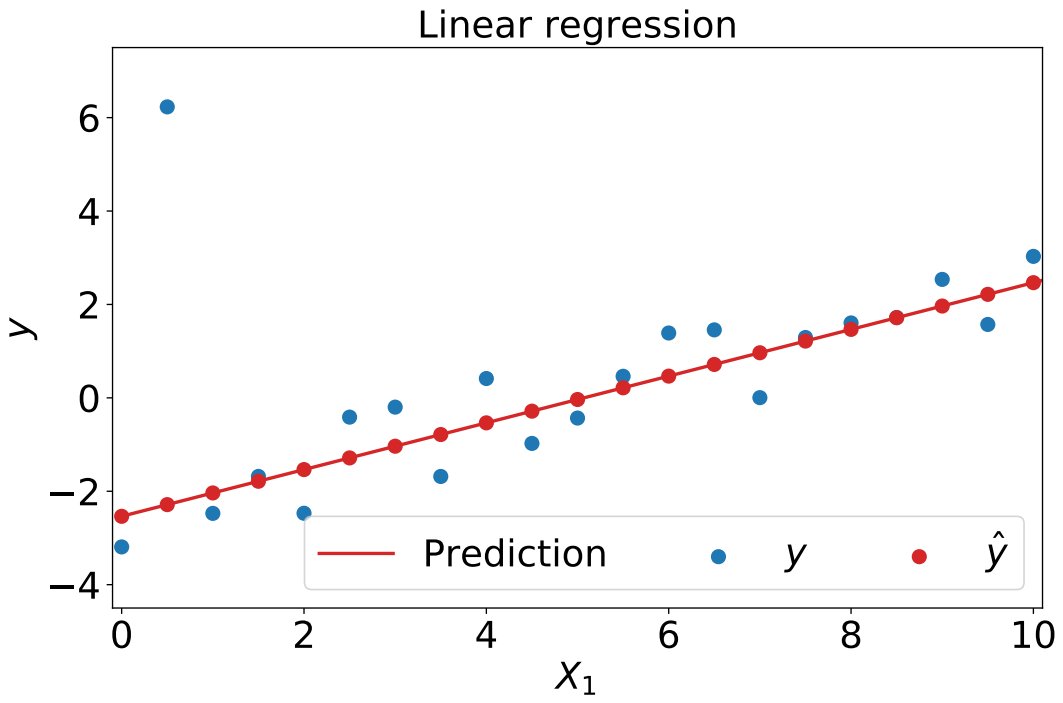

# Переобучение

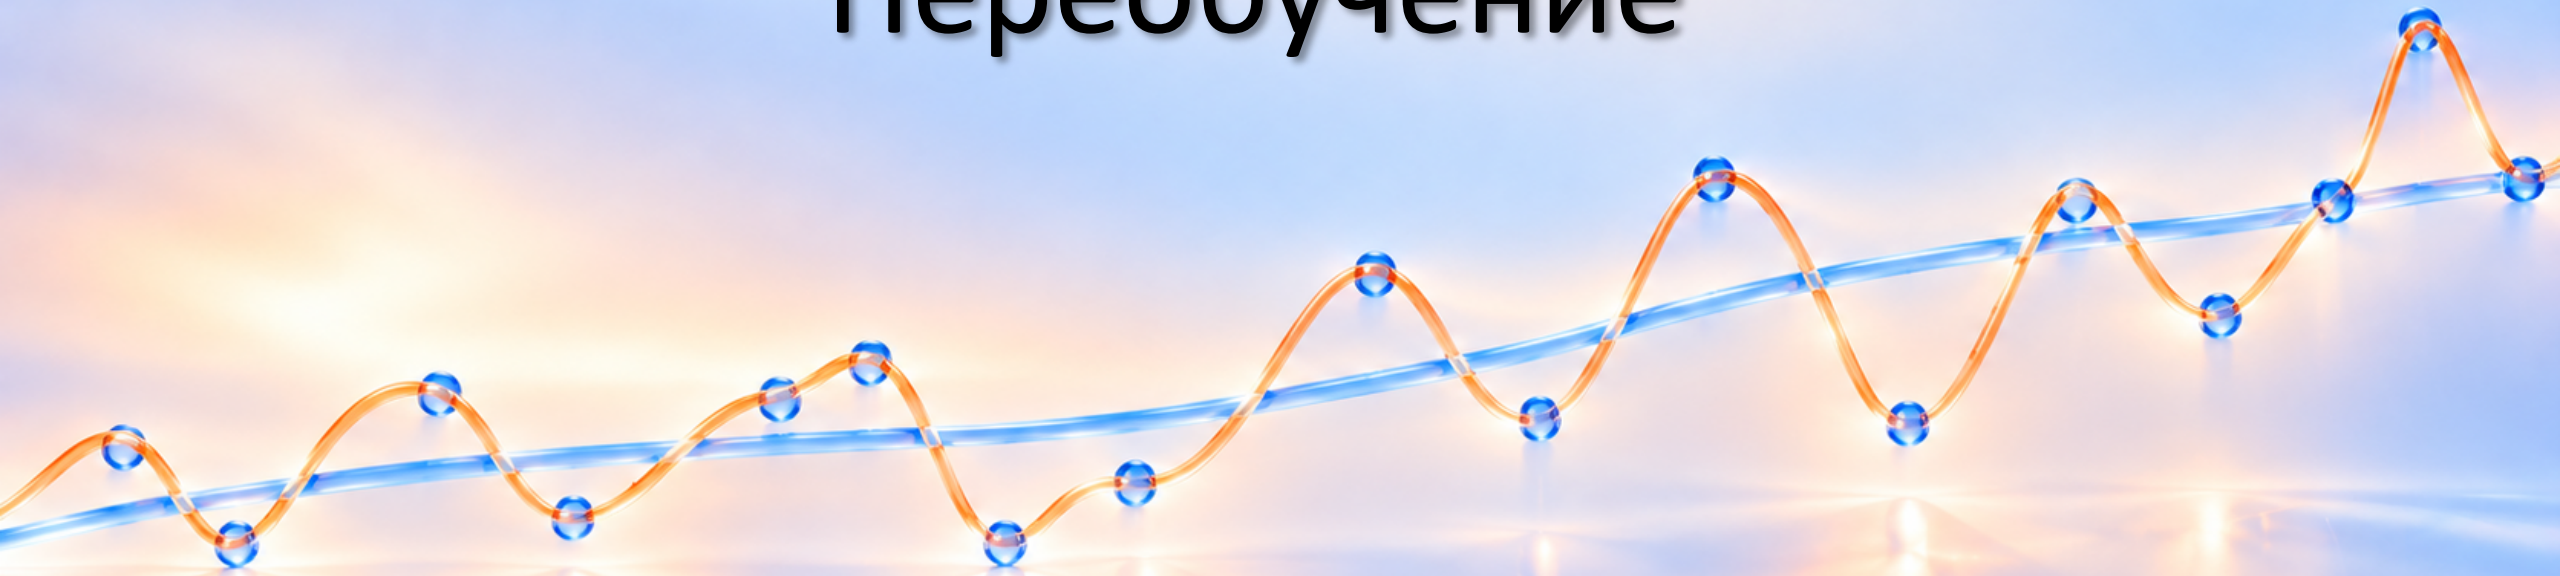

# Обучение и тест

- **Обучающая выборка (train):** для обучения модели
- **Тестовая (отложенная) выборка (test):** для измерения качества модели

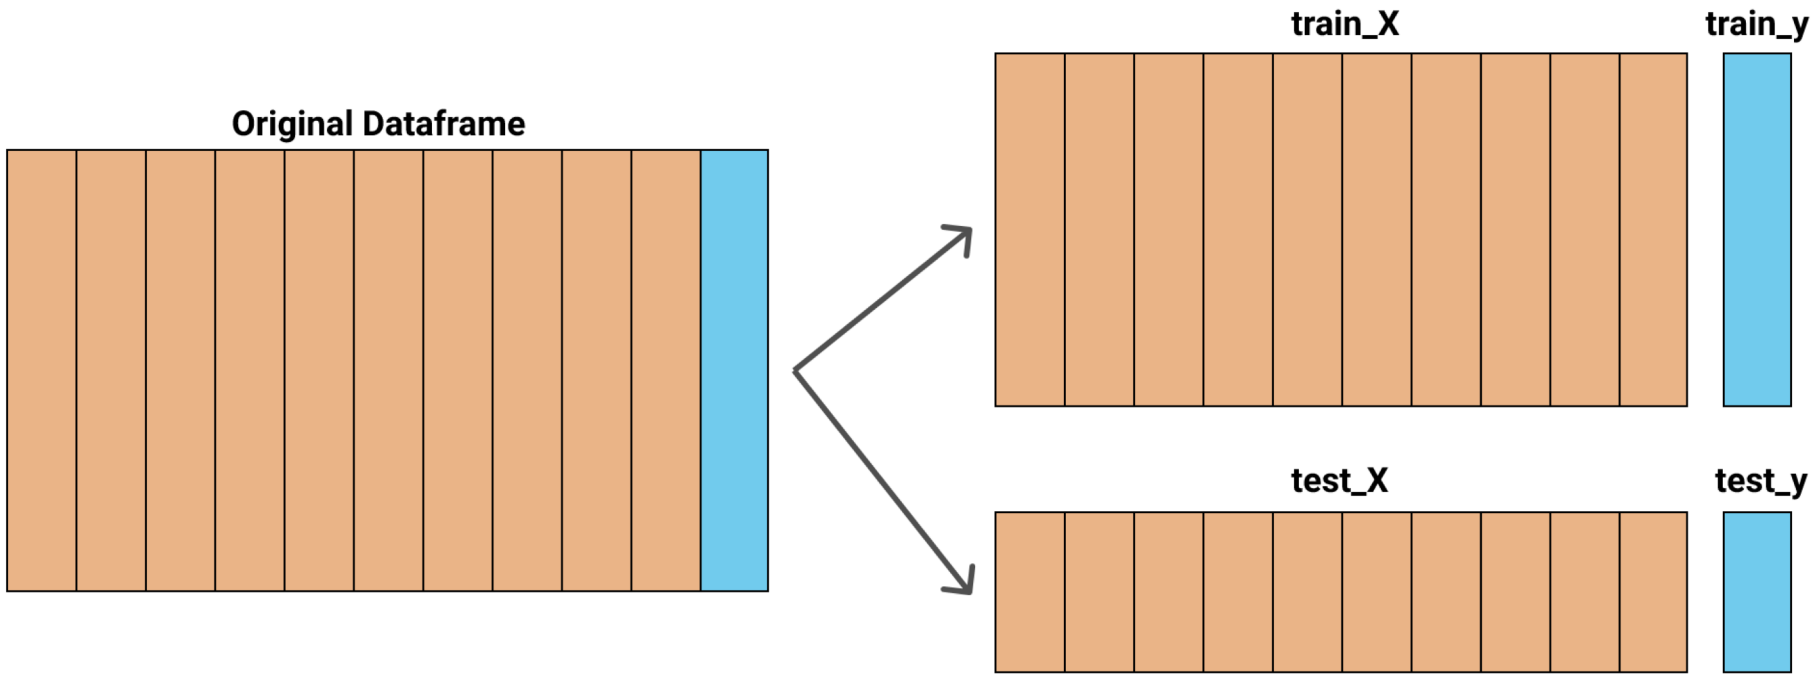

# Переобучение

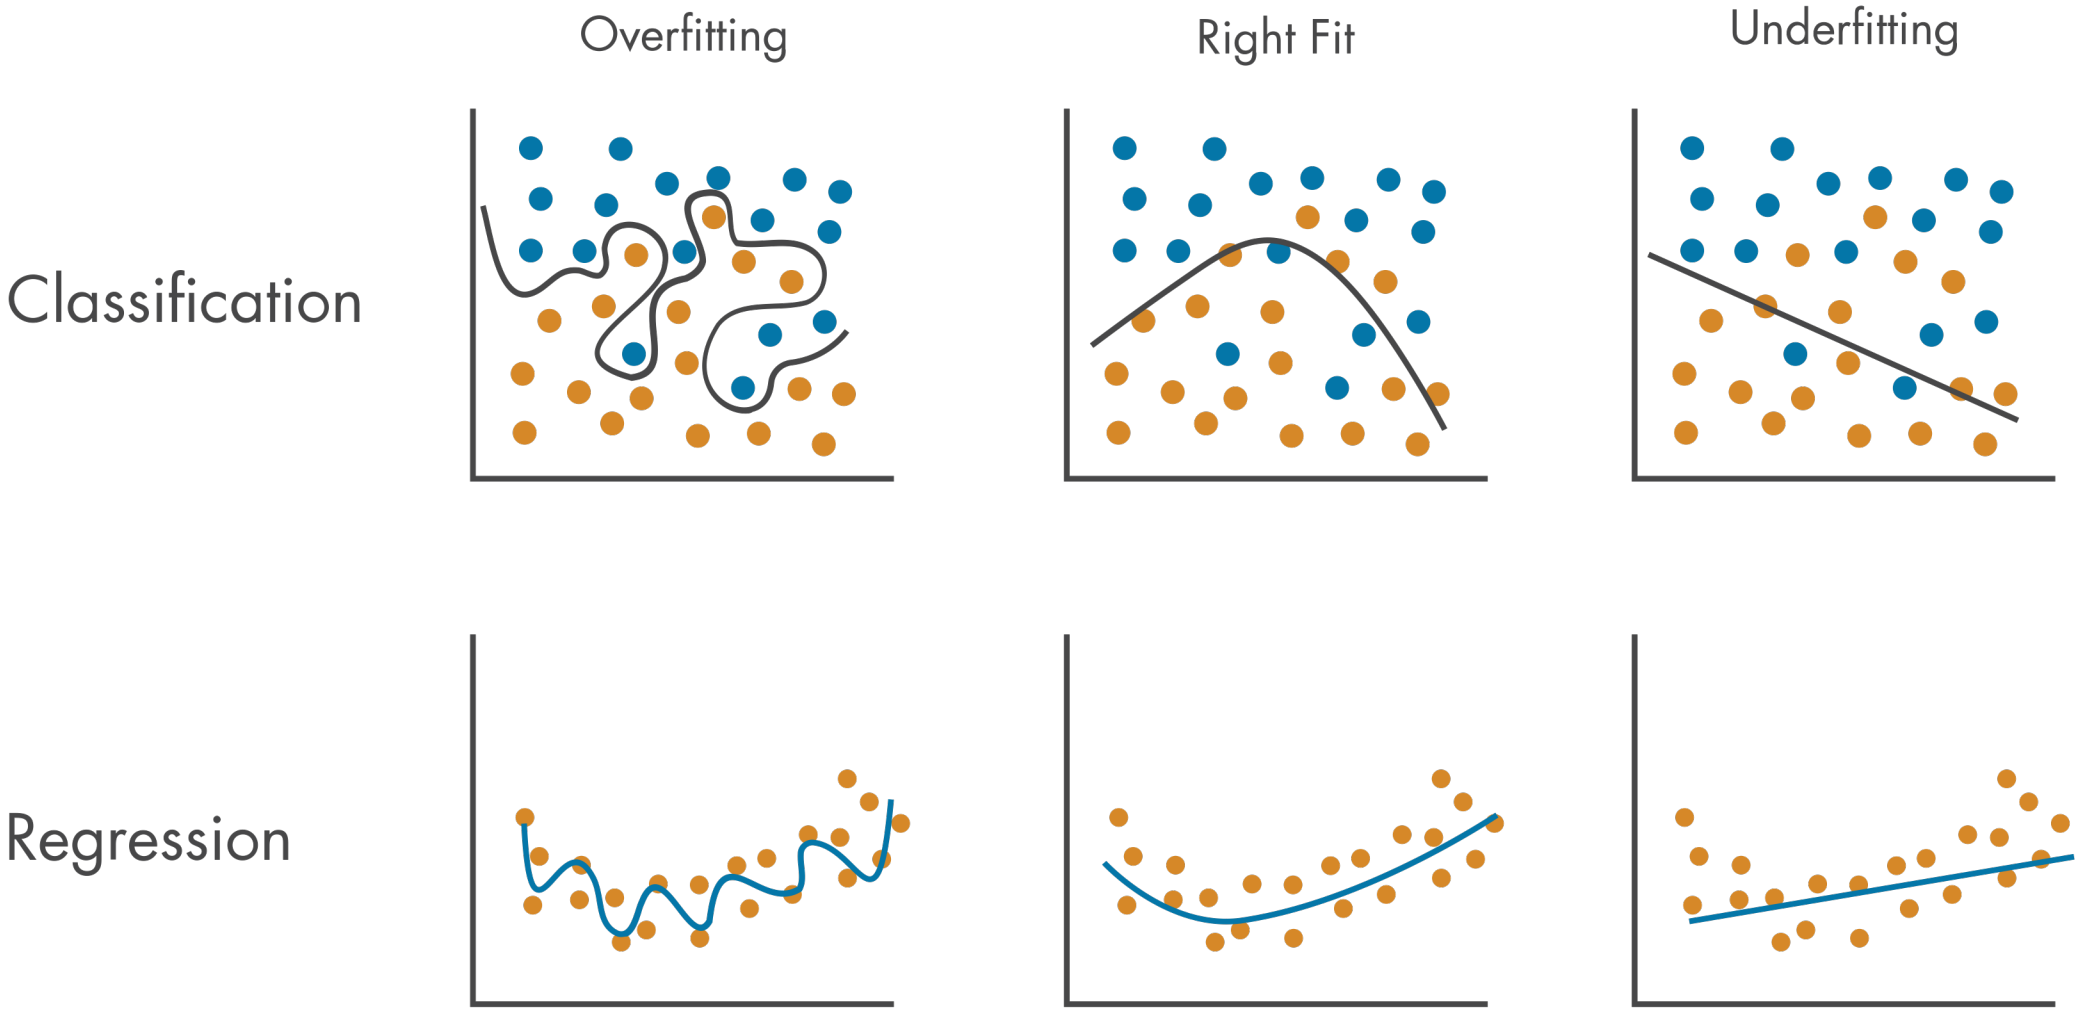


Источник: https://www.mathworks.com/discovery/overfitting.html

# Кривая обучения

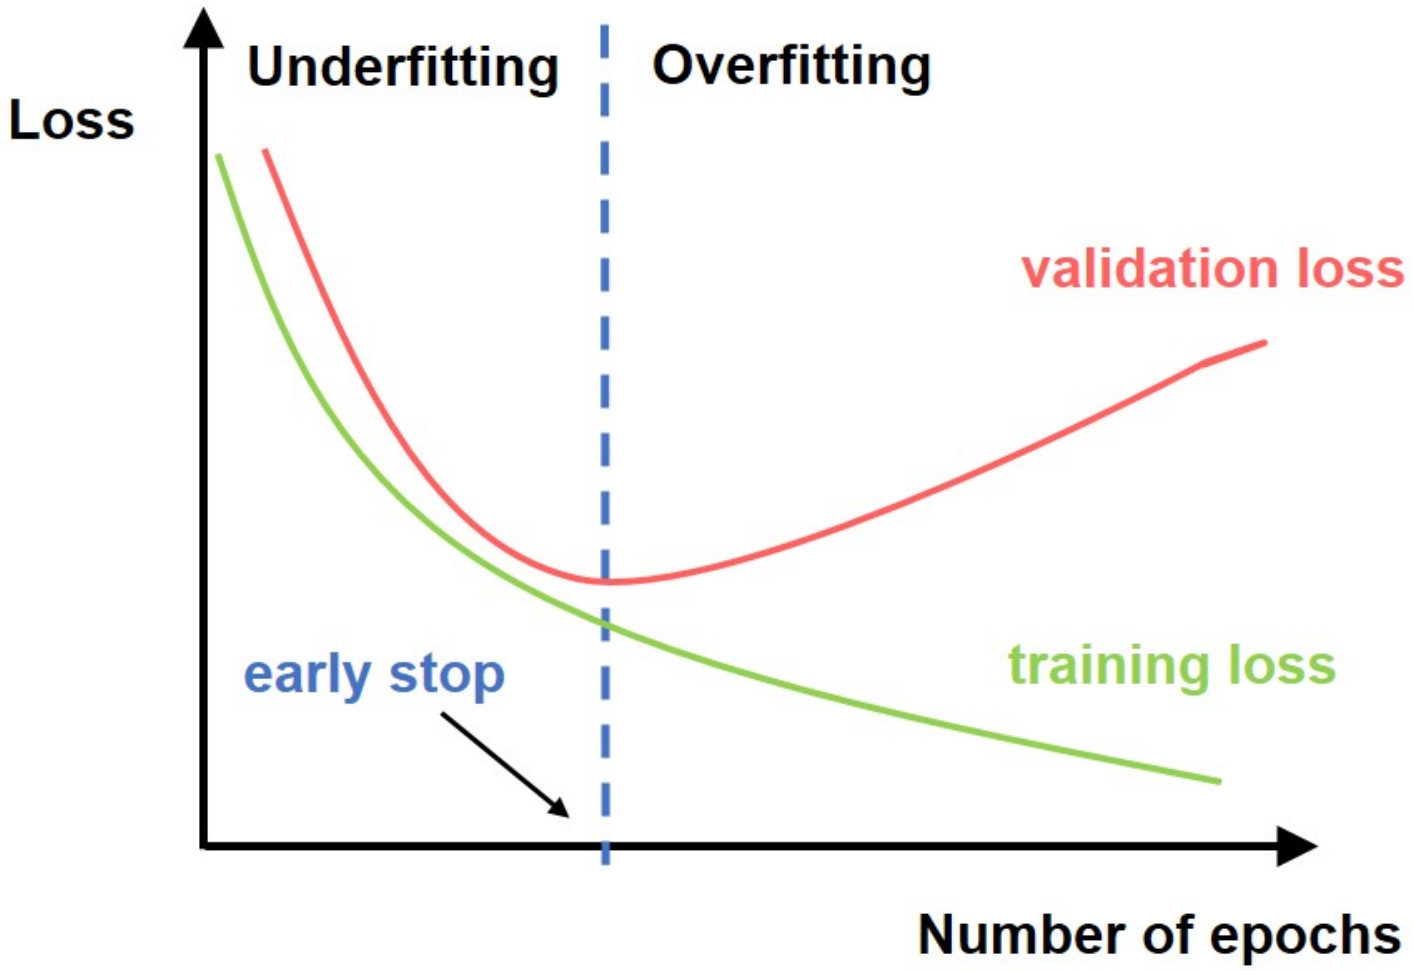


Число итераций градиентного спуска

Источник: https://datahacker.rs/018-pytorch-popular-techniques-to-prevent-the-overfitting-in-a-neural-networks/

# Регуляризация

- Линейная и логистическая регрессии
  - $L_1$-регуляризация
  - $L_2$-регуляризация
- KNN
  - Число соседей

# K-Fold кросс-валидация

**Каждый блок один раз используется для валидации.**
**На каждой итерации модель обучается заново.**

Предобработка обучается только на обучающих блоках. Тестовая выборка оценивается отдельно.

# Кросс-валидация (cross-validation)

- Используется для измерения качества моделей в машинном обучении
- Отложенная выборка (train / test):
  - Делим всю выборку на две подвыборки в пропорции 70:30
  - Большая часть данных не используется для обучения (хуже качество модели)
- K-Fold кросс-валидация
  - K берем порядка 10
  - Больше данных участвует в обучении отдельной модели
  - Проверяем качество на всех данных
  - Более точная оценка качества

# Leave-One-Out (LOO) кросс-валидация

Каждый объект один раз используется для валидации. Модель обучается заново.

# Многоклассовая классификация

# Задача

- Разделить объекты между **несколькими** классами.
- Многие классификаторы поддерживают несколько классов.
- Но не все ☹
- Как **разложить** эту задачу на несколько задач бинарной классификации?

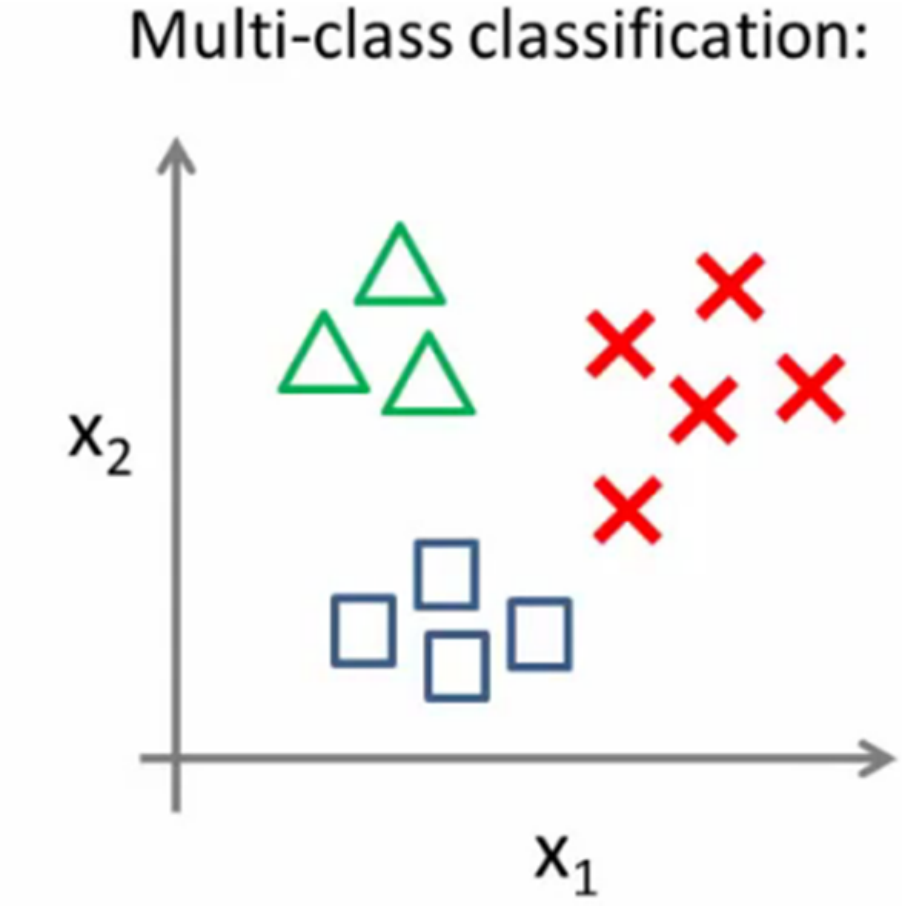

# Один против всех (one-vs-all)

- Пусть дано **K** классов
- Для **каждого** класса обучаем свой бинарный классификатор **отделять объекты этого класса от всех остальных**
- Всего обучаем **K** таких классификаторов

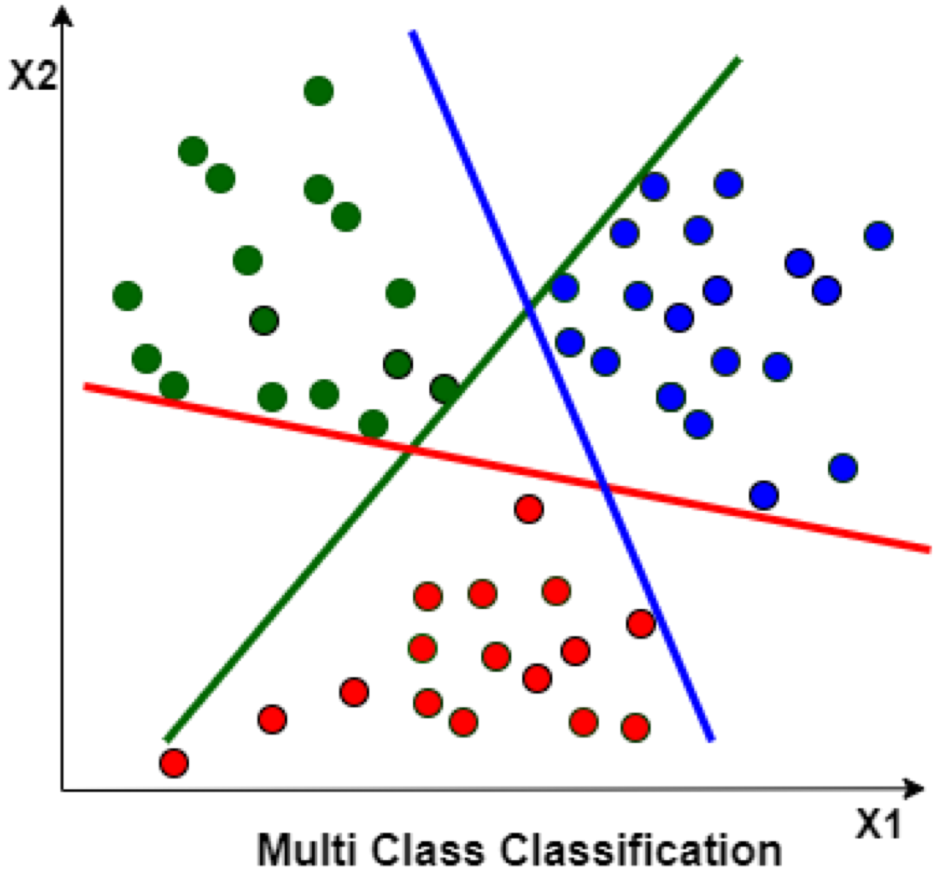

# Один против всех (one-vs-all)

- Пусть есть K обученных классификаторов: $\hat{p}_1(x), \hat{p}_2(x), \dots, \hat{p}_K(x)$
- Пусть дан объект $x_i$, для которого делаем прогноз:
  - Получаем K прогнозов: $\hat{p}_1(x_i), \hat{p}_2(x_i), \dots, \hat{p}_K(x_i)$
  - Находим класс с максимальным прогнозом:

$$\hat{y}(x_i) = \arg\max_{k \in \{1,\dots,K\}} \hat{p}_k(x_i)$$

  - Здесь $\hat{p}_k(x_i)$ – прогноз “вероятности” положительного ($k$-го) класса;
  - $\hat{y}(x_i)$ - итоговый прогноз метки класса (одного из K)

# Один против одного (one-vs-one)

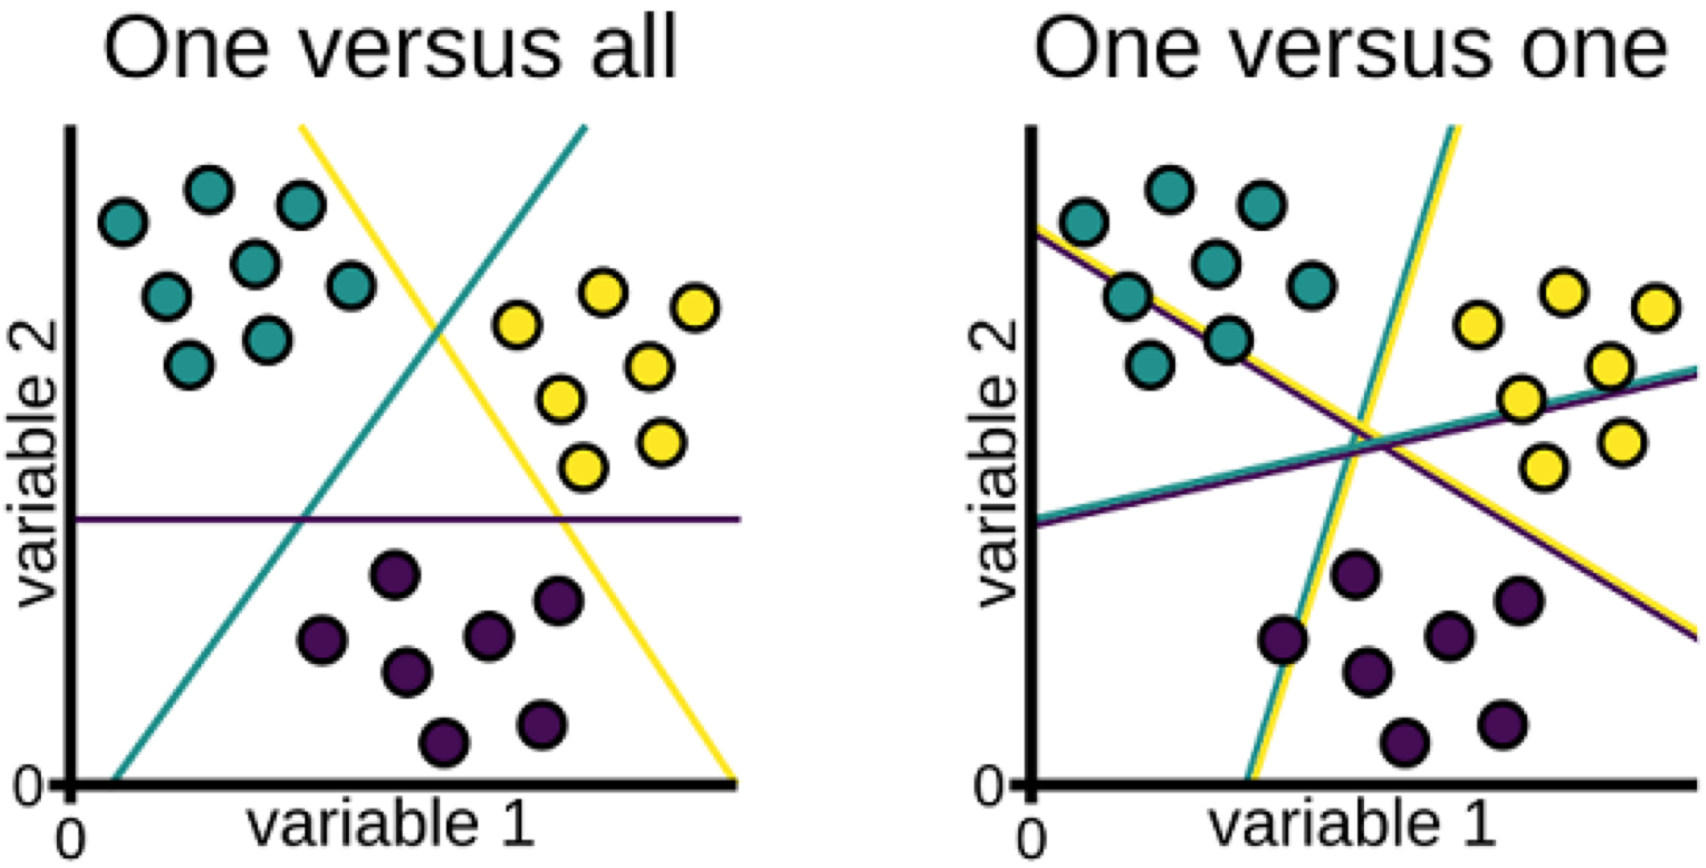

# Один против одного (one-vs-one)

- Для каждой пары классов $i, j$ обучаем свой бинарный классификатор $\hat{y}_{ij}(x)$
- Пусть дан объект $x_t$, для которого делаем прогноз:

$$\hat{y}(x_t) = \arg\max_{k \in \{1,\dots,K\}} \sum_{i=1}^{K} \sum_{j \neq i} [\hat{y}_{ij}(x_t) = k]$$

- Т.е. выбираем класс, за который наберется больше всего голосов

# (Дополнительно)
# Логистическая регрессия на К классов

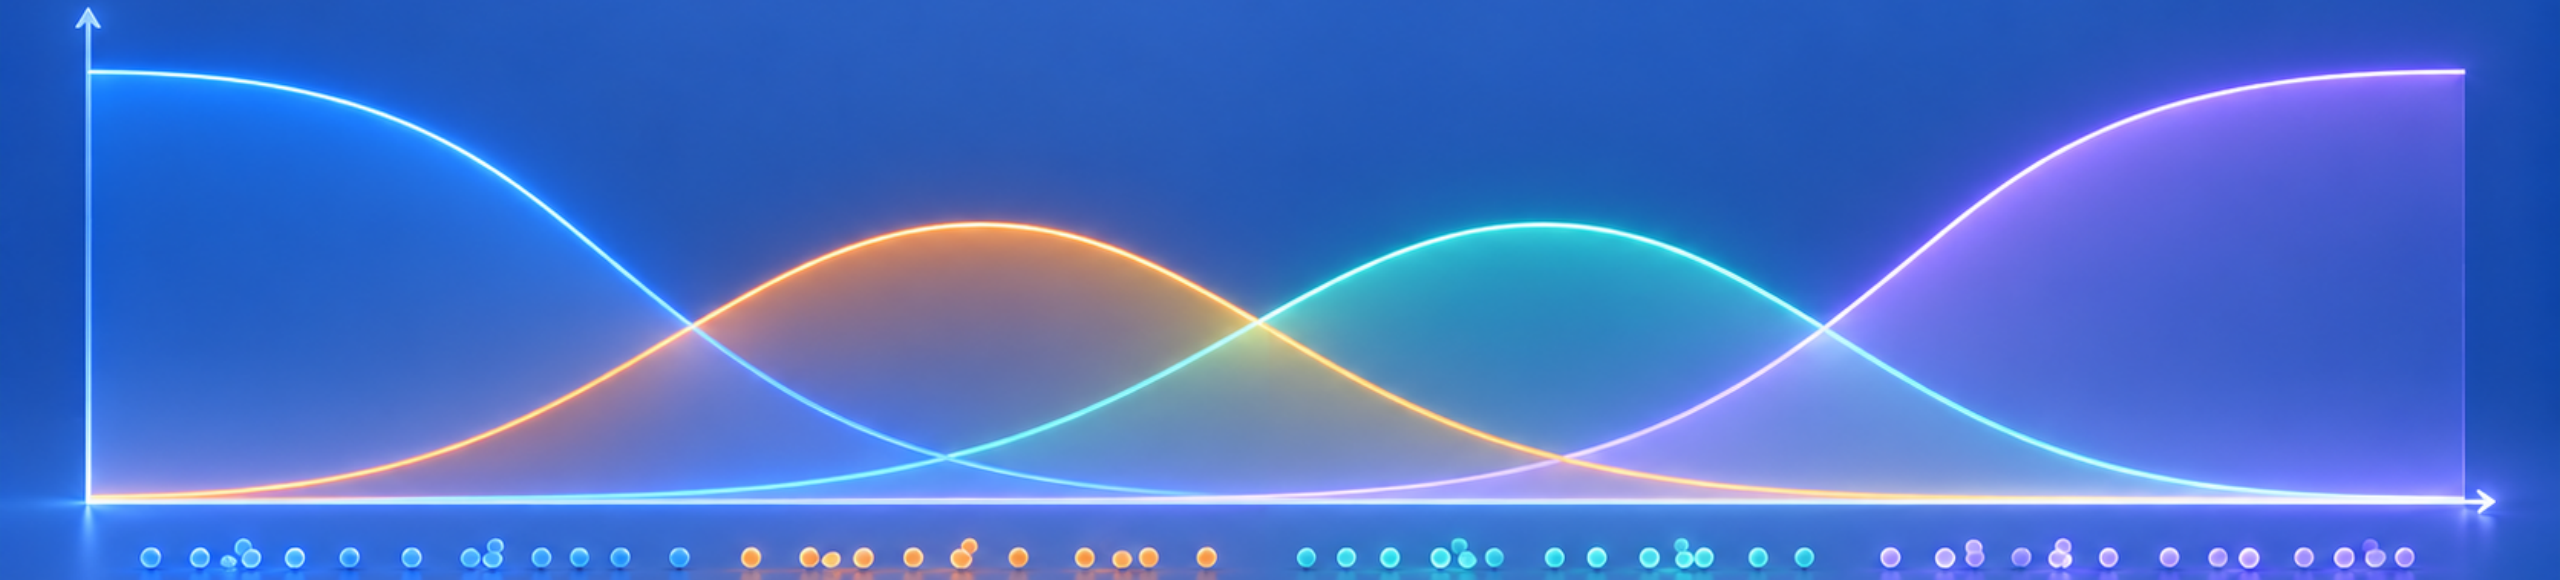

# Логистическая регрессия на 2 класса

- Вероятность класса 1:

$$p(y = \mathbf{1}|x_i) = \sigma\left(x_i^T w\right) = \hat{y}_i$$

- Вероятность класса 0:

$$p(y = \mathbf{0}|x_i) = 1 - \sigma(x_i^T w)$$

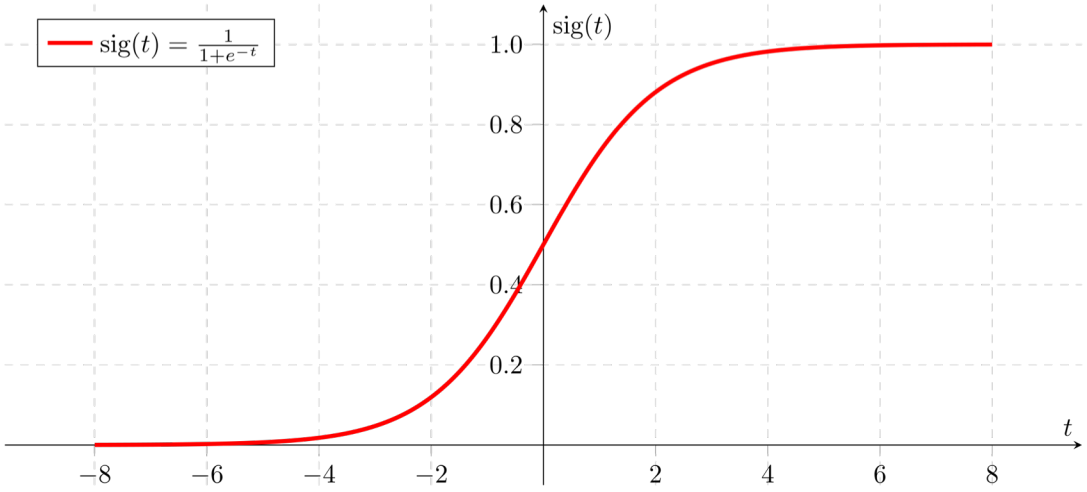

# Логистическая регрессия на K классов

- Строим **K один против всех** моделей:
  - Класс 1 против всех: $z_{i1} = x_i^T w_1$
  - Класс 2 против всех: $z_{i2} = x_i^T w_2$
  - Класс 3 против всех: $z_{i3} = x_i^T w_3$
  - Класс K против всех: $z_{iK} = x_i^T w_K$

- Получаем **K** векторов весов для обучения

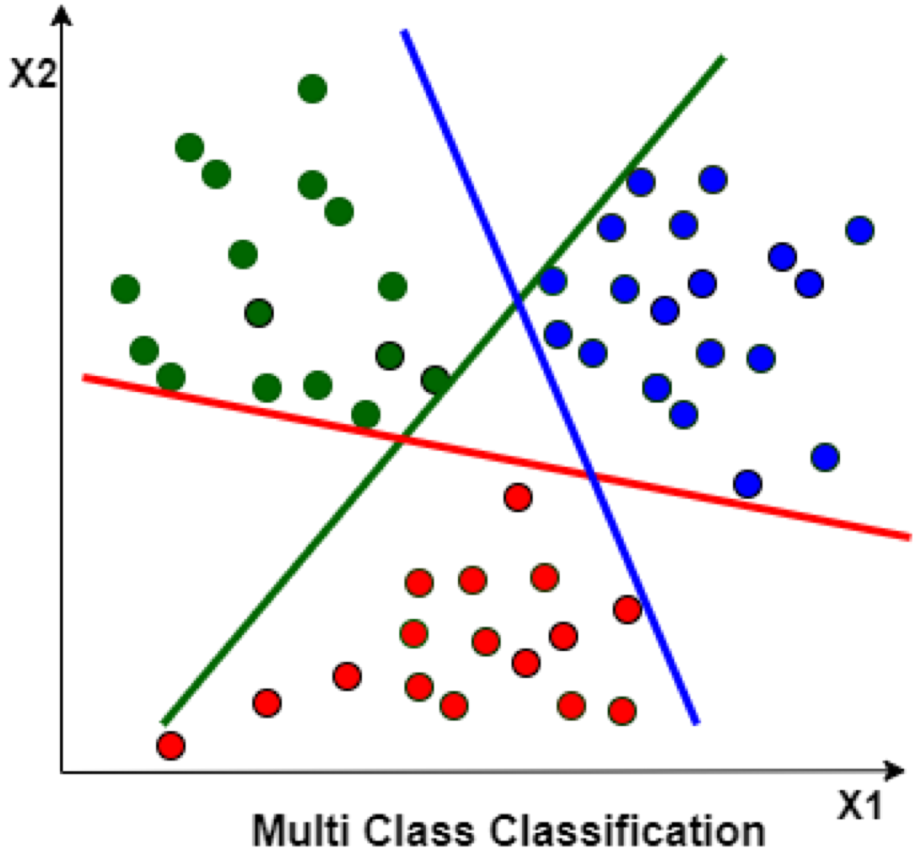

# Логистическая регрессия на K классов

- SoftMax – многомерный вариант сигмоиды:

$$\hat{y}_{i1} = p(y = \mathbf{1}|x_i) = \frac{e^{z_{i1}}}{\sum_{k=1}^{K} e^{z_{ik}}}$$

$$\hat{y}_{i2} = p(y = \mathbf{2}|x_i) = \frac{e^{z_{i2}}}{\sum_{k=1}^{K} e^{z_{ik}}}$$

$$\hat{y}_{iK} = p(y = \boldsymbol{K}|x_i) = \frac{e^{z_{iK}}}{\sum_{k=1}^{K} e^{z_{ik}}}$$

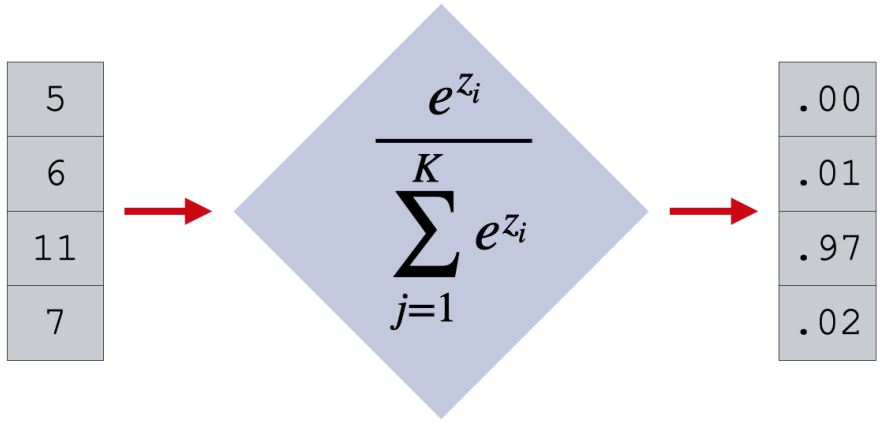

# Логарифм правдоподобия для K классов

- Правдоподобие:

$$\text{Likelihood} = -\prod_{i=1}^{n} p(y=1|x_i)^{[y_i=1]} p(y=2|x_i)^{[y_i=2]} \dots p(y=K|x_i)^{[y_i=k]}$$

- Логарифм правдоподобия (функция потерь):

$$L = -\sum_{i=1}^{n}\sum_{k=1}^{K} [y_i = k] \log(\hat{y}_{ik}) \to \min_{w_1,\dots,w_K}$$

# Пример

Предсказания нейронной сети

| | пес | кот | жук |
|---|---|---|---|
| 1 | 0.7 | **0.1** | 0.2 |
| 2 | 0.8 | 0.15 | **0.05** |
| 3 | 0.04 | **0.9** | 0.06 |
| 4 | **0.6** | 0.1 | 0.3 |
| 5 | 0.75 | **0.2** | 0.05 |

Правильные ответы Y

| | |
|---|---|
| 1 | кот |
| 2 | жук |
| 3 | кот |
| 4 | пес |
| 5 | кот |

Кросс-энтропийный функционал

$$Q(w) = -\sum_{n=1}^{N} \log P(y_n | f(x_n, w))$$

-log 0.1 - log 0.05 - log 0.9 - log 0.6 - log 0.2

# Метрики качества для мультикласса

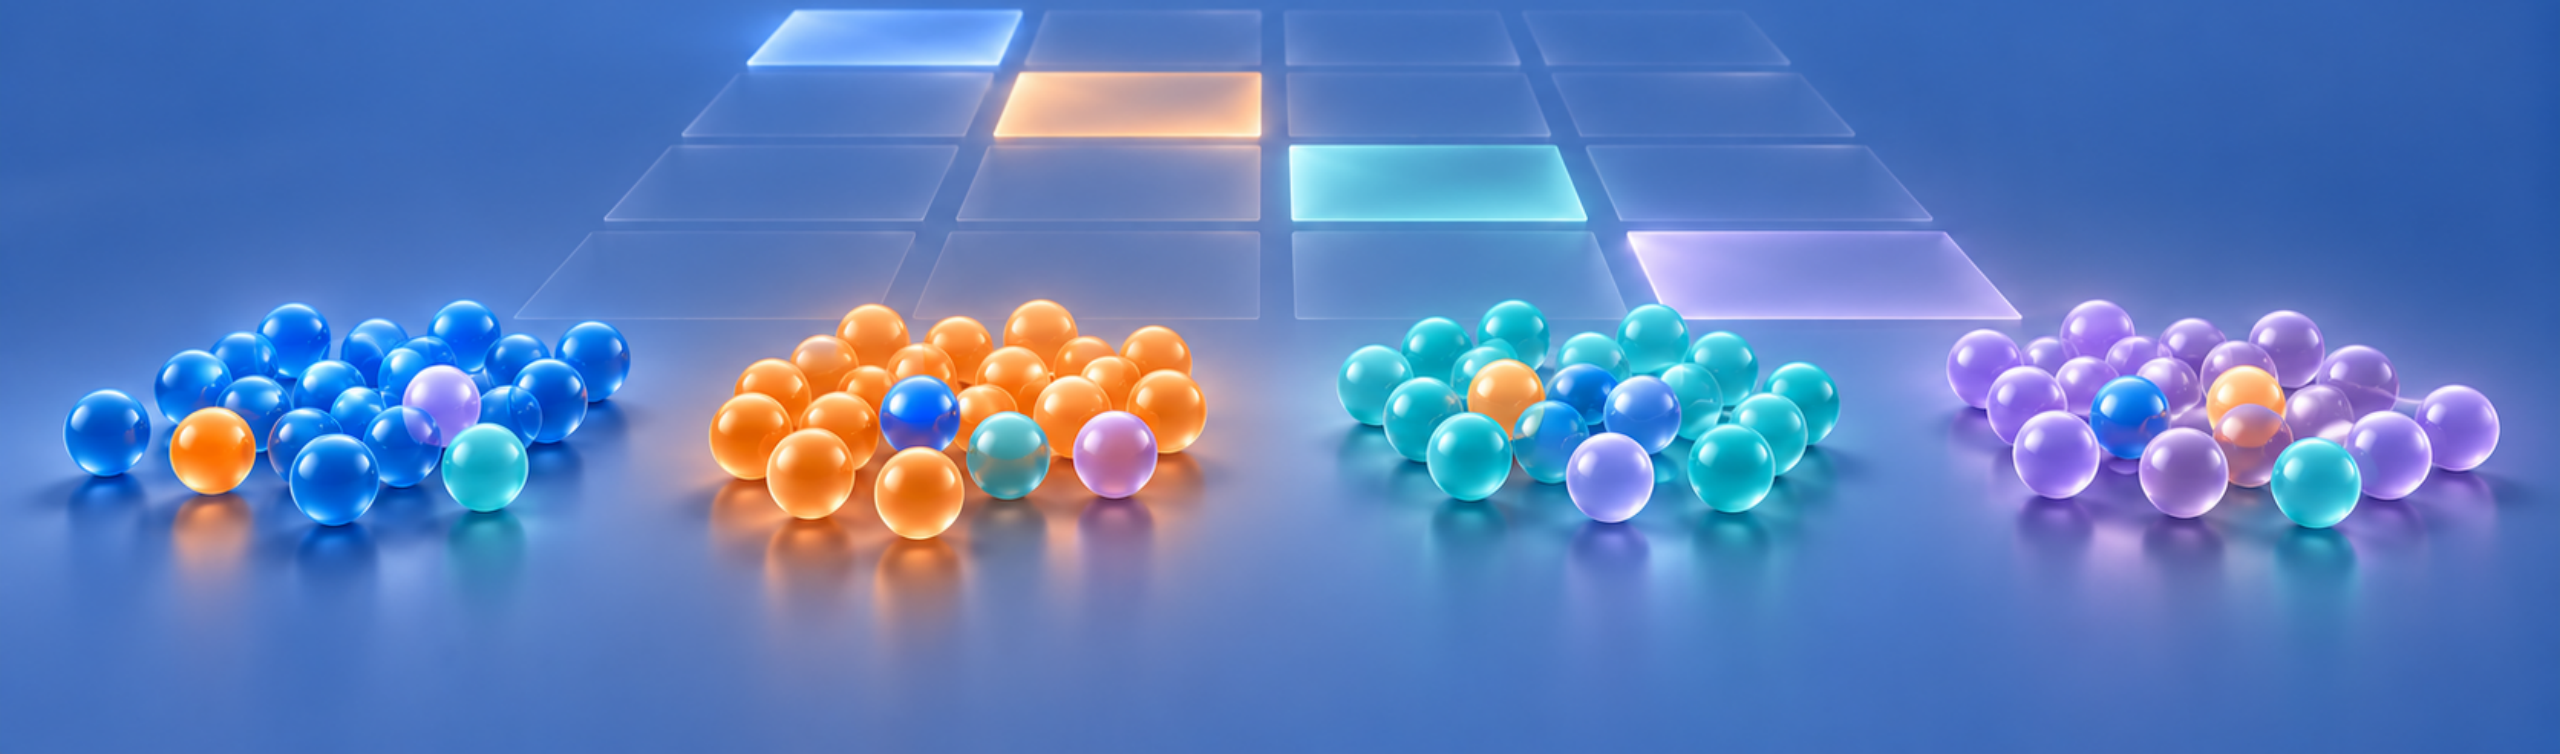

# Задача

- Мы знаем как считать метрики для **двух** классов.
- Что делать в случаем K классов?

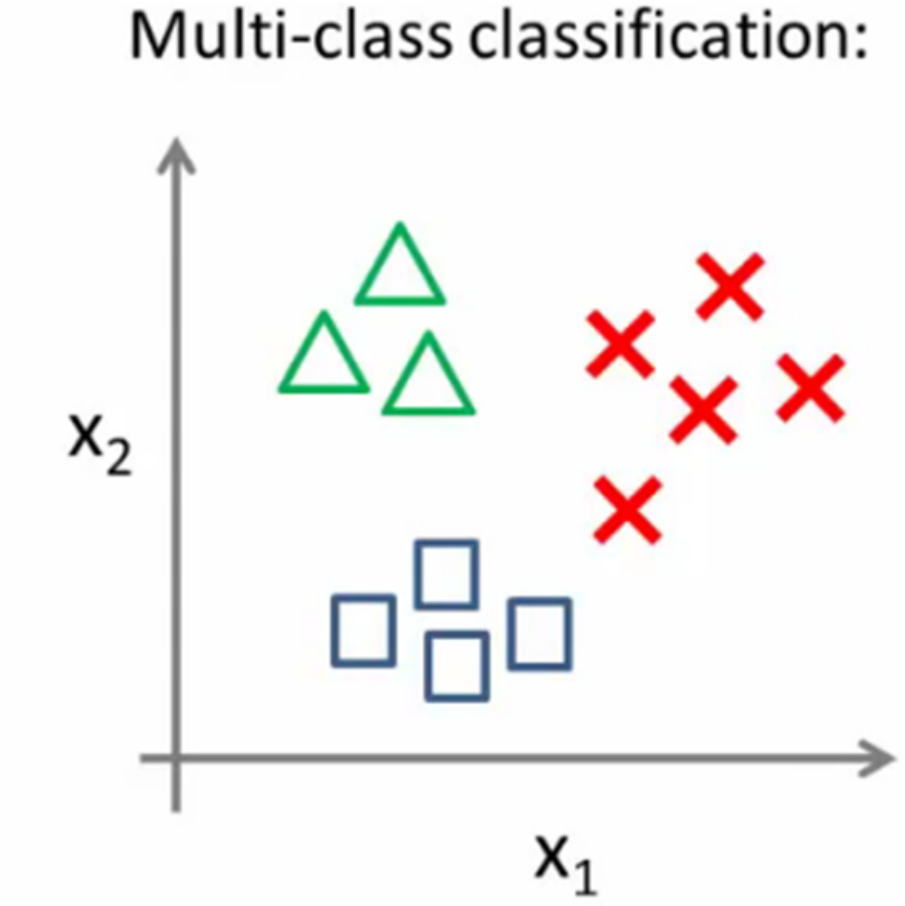

# Микро-усреднение

- Пусть дано K классов
- Рассмотрим K один против всех задач
- Для каждой задачи считаем $TP_k, FP_k, FN_k, TN_k$
- Усредняем эти характеристики по всем классам:

$$\overline{TP} = \frac{1}{K}\sum_{k=1}^{K} TP_k$$

- Используем их для подсчета метрик качества:

$$Precision = \frac{\overline{TP}}{\overline{TP} + \overline{FP}}$$

# Макро-усреднение

- Пусть дано K классов
- Рассмотрим K один против всех задач
- Для каждой задачи считаем $TP_k, FP_k, FN_k, TN_k$
- Используем их для подсчета метрик качества:

$$Precision_k = \frac{TP_k}{TP_k + FP_k}$$

- Усредняем эти метрики качества по всем классам:

$$\overline{Precision} = \frac{1}{K}\sum_{k=1}^{K} Precision_k$$

# Пересекающиеся классы

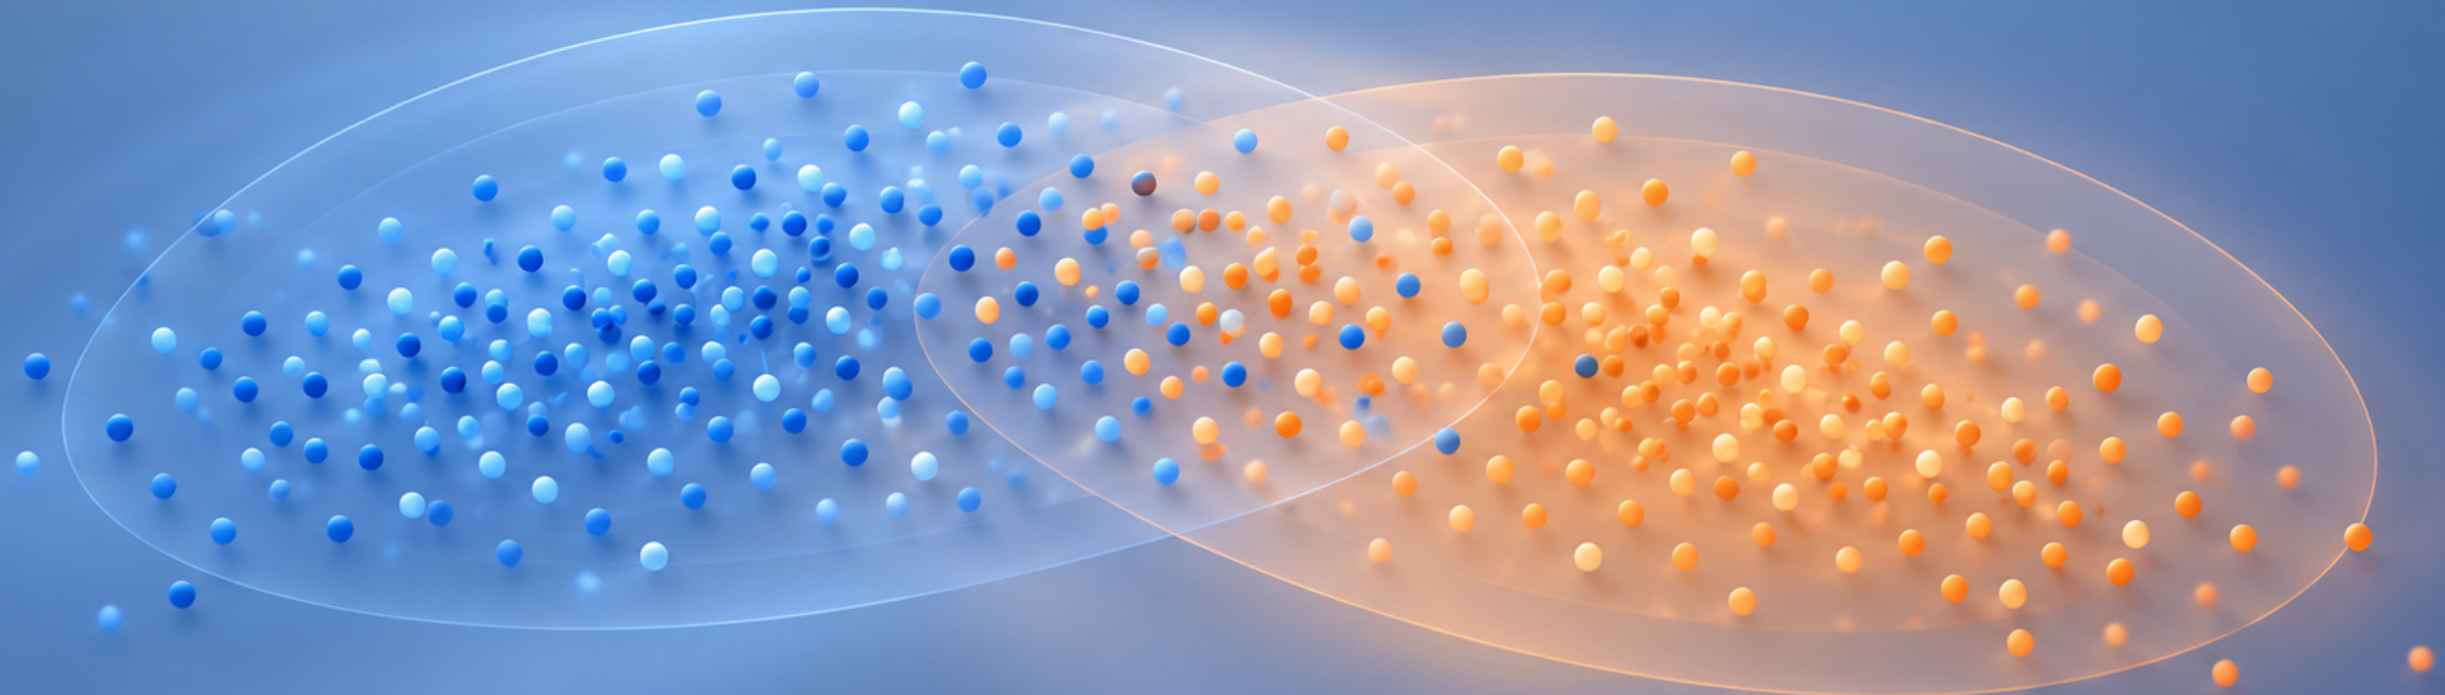

# Классификация с пересекающимися классами

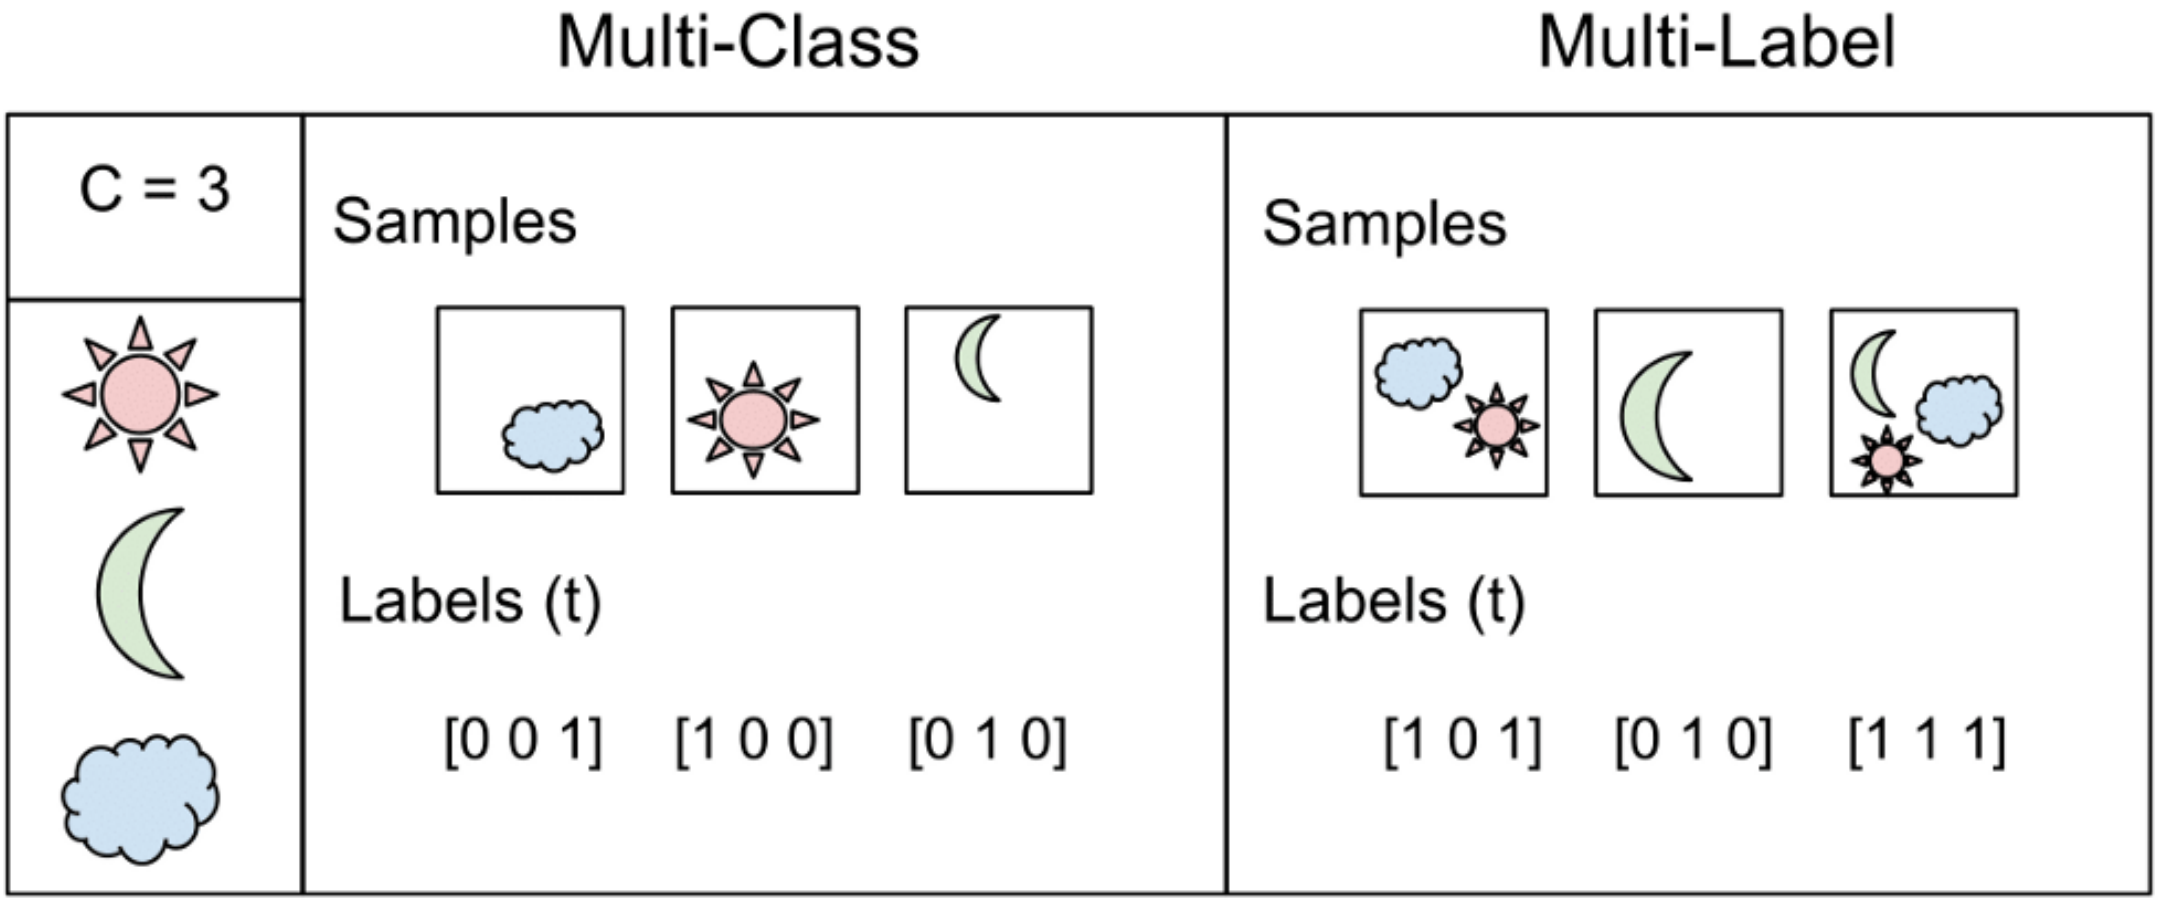

# Независимая классификация (one-vs-all)

- Пусть есть K обученных классификаторов: $\hat{p}_1(x), \hat{p}_2(x), \dots, \hat{p}_K(x)$
- Пусть дан объект $x_i$, для которого делаем прогноз:
  - Получаем K прогнозов: $\hat{p}_1(x_i), \hat{p}_2(x_i), \dots, \hat{p}_K(x_i)$
  - Тогда вектор прогнозов:

$$\hat{y}(x_i) = \begin{pmatrix} [\hat{p}_1(x_i) > \tau\,] \\ [\hat{p}_2(x_i) > \tau\,] \\ \dots \\ [\hat{p}_K(x_i) > \tau\,] \end{pmatrix}$$

  - Можно взять порог $\tau = 0.5$
  - Здесь $\hat{p}_k(x_i)$ – прогноз “вероятности” положительного ($k$-го) класса;
  - $\hat{y}(x_i)$ - итоговый прогноз метки класса (несколько из K)

# Независимая классификация

- Самое простое решение задачи **multi-label classification**
- Не учитывает связи между классами

# Заключение

# Вопросы

- Что такое точность, полнота и F-мера?
- Что такое AUC-ROC? Опишите алгоритм построения ROC-кривой.
- В чем состоят преимущества и недостатки использования метрик Mean squared error (MSE) и Mean absolute error (MAE) в задаче регрессии? Запишите формулу метрики Mean absolute percentage error (MAPE).
- Что такое переобучение и недообучение? Как отличить переобучение от недообучения?
- Что такое кросс-валидация и для чего она используется? Чем применение кросс-валидации лучше, чем разбиение выборки на обучение и контроль?
- В чём заключается подход с независимой классификацией в задаче классификации с пересекающимися классами (multilabel classification)?
- Что такое микро- и марко-усреднение при оценивании качества многоклассовой классификации?