Машинное обучение

Лекция 7

Композиции алгоритмов. Бэггинг.

Михаил Гущин

mhushchyn@hse.ru

НИУ ВШЭ, 2026

Эволюция решающих деревьев



Решающие деревья

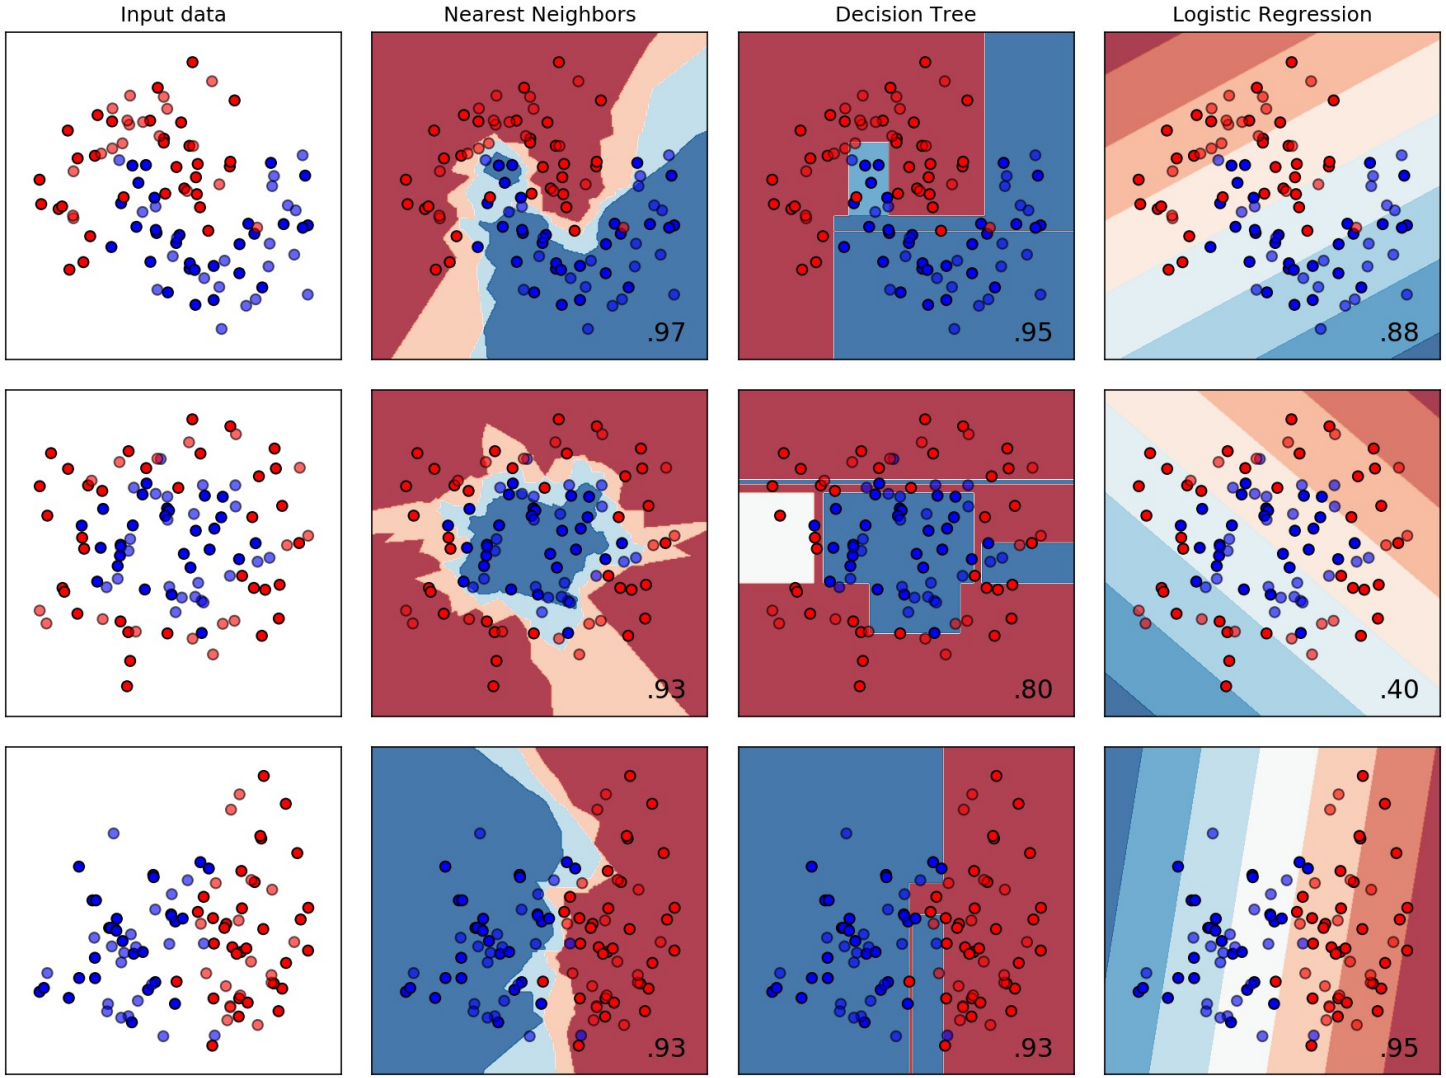


Случайный лес решающих деревьев



Постановка задачи

Классификаторы

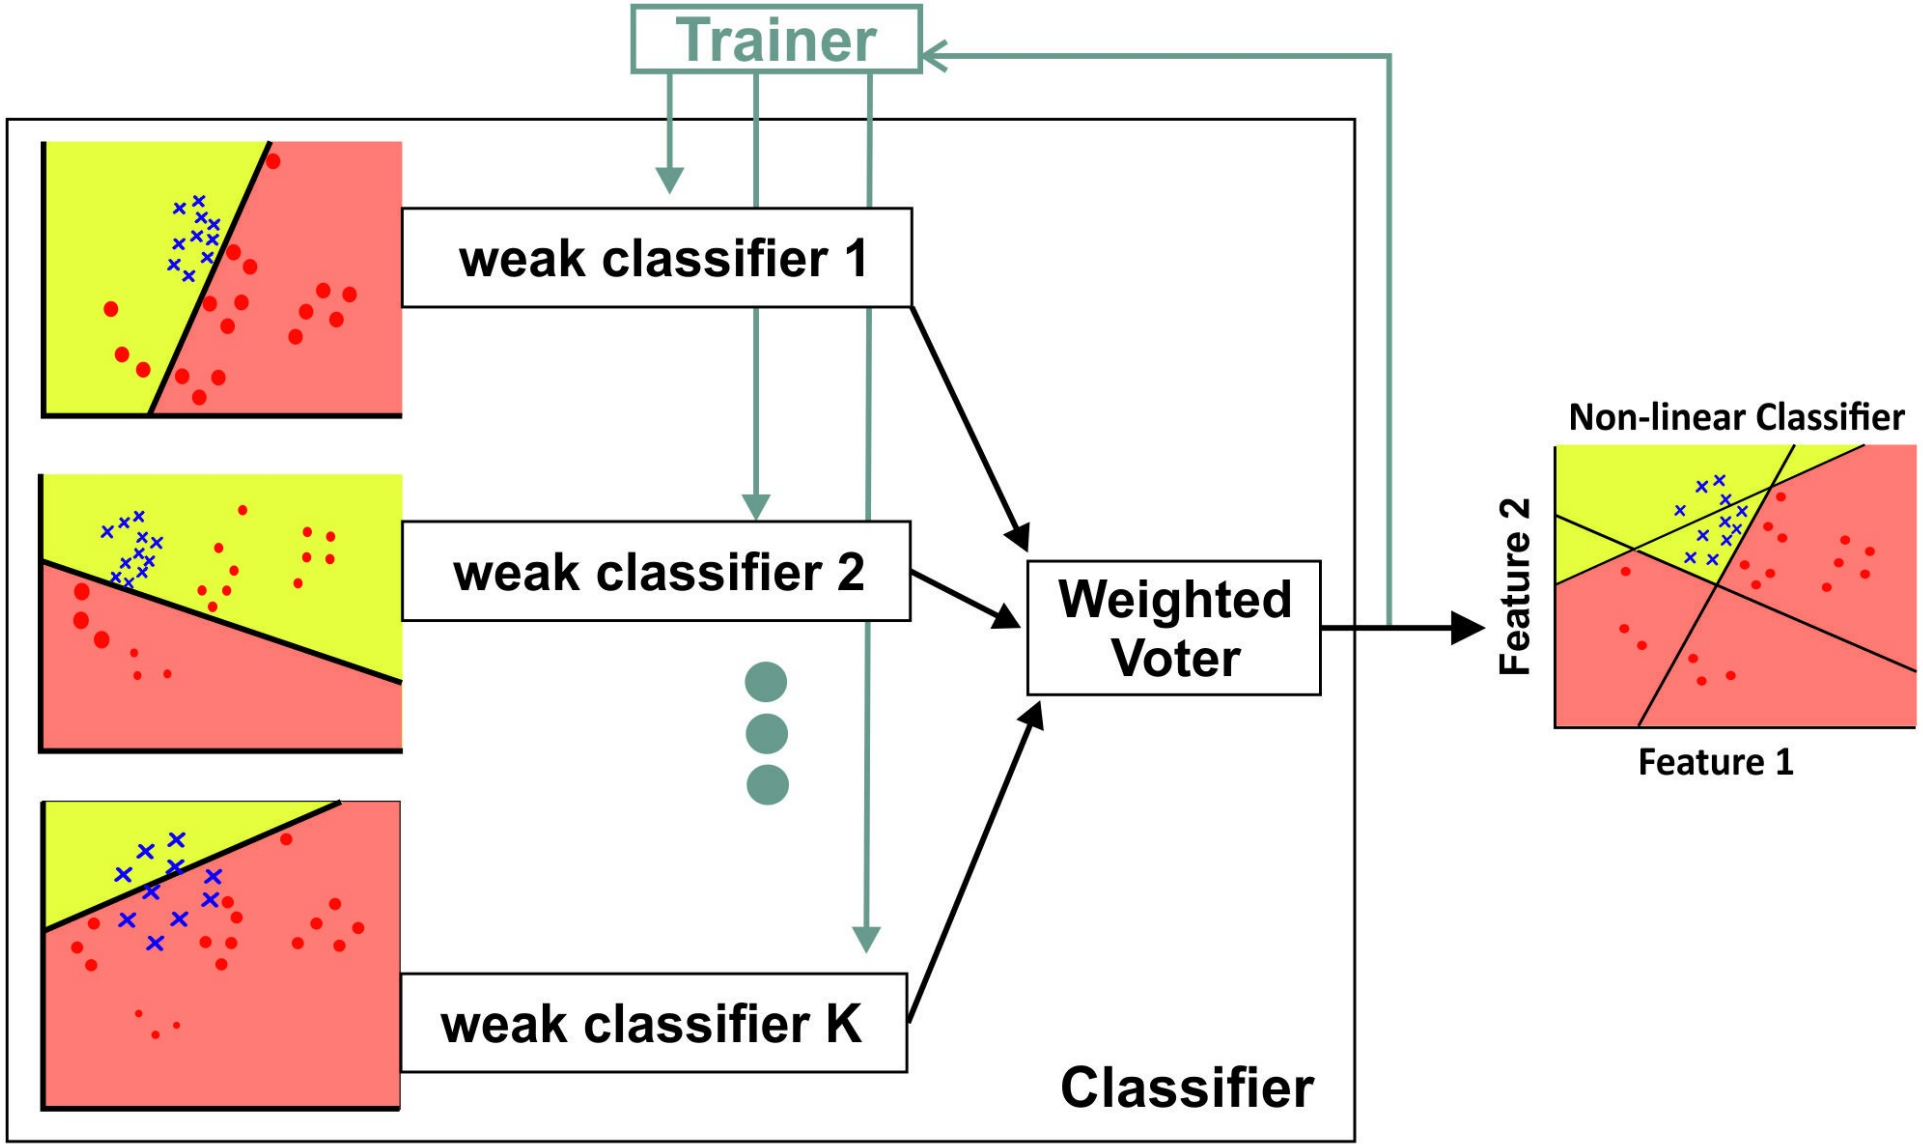


Задача

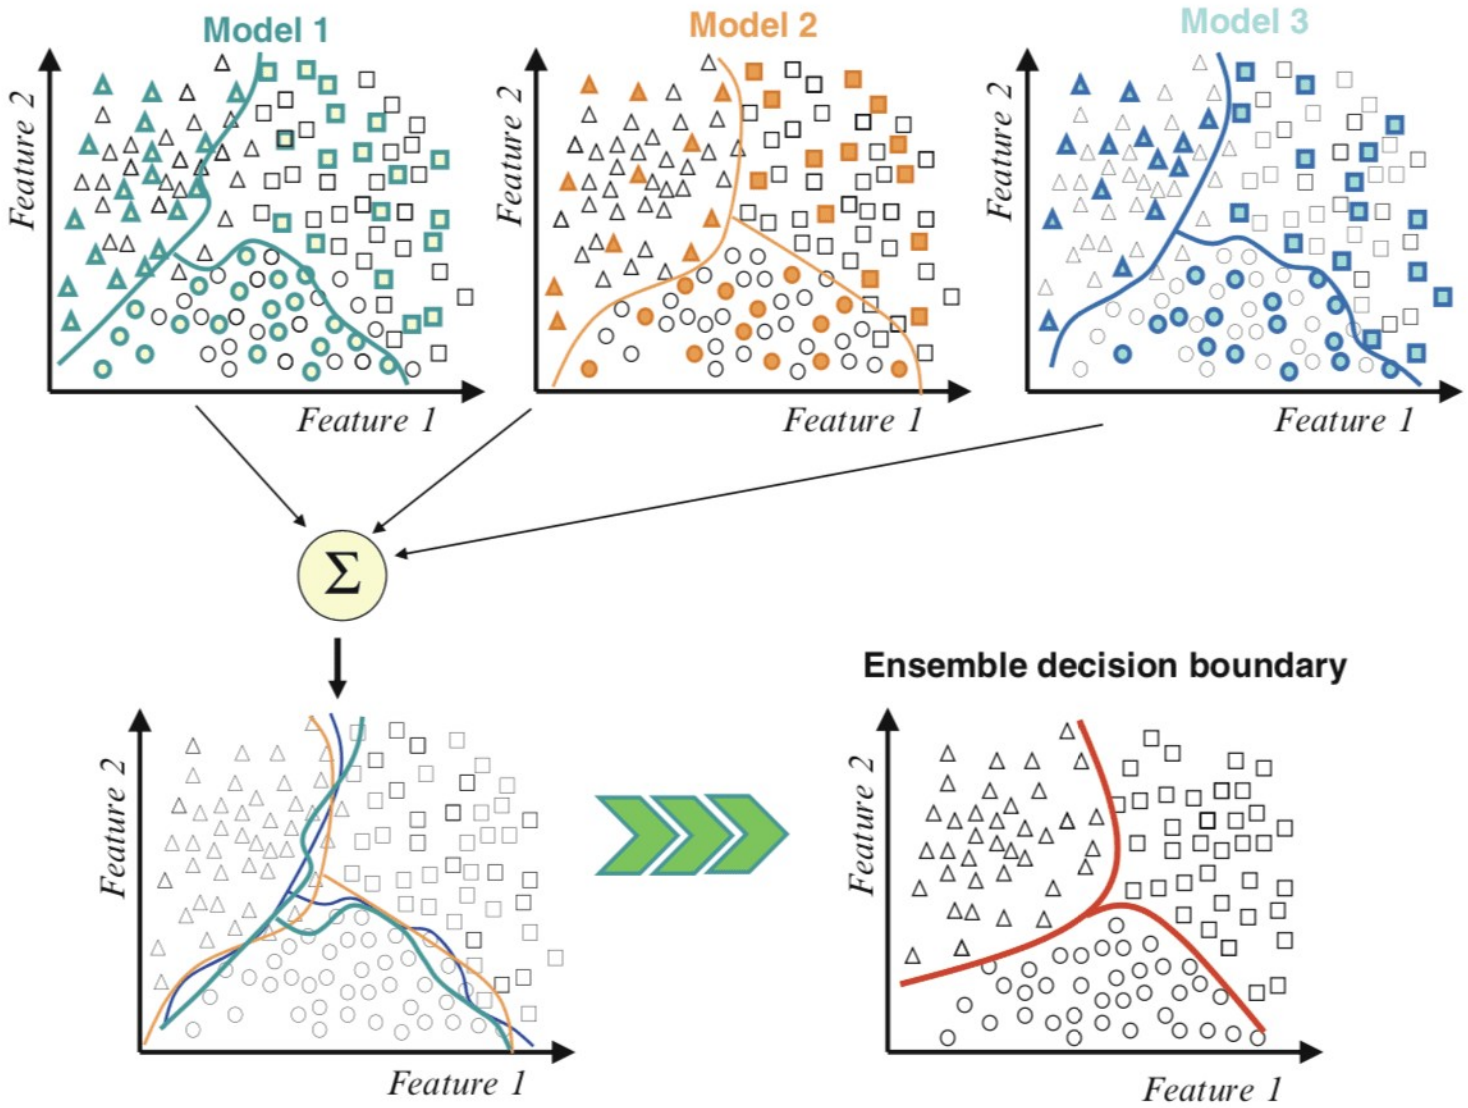
- **Нам дано:**
  - Набор данных X, y
  - Несколько классификаторов

- **Наши задачи:**
  - Как улучшить прогнозы классификаторов?
  - Можно ли объединить разные классификаторы в одну модель?

Пример

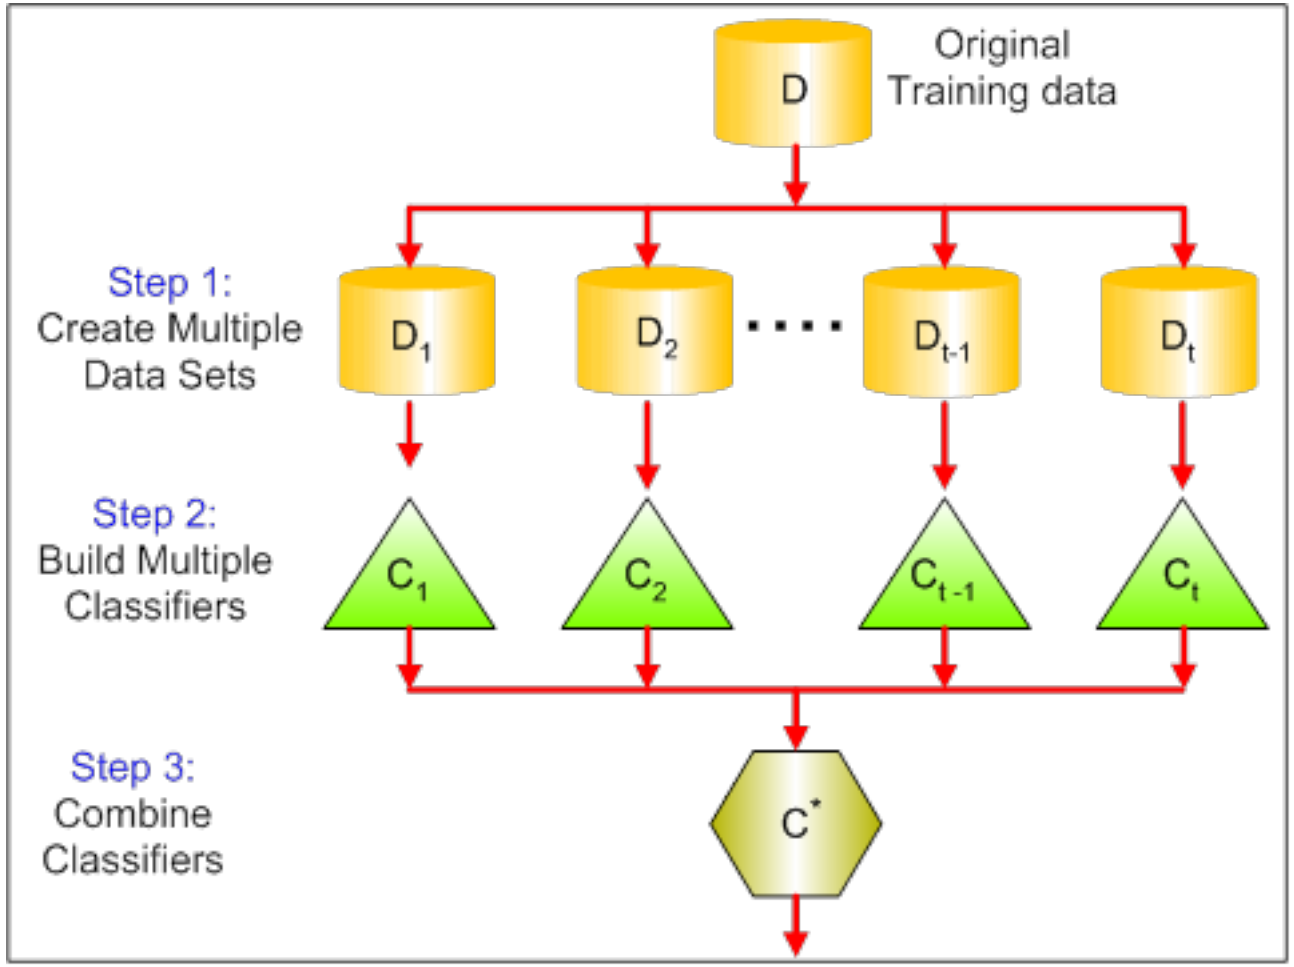

Trainer
weak classifier 1
weak classifier 2
weak classifier K
Weighted Voter
Classifier
Non-linear Classifier
Feature 2
Feature 1

Пример


Model 1
Model 2
Model 3
Feature 2
Feature 1
Σ
Ensemble decision boundary

Бэггинг (bagging)

Бэггинг (bagging)



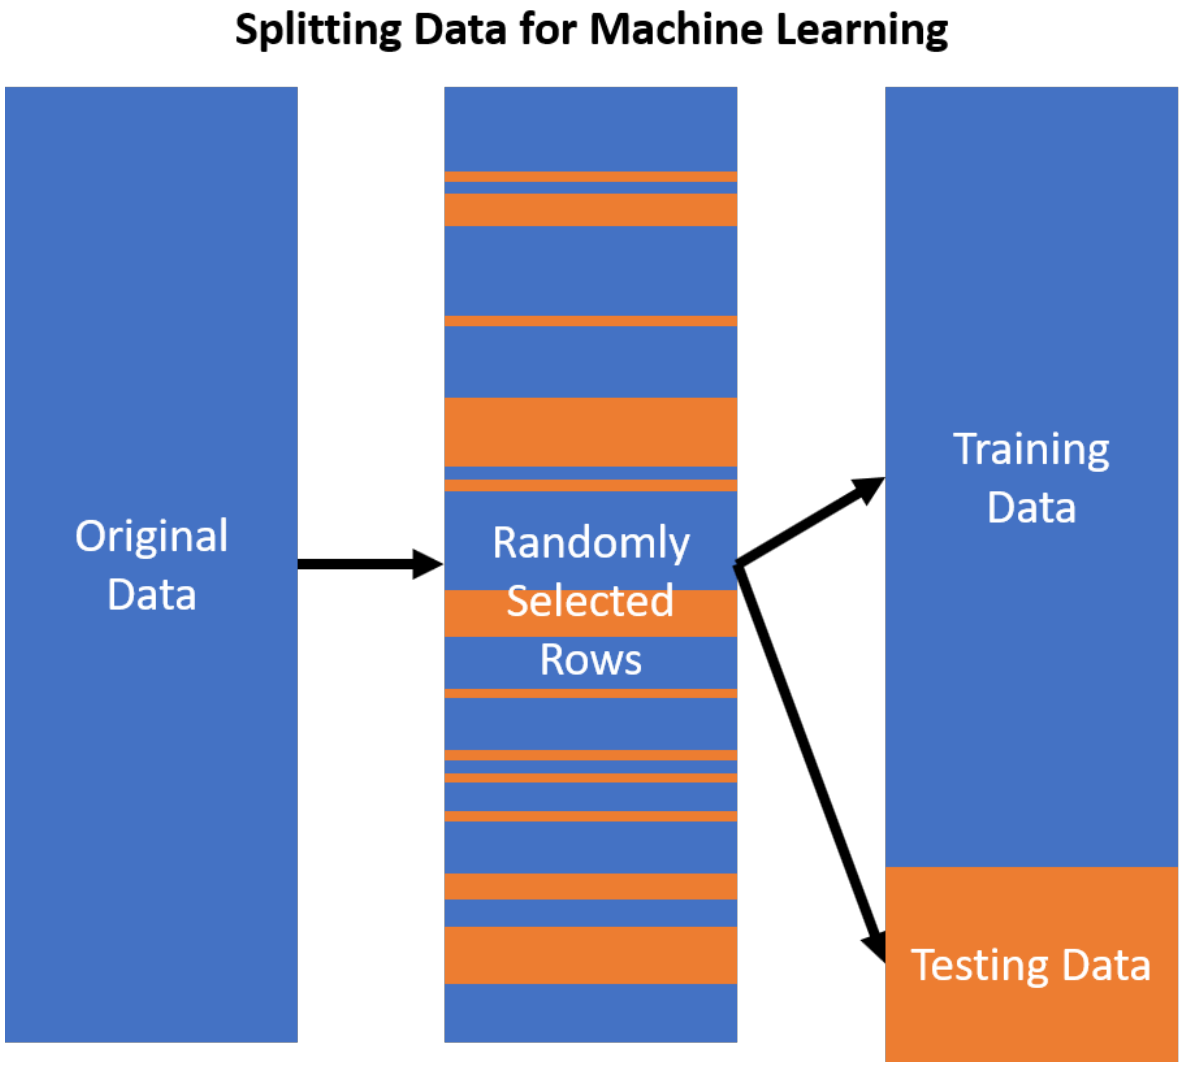
Подвыборки

- Как создать разные подвыборки имеющихся данных?

Два наиболее популярных способа:

- Случайная подвыборка без повторений (train-test split)
  - Случайным образом выбираем объекты из всей выборки
  - Размер подвыборки меньше самой выборки
- Бутстрап
  - Случайная подвыборка с повторениями
  - Размер подвыборки совпадает с размером всей выборки

Случайная подвыборка



Бутстрап (bootstrap)



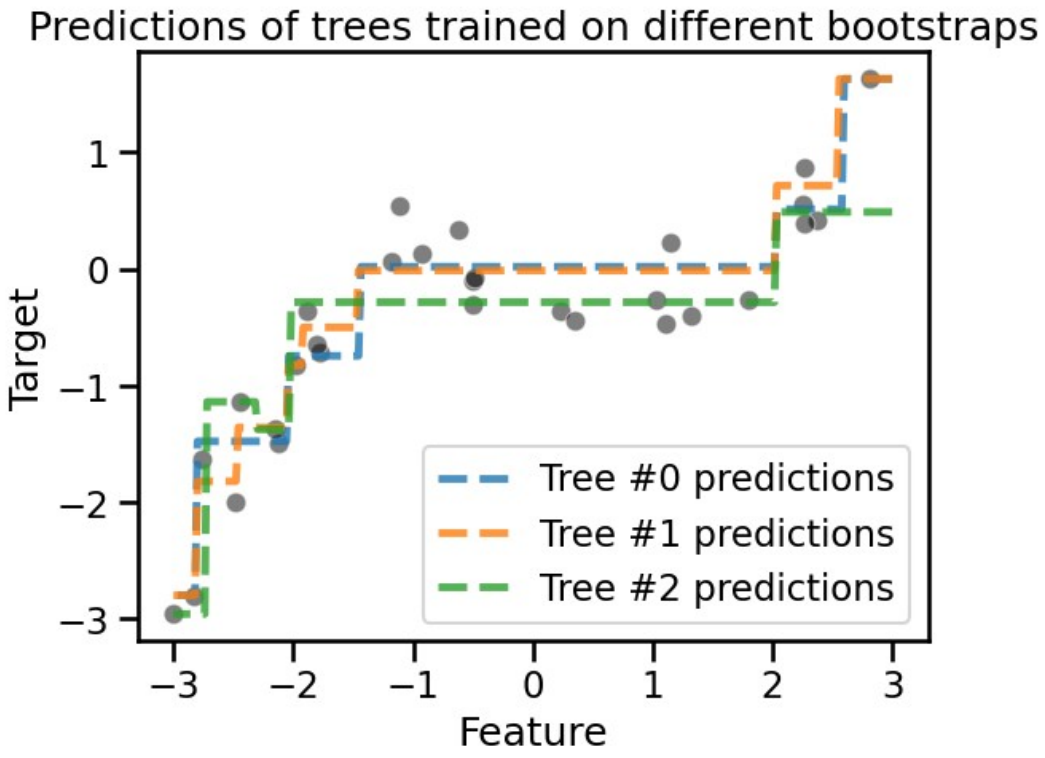
This work by Sebastian Raschka is licensed under a
Creative Commons Attribution 4.0 International License.

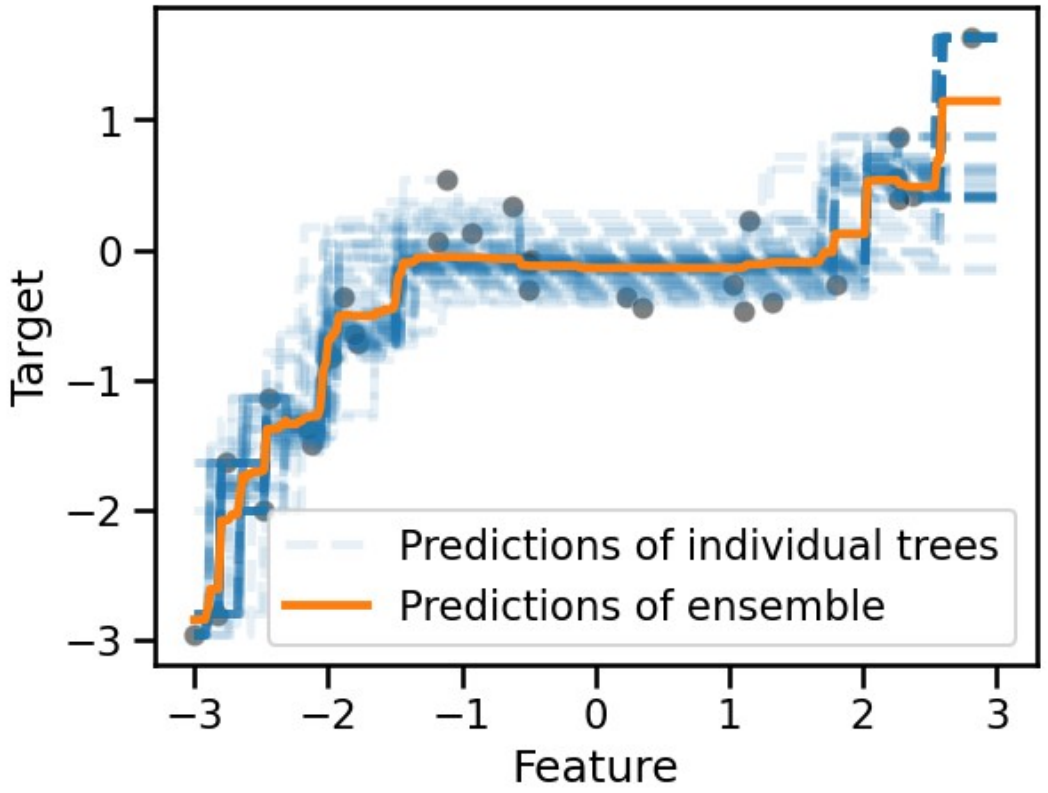
Алгоритм бэггинга

- Дана выборка данных X, y
- Для k = 1 … K:
  - Методом **бутстрапа** генерируем подвыборку $X^{(k)}, y^{(k)}$
  - Обучаем модель классификации или регрессии $b_k(x)$ на $X^{(k)}, y^{(k)}$
- Собираем композицию моделей:

$$\hat{y}(x) = \frac{1}{K}\sum_{k=1}^{K} b_k(x)$$

Пример



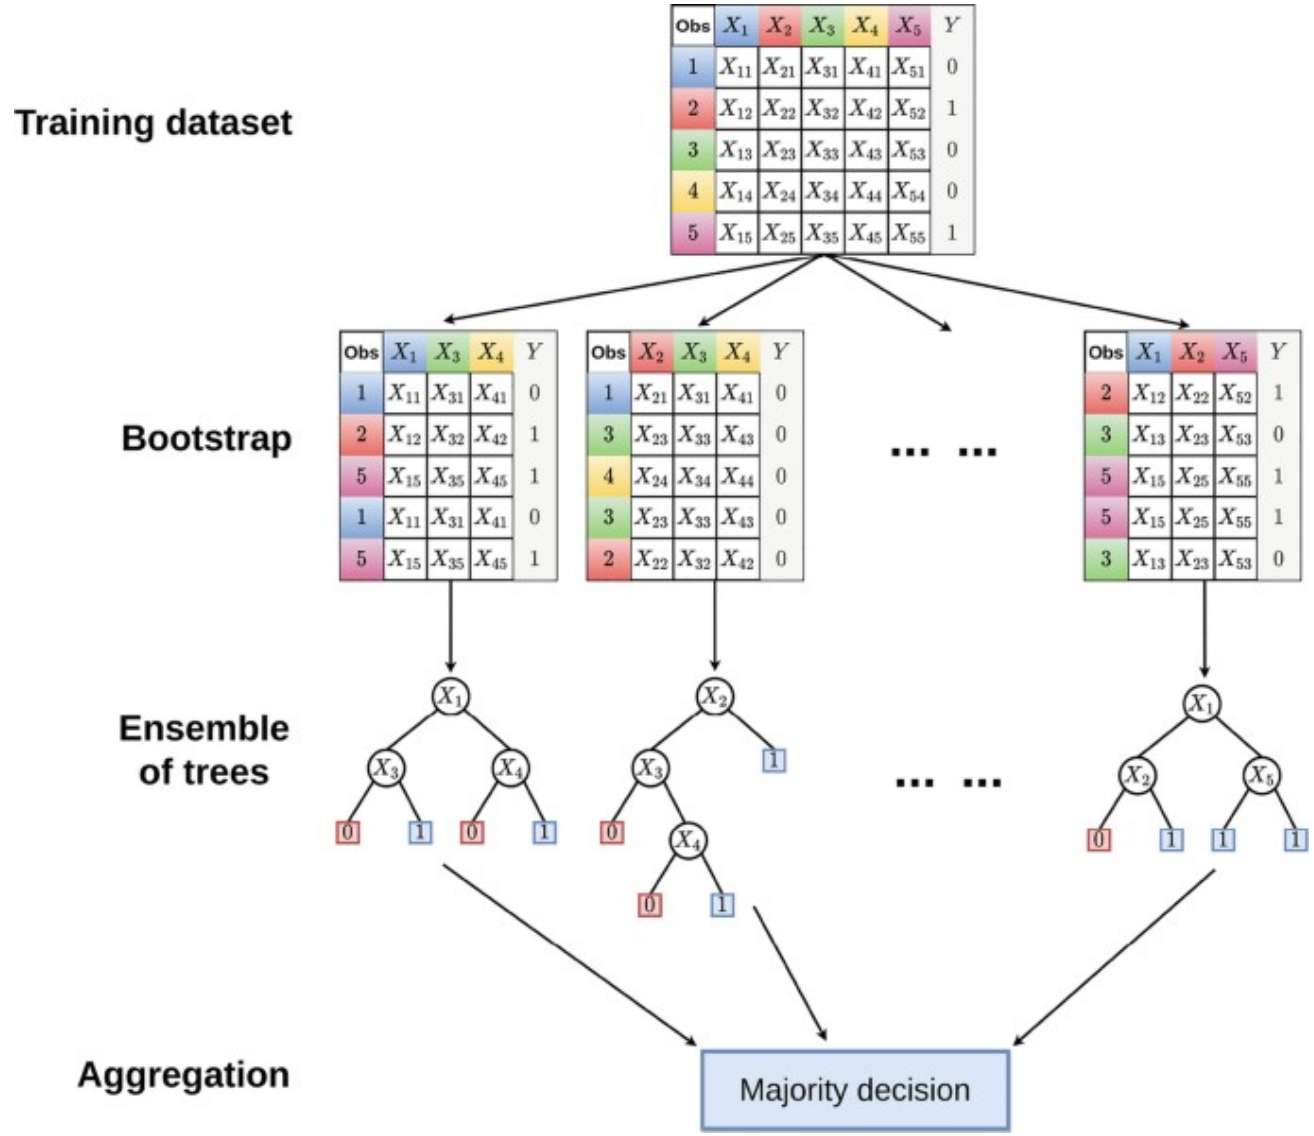


Источник: https://inria.github.io/scikit-learn-mooc/python_scripts/ensemble_bagging.html



Случайный лес решающих деревьев

Случайный лес (random forest)

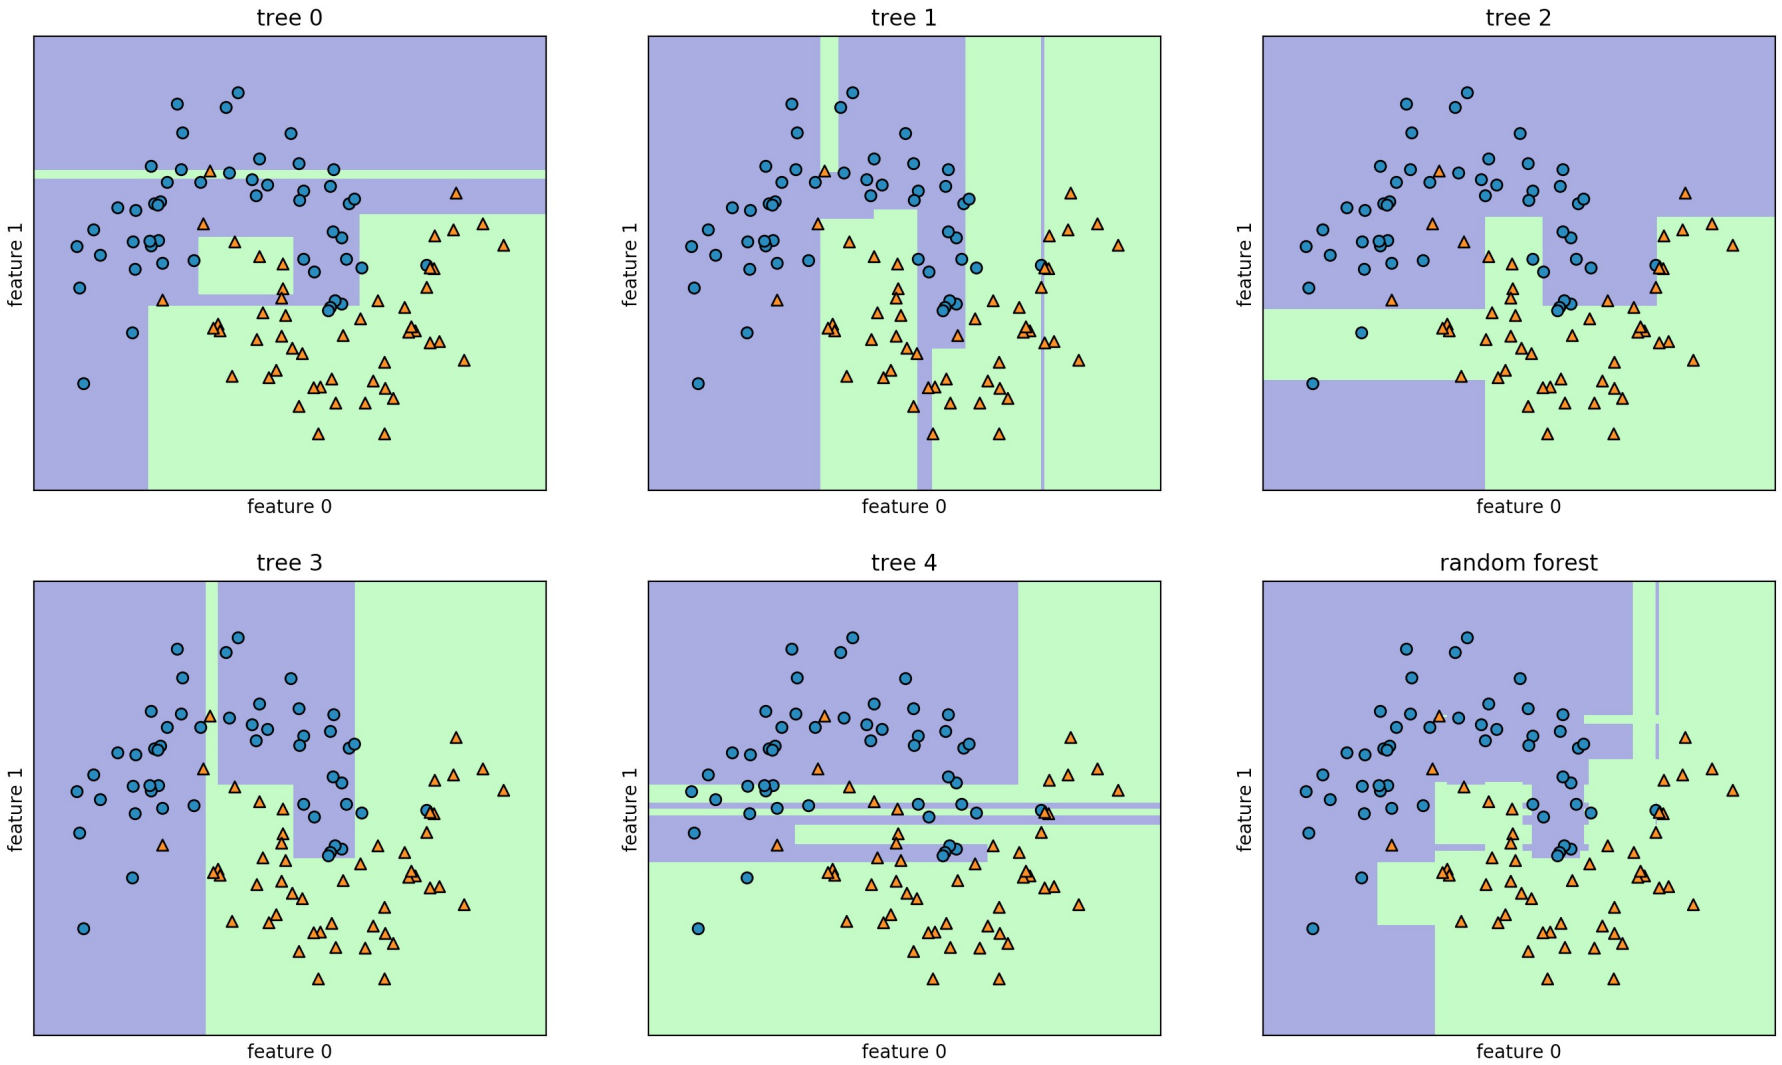


Алгоритм случайного леса

- Дана выборка данных $X \in R^{(n \times d)}, y^n$
- Для k = 1 … K:
  - Методом **бутстрапа** генерируем подвыборку $X^{(k)}, y^{(k)}$
  - Обучаем решающее дерево классификации или регрессии $b_k(x)$ на $X^{(k)}, y^{(k)}$
  - При каждом разбиении дерева выбирается m **случаных признаков из** d. Оптимальное разбиение ищется только среди них.
- Собираем композицию моделей:

$$\hat{y}(x) = \frac{1}{K} \sum_{k=1}^{K} b_k(x)$$

Пример


tree 0
tree 1
tree 2
tree 3
tree 4
random forest
feature 0
feature 1

Бутстрап (bootstrap)



This work by Sebastian Raschka is licensed under a
Creative Commons Attribution 4.0 International License.

Out-of-Bag (OOB) ошибка

- Строим деревья на бутстрап подвыборках
- Объекты, которые не попали в подвыборку, можно использовать для тестирования дерева
- Для каждого объекта x_i можно найти деревья, которые были обучены без него, и посчитать по их прогнозам Out-of-Bag ошибку:

$$OOB = \sum L(y_i, \frac{1}{\sum_{k=1}^{K}[x_i \notin X^{(k)}]} \sum_{k=1}^{K}[x_i \notin X^{(k)}]b_k(x_i))$$

  - где L(y, z) – функция потерь или метрика качества

Важные замечания

- Бэггинг можно применять для любых алгоритмов
- Лучше всего он работает на слабых моделях
- Как правило, в композиции объединяют переобученные модели

Bias-Variance decomposition

Вопросы

- Почему композиции алгоритмов работают?
- Почему прогноз композиции лучше, чем прогнозы отдельных моделей?
- Почему используют переобученные модели?

Задача

- Рассмотрим задачу регрессии с функцией потерь MSE
- Пусть ответ $y(x)$ для заданного x – некоторая случайная величина:

$$y(x) = f(x) + \epsilon$$

  - где $\epsilon \sim N(0, \sigma^2)$
- Обозначим прогноз нашей модели $a(x)$
- Посчитаем мат. ожидание ошибки прогноза для заданного x:

$$Error = E[(a(x) - y(x))^2]$$

Расчет ошибки

$$Error = E\left[\left(a(x) - y(x)\right)^2\right] =$$

$$= E[(a(x) - f(x) - \epsilon + E[a(x)] - E[a(x)])^2] =$$

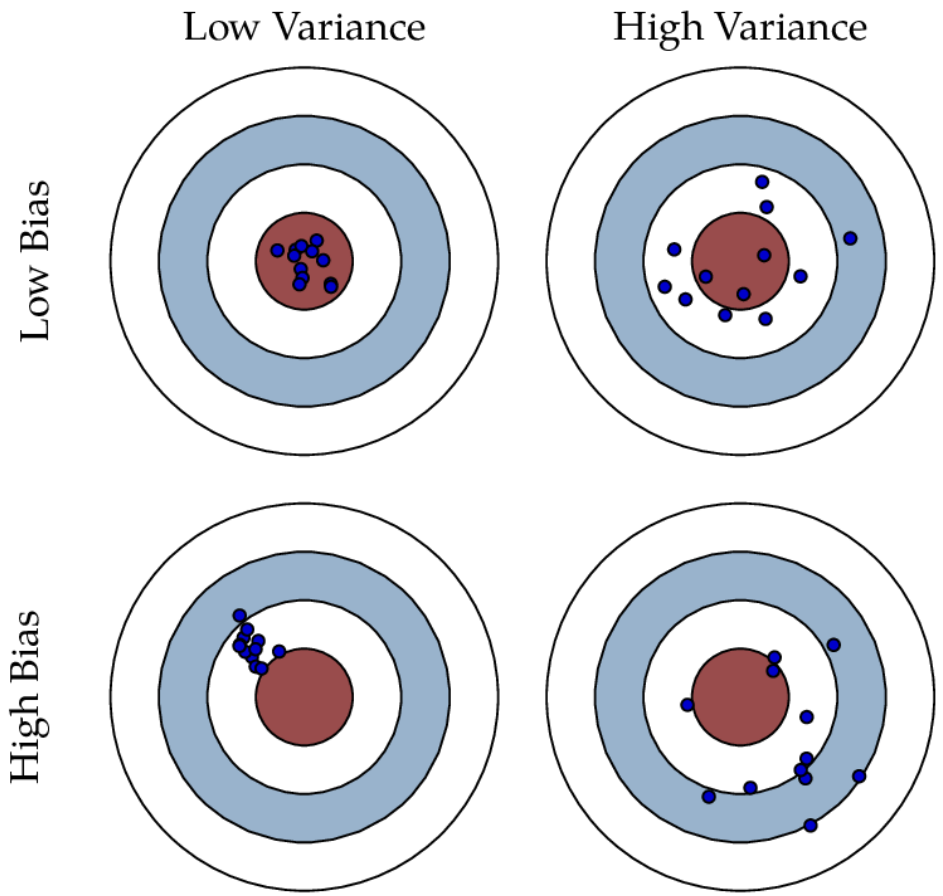
$$= \boldsymbol{E\left[(a(x) - E[a(x)])^2\right]} + \boldsymbol{(E[a(x)] - f(x))^2} + \boldsymbol{\sigma^2} =$$

$$= \boldsymbol{Variance} + \boldsymbol{Bias^2} + \boldsymbol{Noise}$$

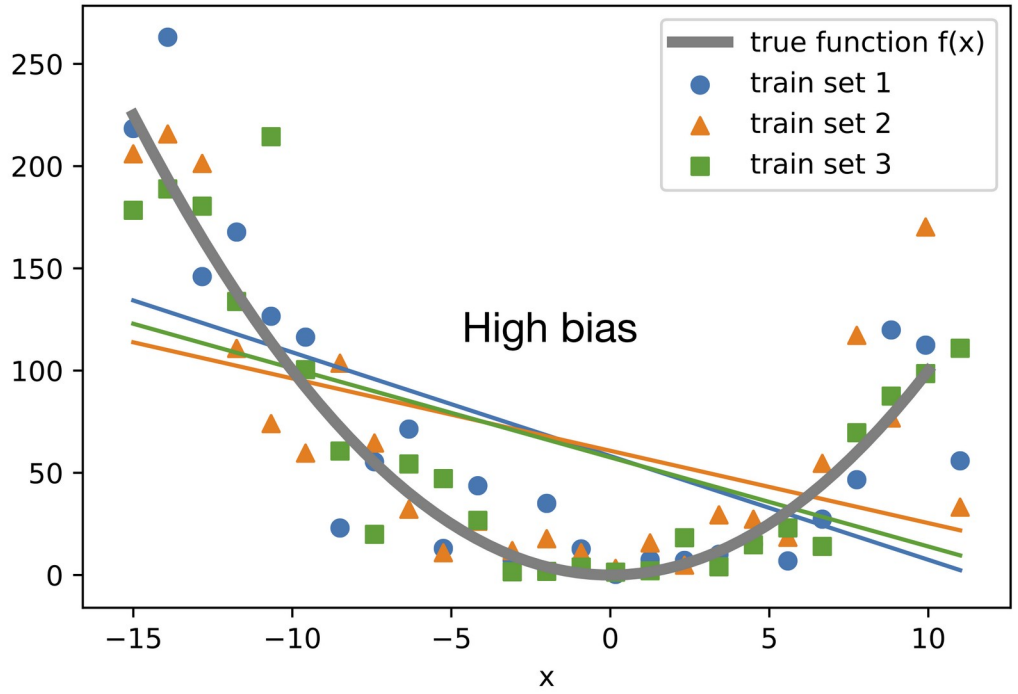
Bias-Variance decomposition

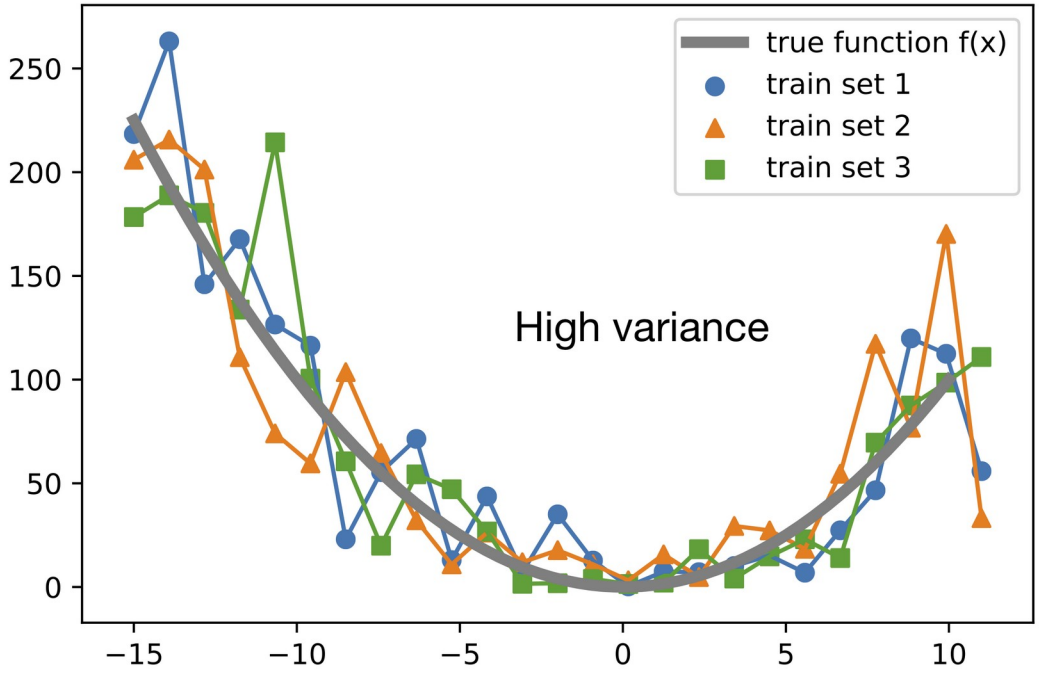
- **Variance (разброс)** – разброс ответов обученных алгоритмов относительно среднего ответа.
- **Bias (смещение)** – отклонение среднего ответа алгоритма от идеального ответа
- **Noise (шум)** – шум в данных

Пример

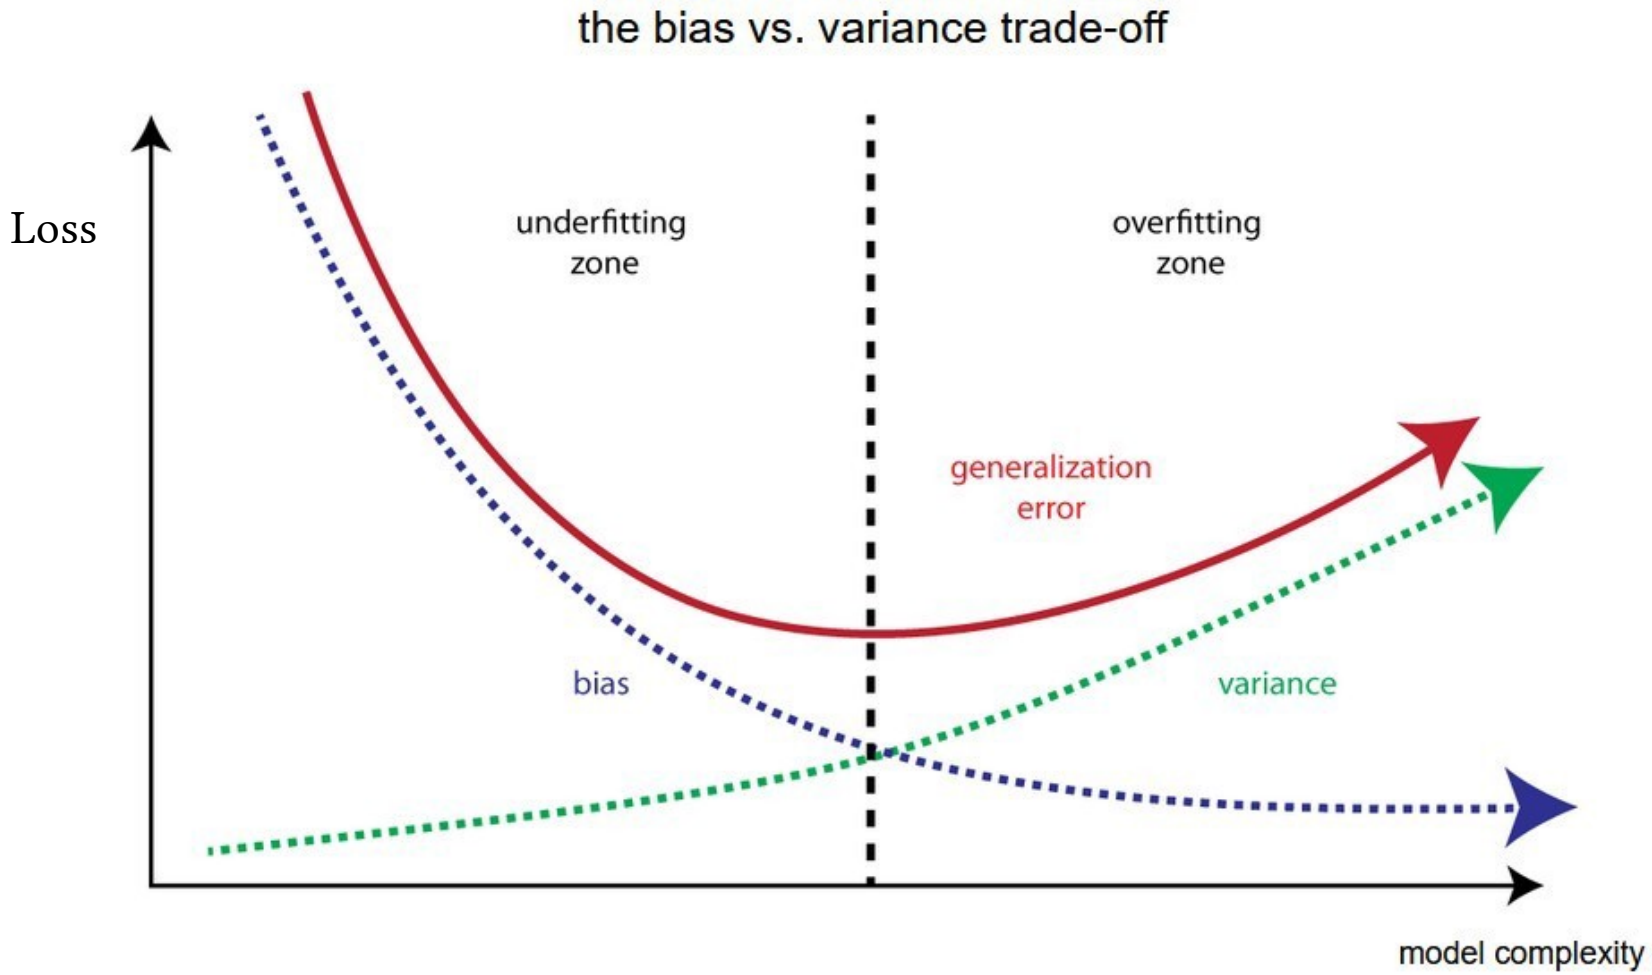


Пример

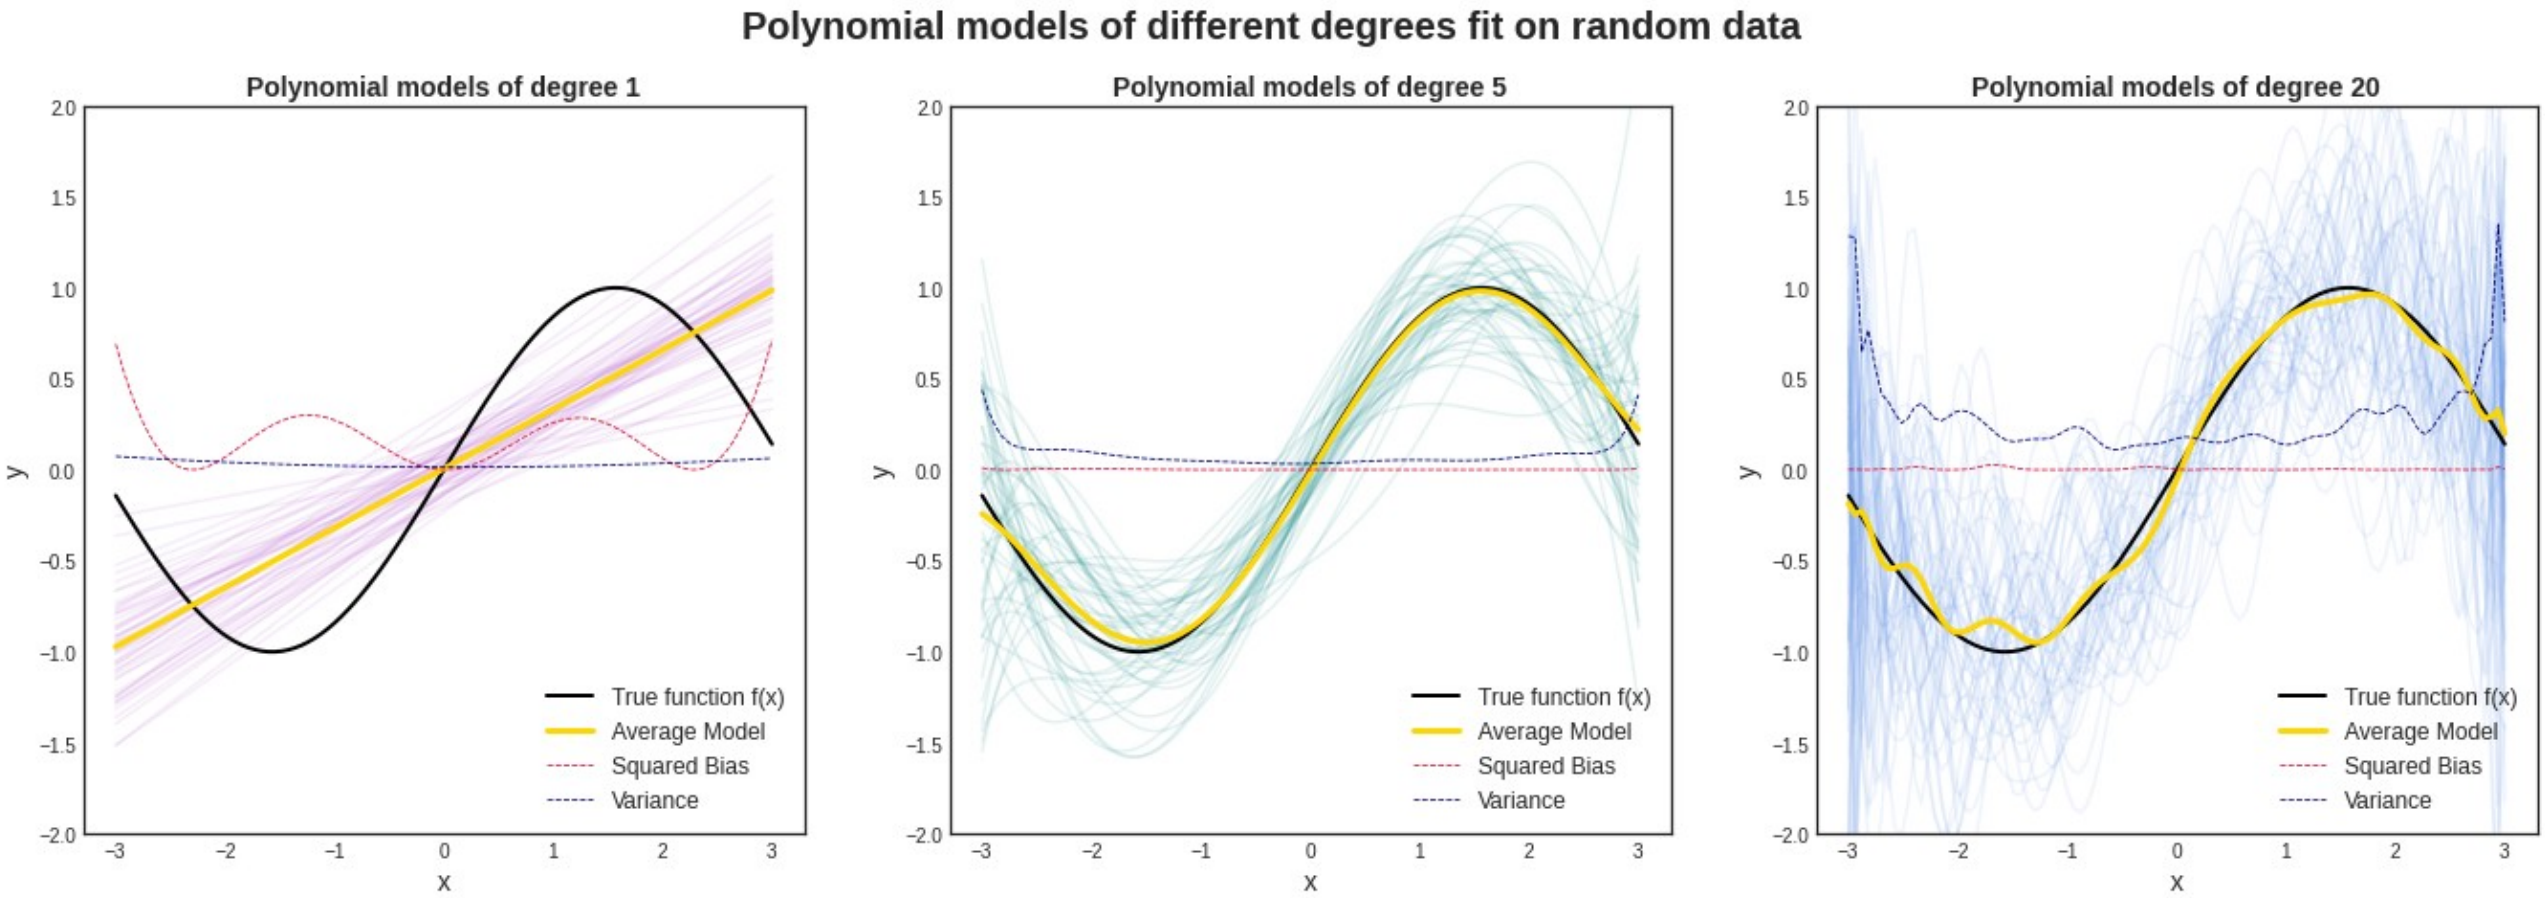

true function f(x)
train set 1
train set 2
train set 3
High bias
250
200
150
100
50
0
−15
−10
−5
0
5
10
x


true function f(x)
train set 1
train set 2
train set 3
High variance
250
200
150
100
50
0
−15
−10
−5
0
5
10

Переобучение



Пример

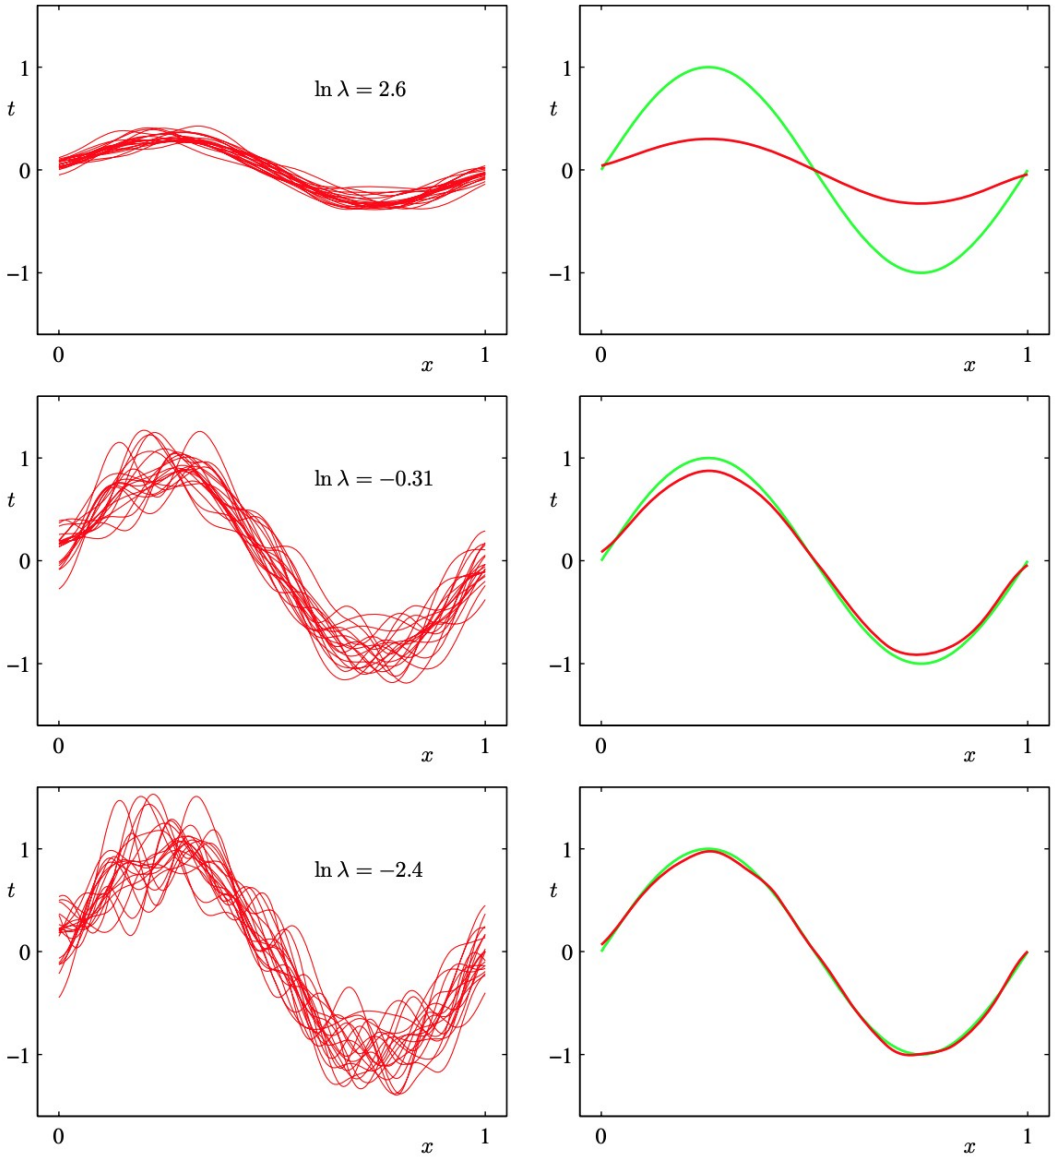


Источник: https://allenkunle.me/bias-variance-decomposition

Эффект регуляризации

- Большой коэффициент регуляризации приводит к росту **bias** и снижению **variance**

- Маленький коэффициент регуляризации приводит к снижению **bias** и росту **variance**



Композиции алгоритмов

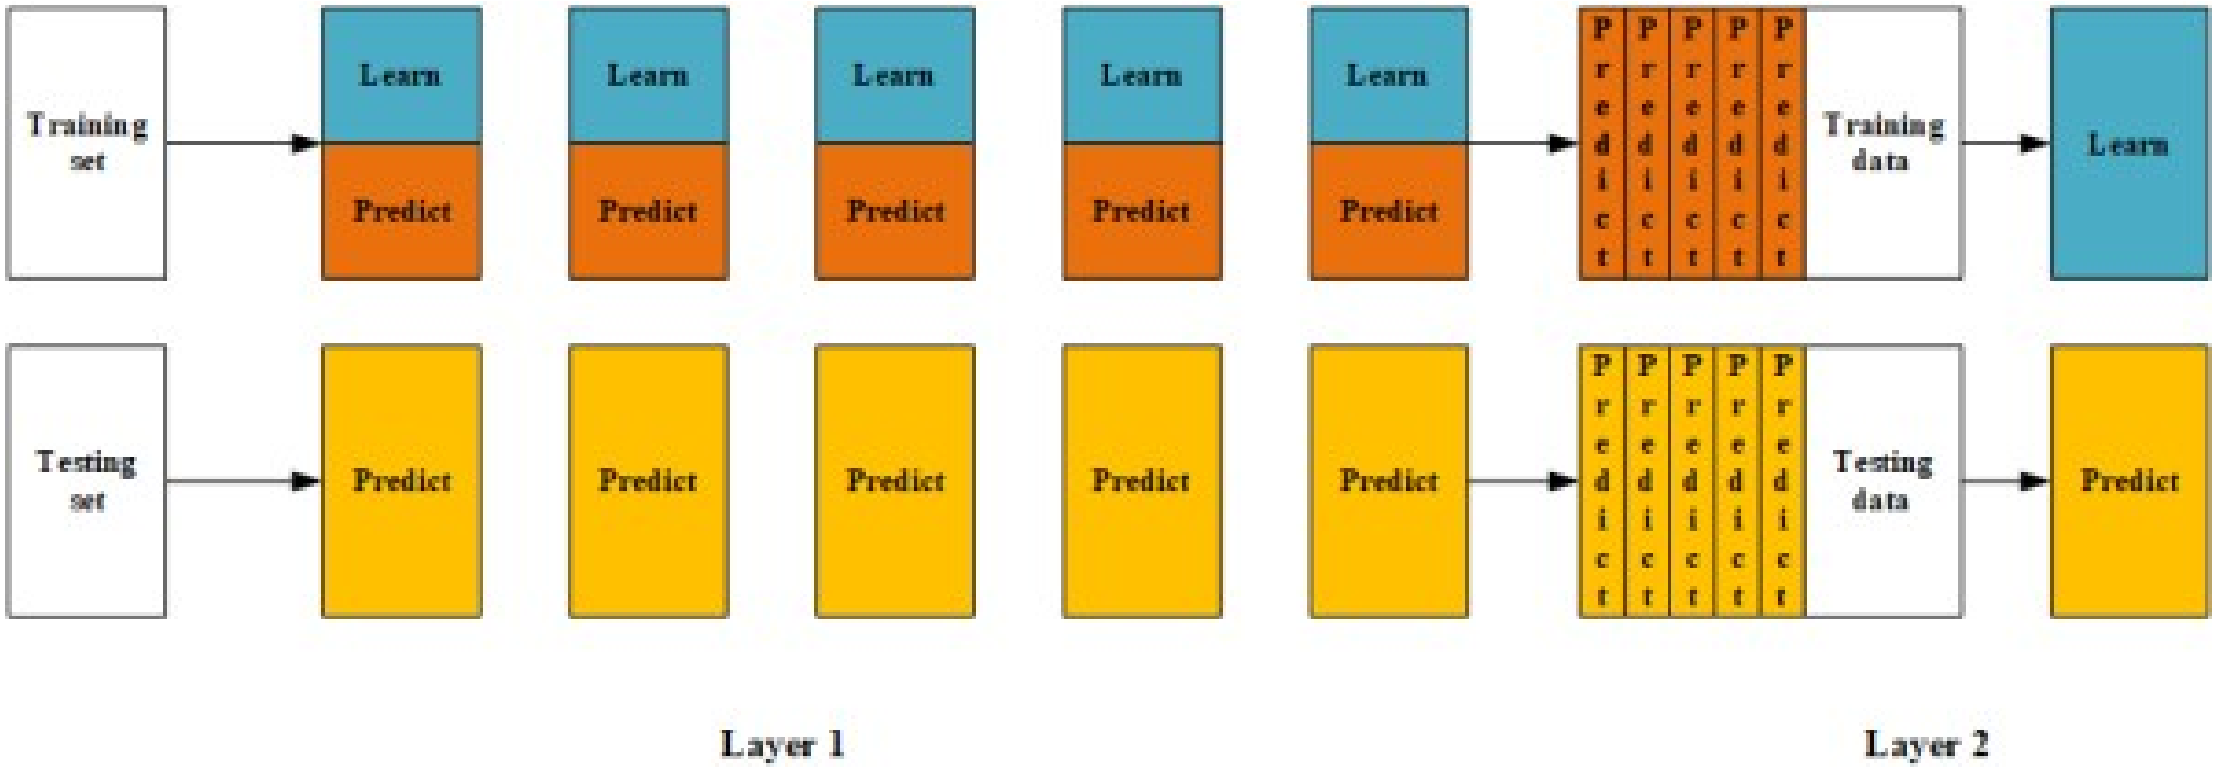
- $$Error = \boldsymbol{E}\left[(\boldsymbol{a}(\boldsymbol{x}) - \boldsymbol{E}[\boldsymbol{a}(\boldsymbol{x})])^2\right] + (\boldsymbol{E}[\boldsymbol{a}(\boldsymbol{x})] - \boldsymbol{f}(\boldsymbol{x}))^2 + \boldsymbol{\sigma}^2$$

- Пусть $a(x)$ - композиция алгоритмов
- Тогда $a(x) \approx E[a(x)]$
- Тогда ошибка для композиции:

$$Error \approx \boldsymbol{0} + (\boldsymbol{E}[\boldsymbol{a}(\boldsymbol{x})] - \boldsymbol{f}(\boldsymbol{x}))^2 + \boldsymbol{\sigma}^2$$

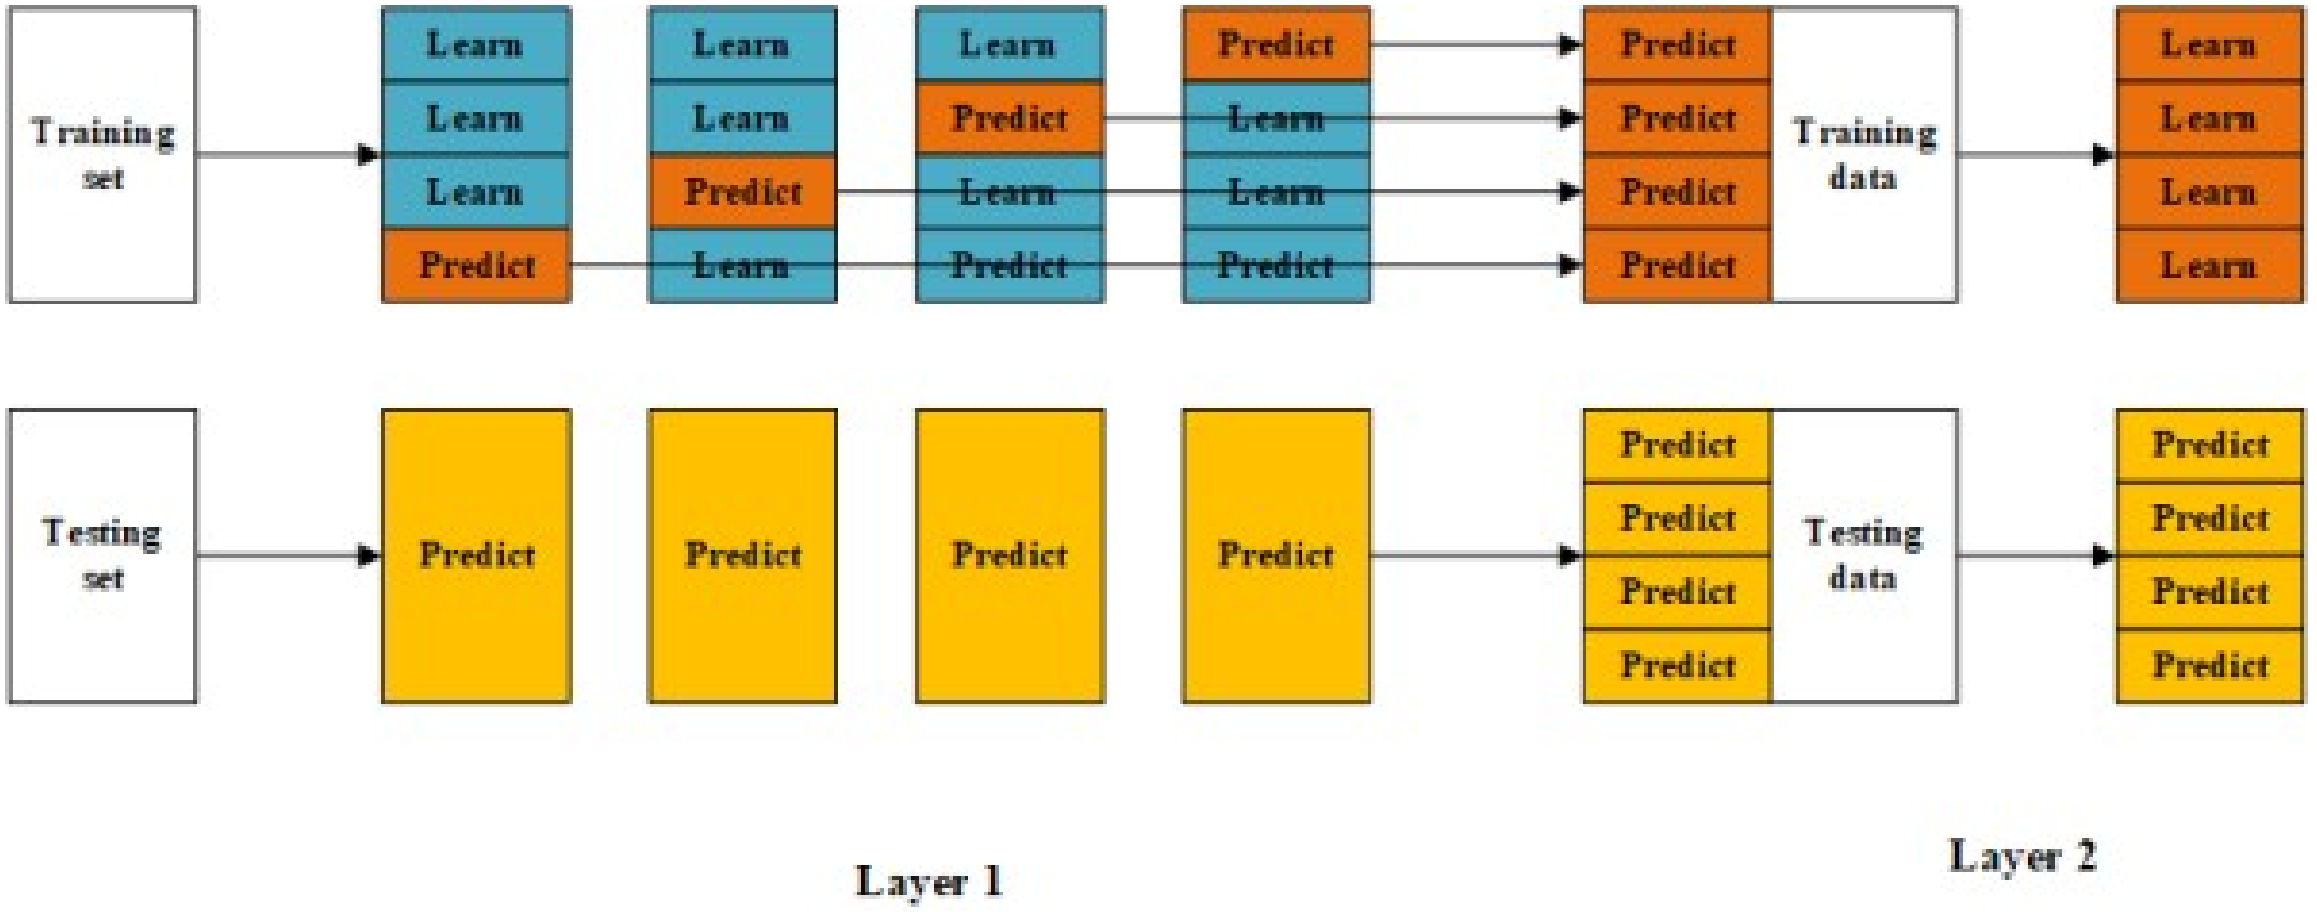
Blending и Stacking (не обязательно)

Blending



Источник: https://www.codeproject.com/Tips/4354591/Step-by-Step-Guide-to-Implement-Machine-Learning-5

Stacking



Источник: https://www.codeproject.com/Tips/4354591/Step-by-Step-Guide-to-Implement-Machine-Learning-5

Заключение

Вопросы

- Что такое композиция алгоритмов машинного обучения? Покажите, что в предположении некоррелированных ошибок базовых алгоритмов, ошибка композиции будет в N раз меньше, чем средняя ошибка базовых алгоритмов, где N - число базовых алгоритмов.
- Что такое бэггинг? Что такое случайный лес? Что такое out-of-bag ошибка, для чего она используется?