# Машинное обучение

Лекция 8

Градиентный бустинг

Михаил Гущин

mhushchyn@hse.ru

НИУ ВШЭ, 2026

# Эволюция решающих деревьев



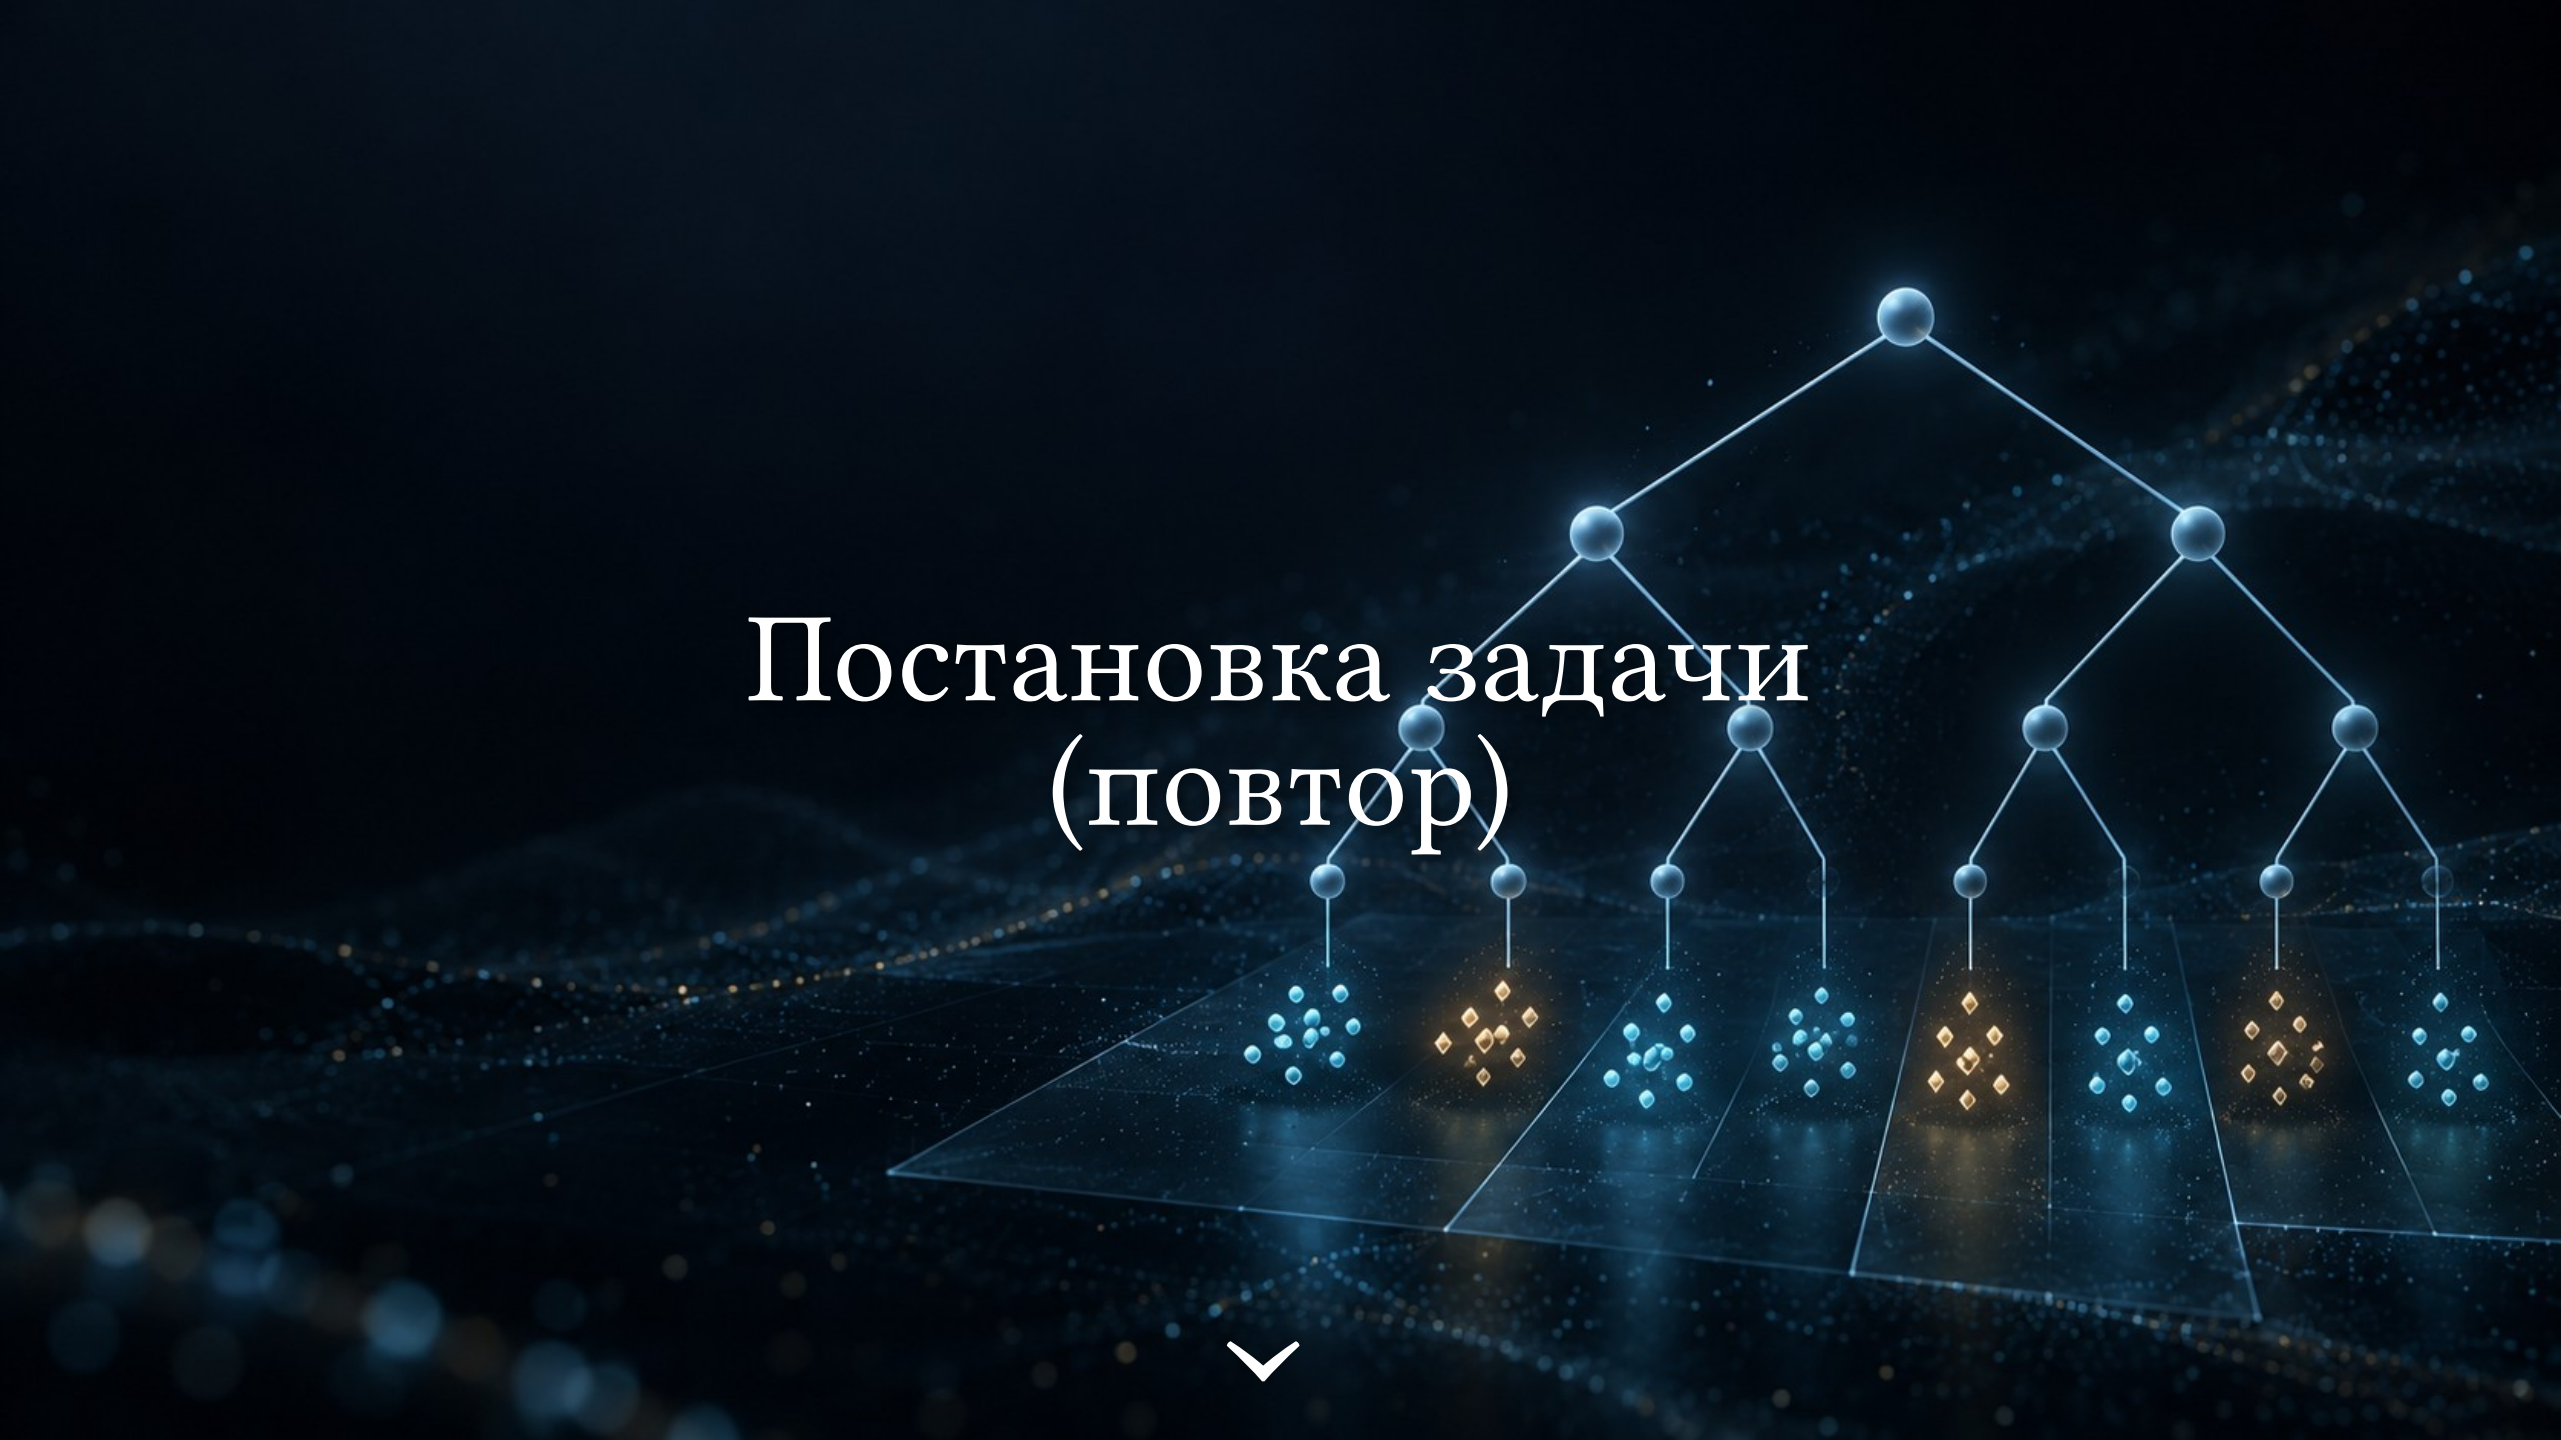
Решающие деревья



Случайный лес решающих деревьев

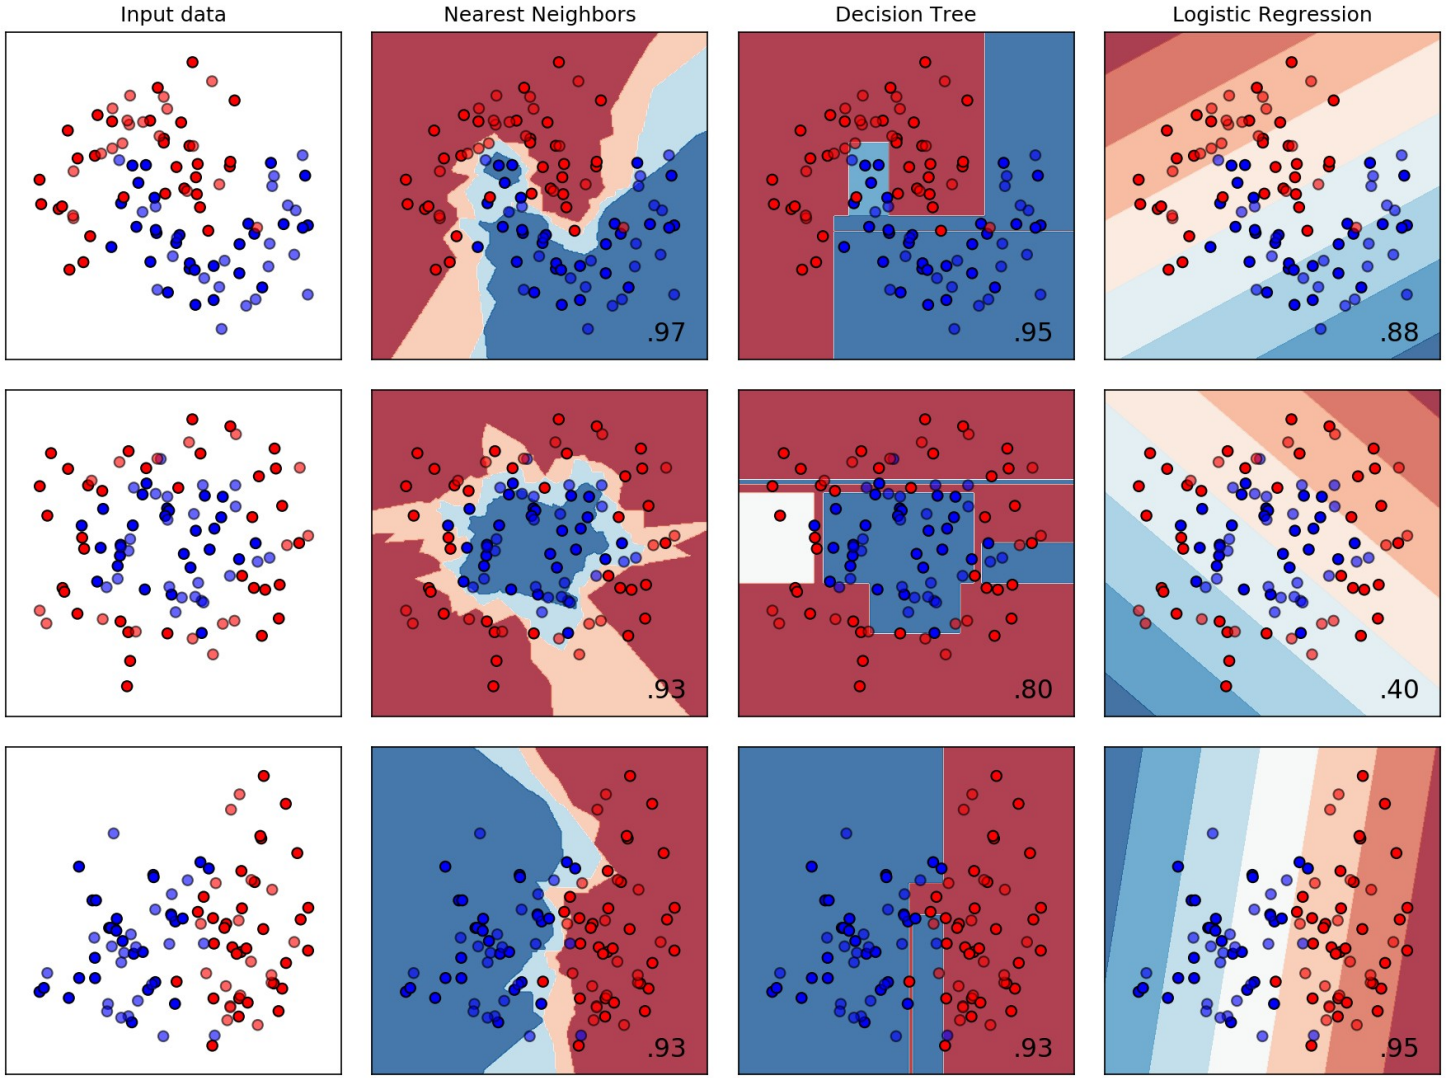


Градиентный бустинг



# Постановка задачи (повтор)

# Классификаторы

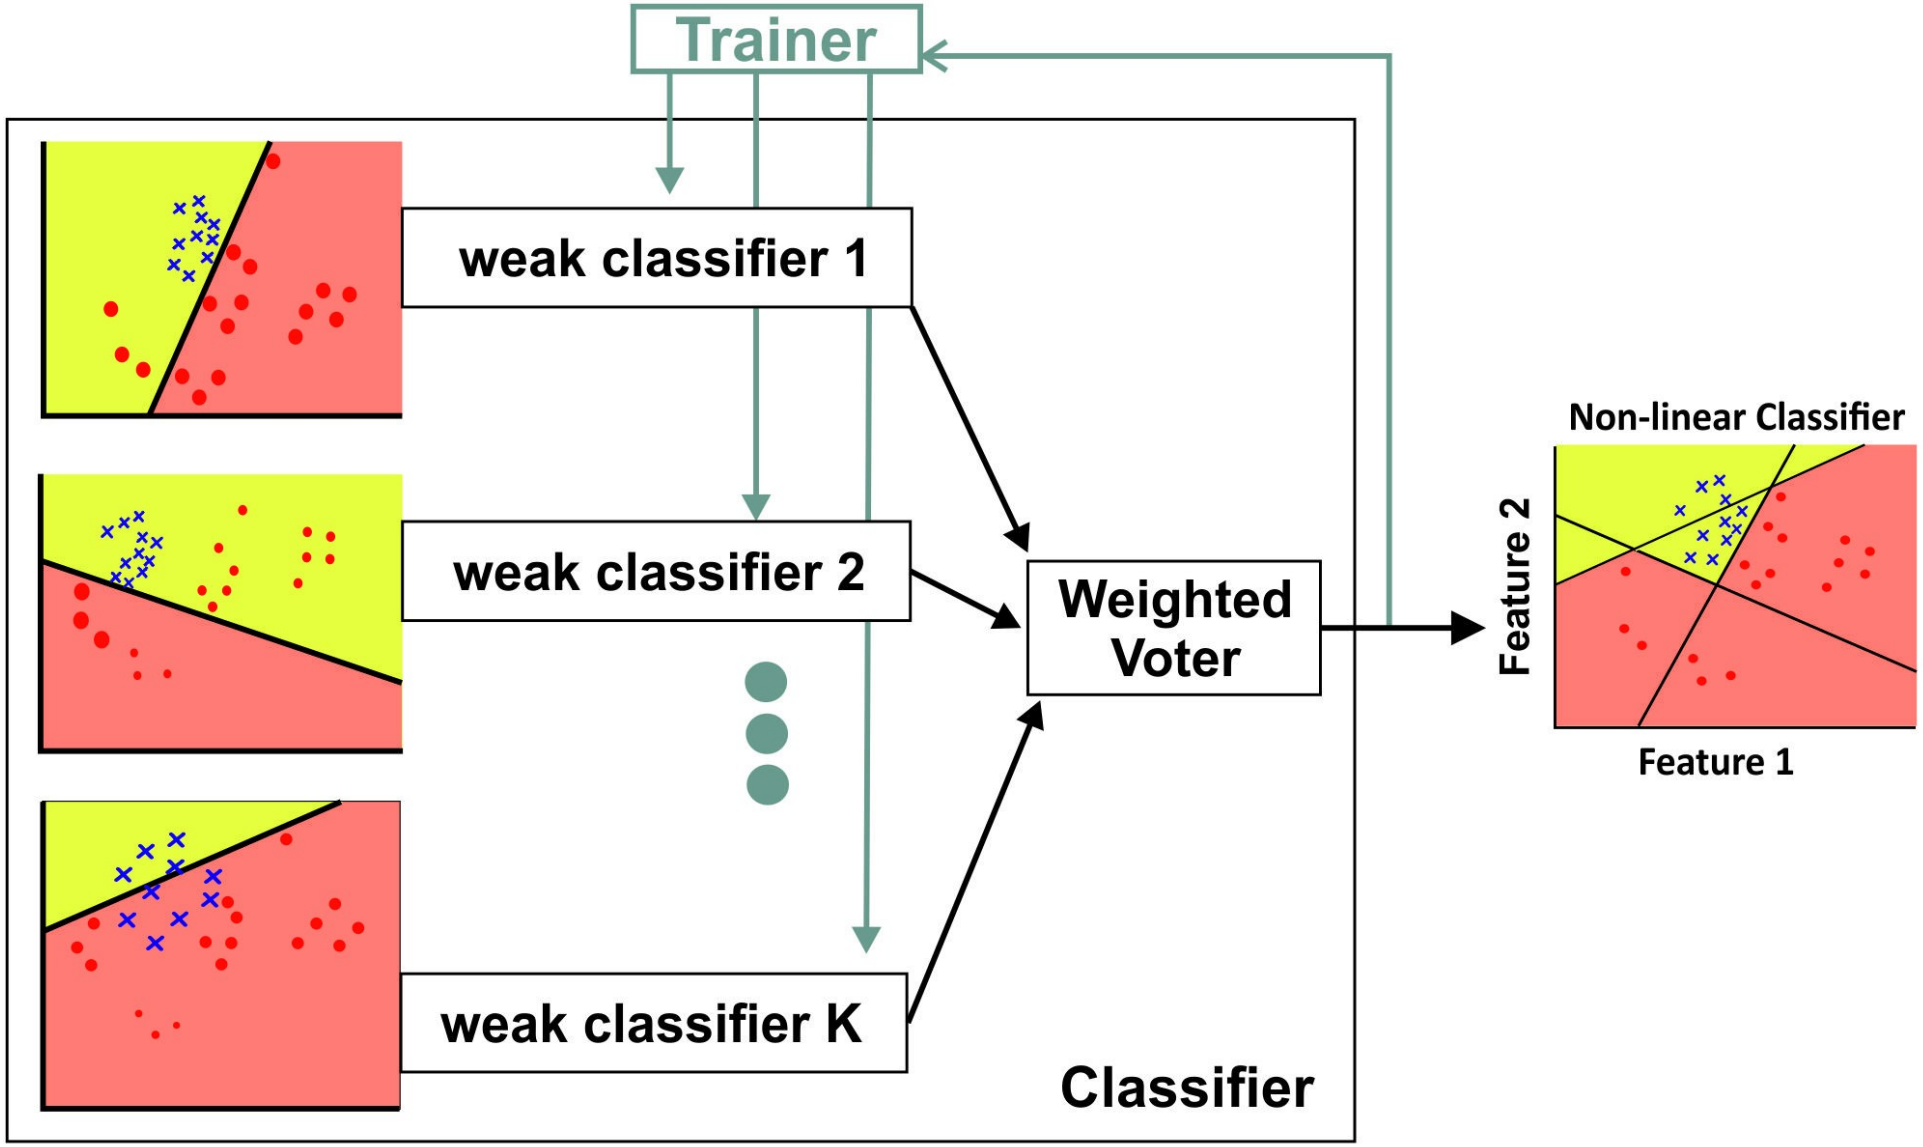


# Задача

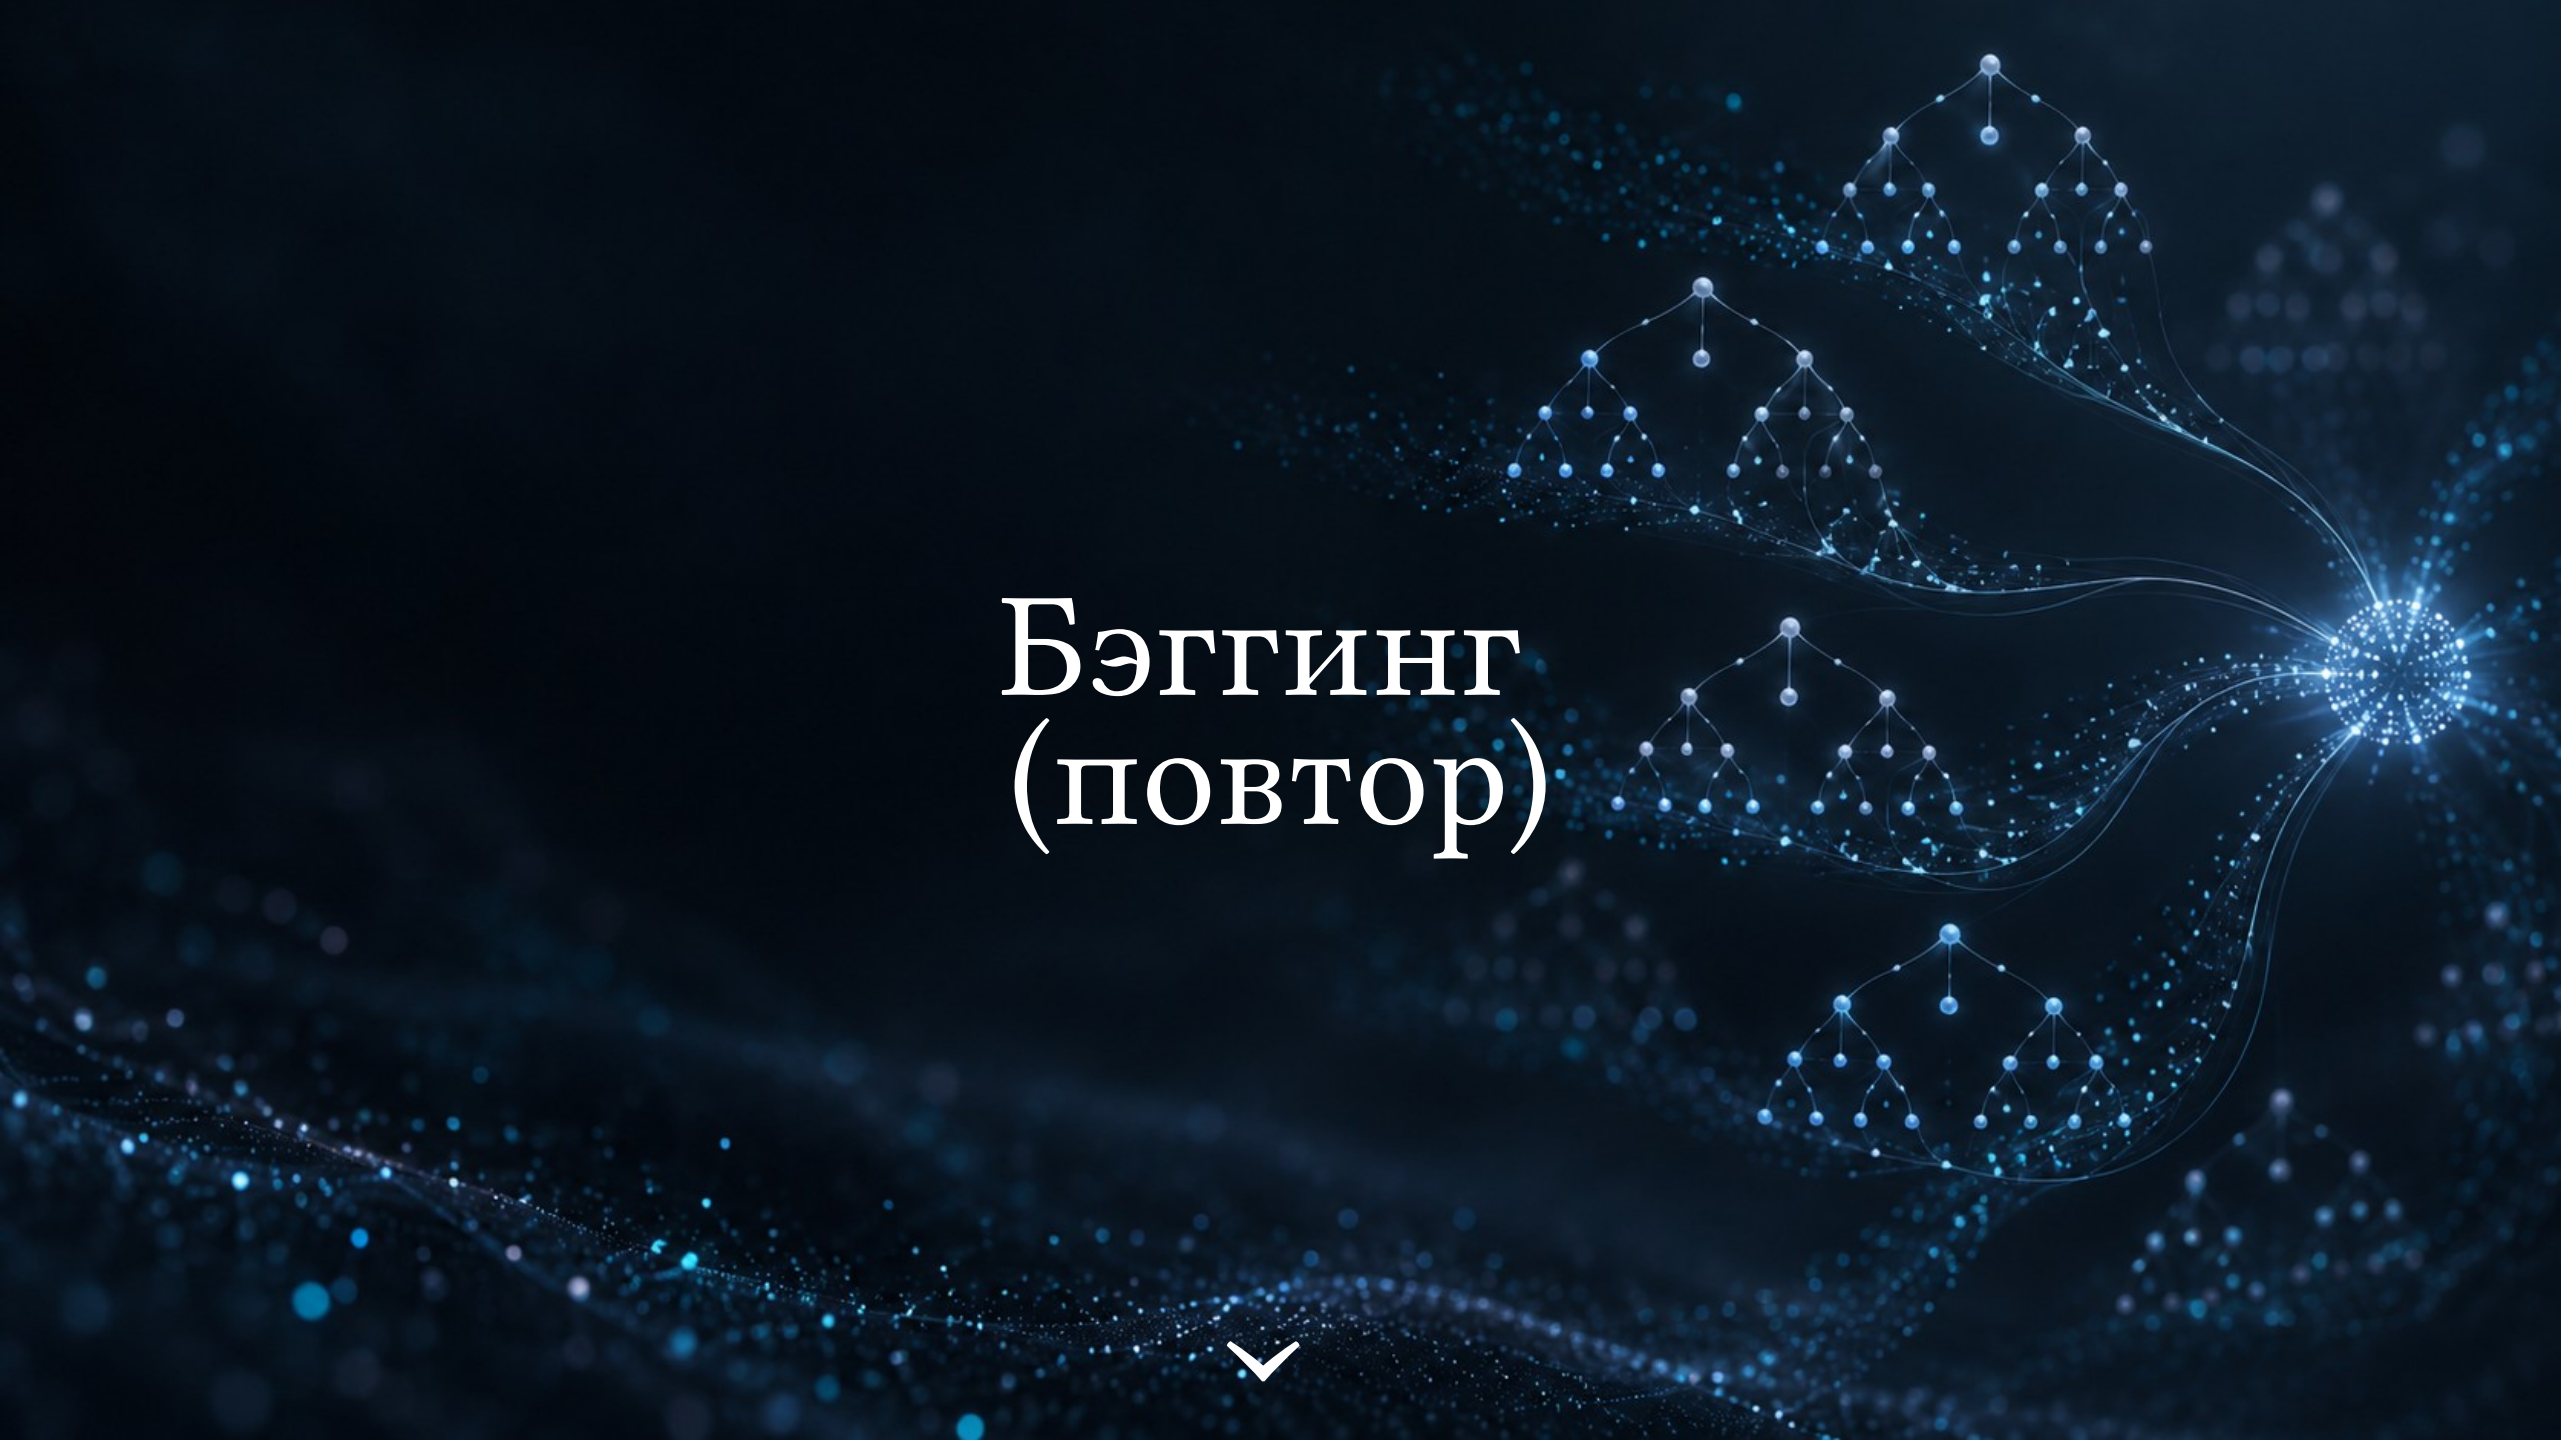
- **Нам дано:**
  - Набор данных $X, y$
  - Несколько классификаторов

- **Наши задачи:**
  - Как улучшить прогнозы классификаторов?
  - Можно ли объединить разные классификаторы в одну модель?

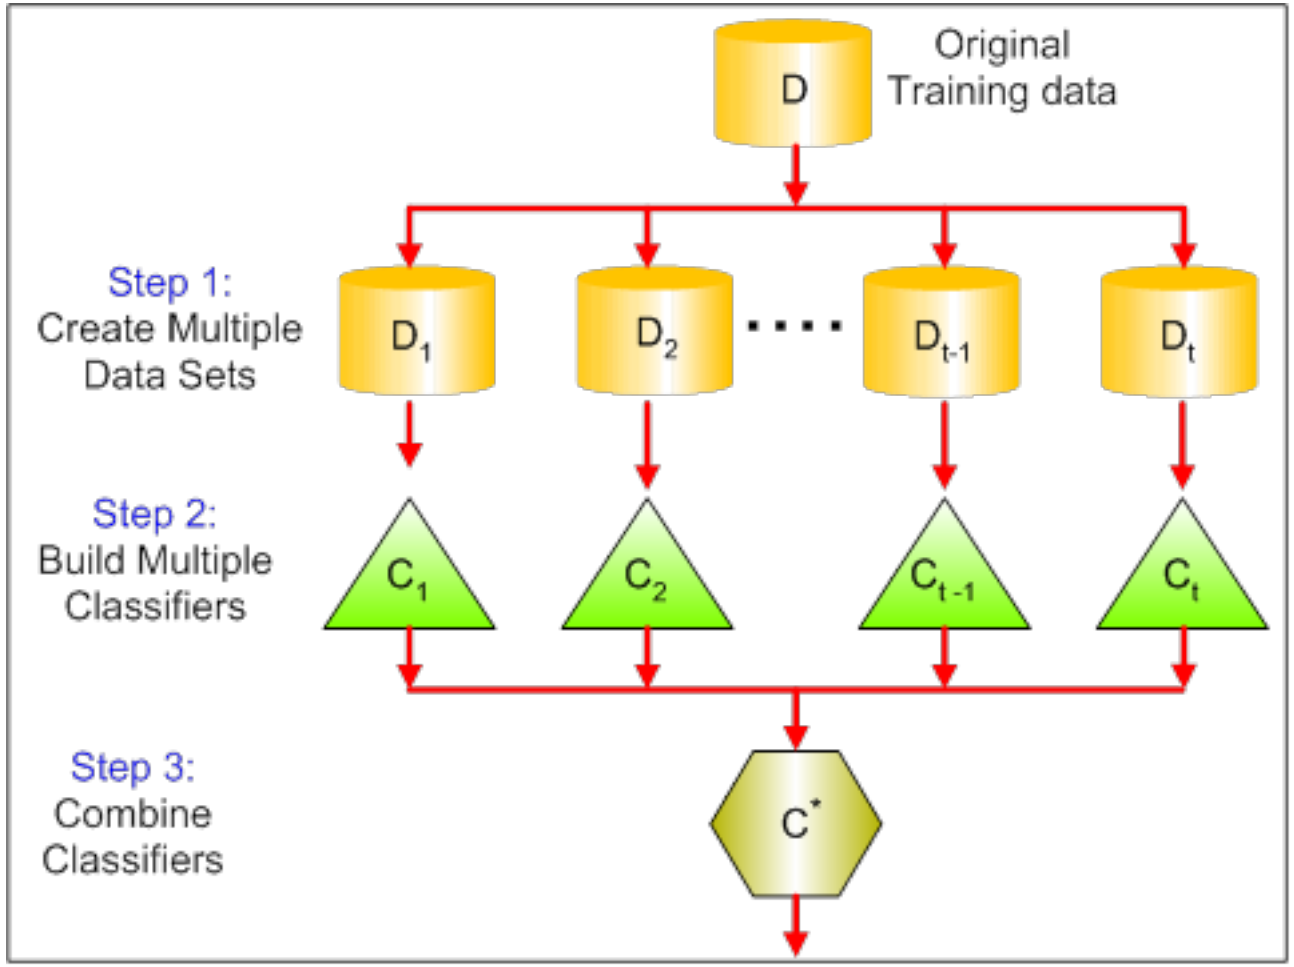
# Пример


Trainer
weak classifier 1
weak classifier 2
weak classifier K
Weighted Voter
Classifier
Non-linear Classifier
Feature 2
Feature 1

# Бэггинг (повтор)



# Бэггинг (bagging)

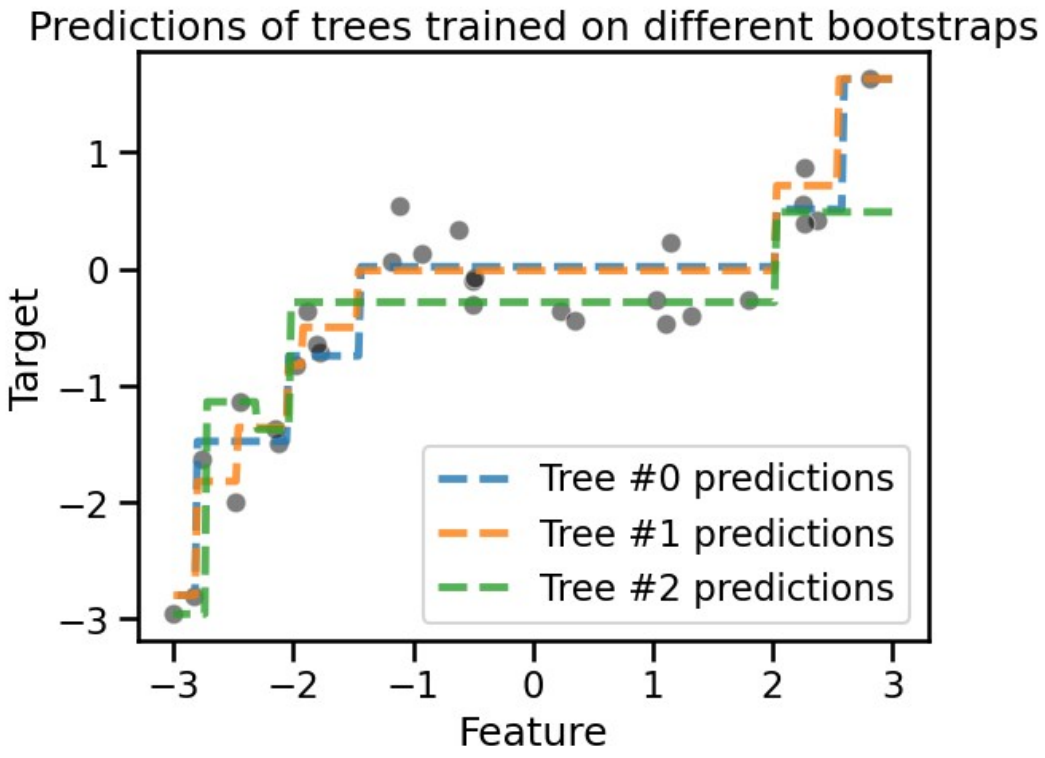


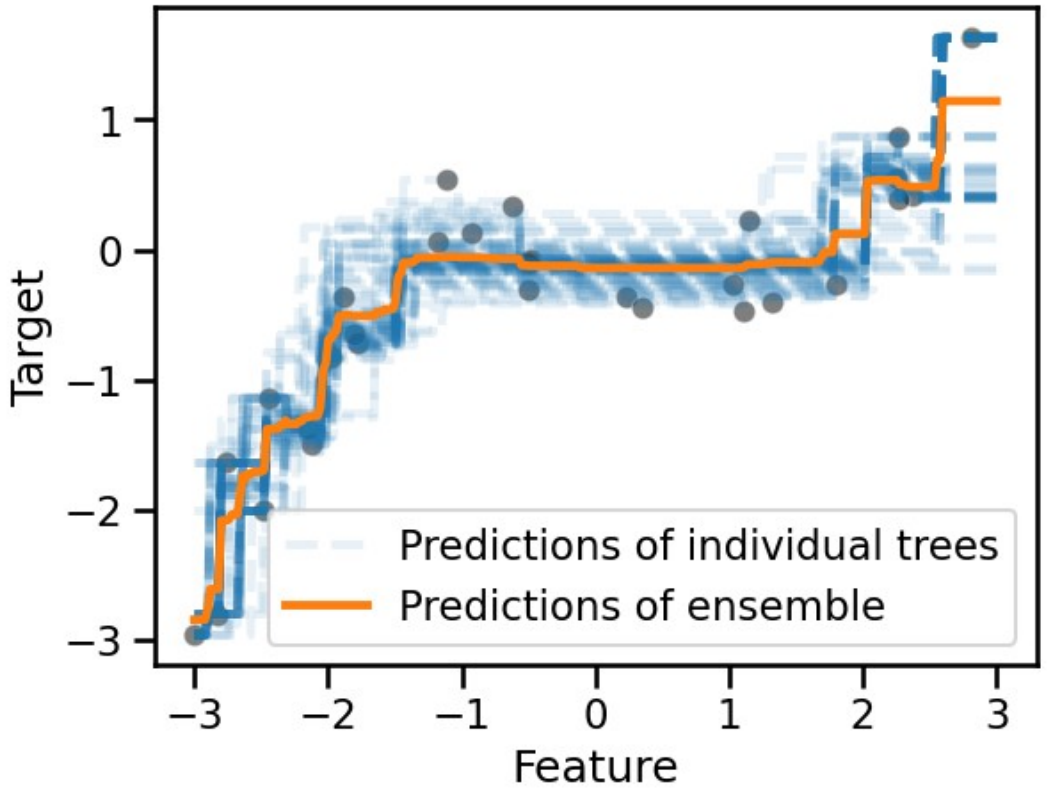
# Алгоритм бэггинга

- Дана выборка данных $X, y$
- Для k = 1 … K:
  - Методом **бутстрапа** генерируем подвыборку $X^{(k)}, y^{(k)}$
  - Обучаем модель классификации или регрессии $b_k(x)$ на $X^{(k)}, y^{(k)}$
- Собираем композицию моделей:

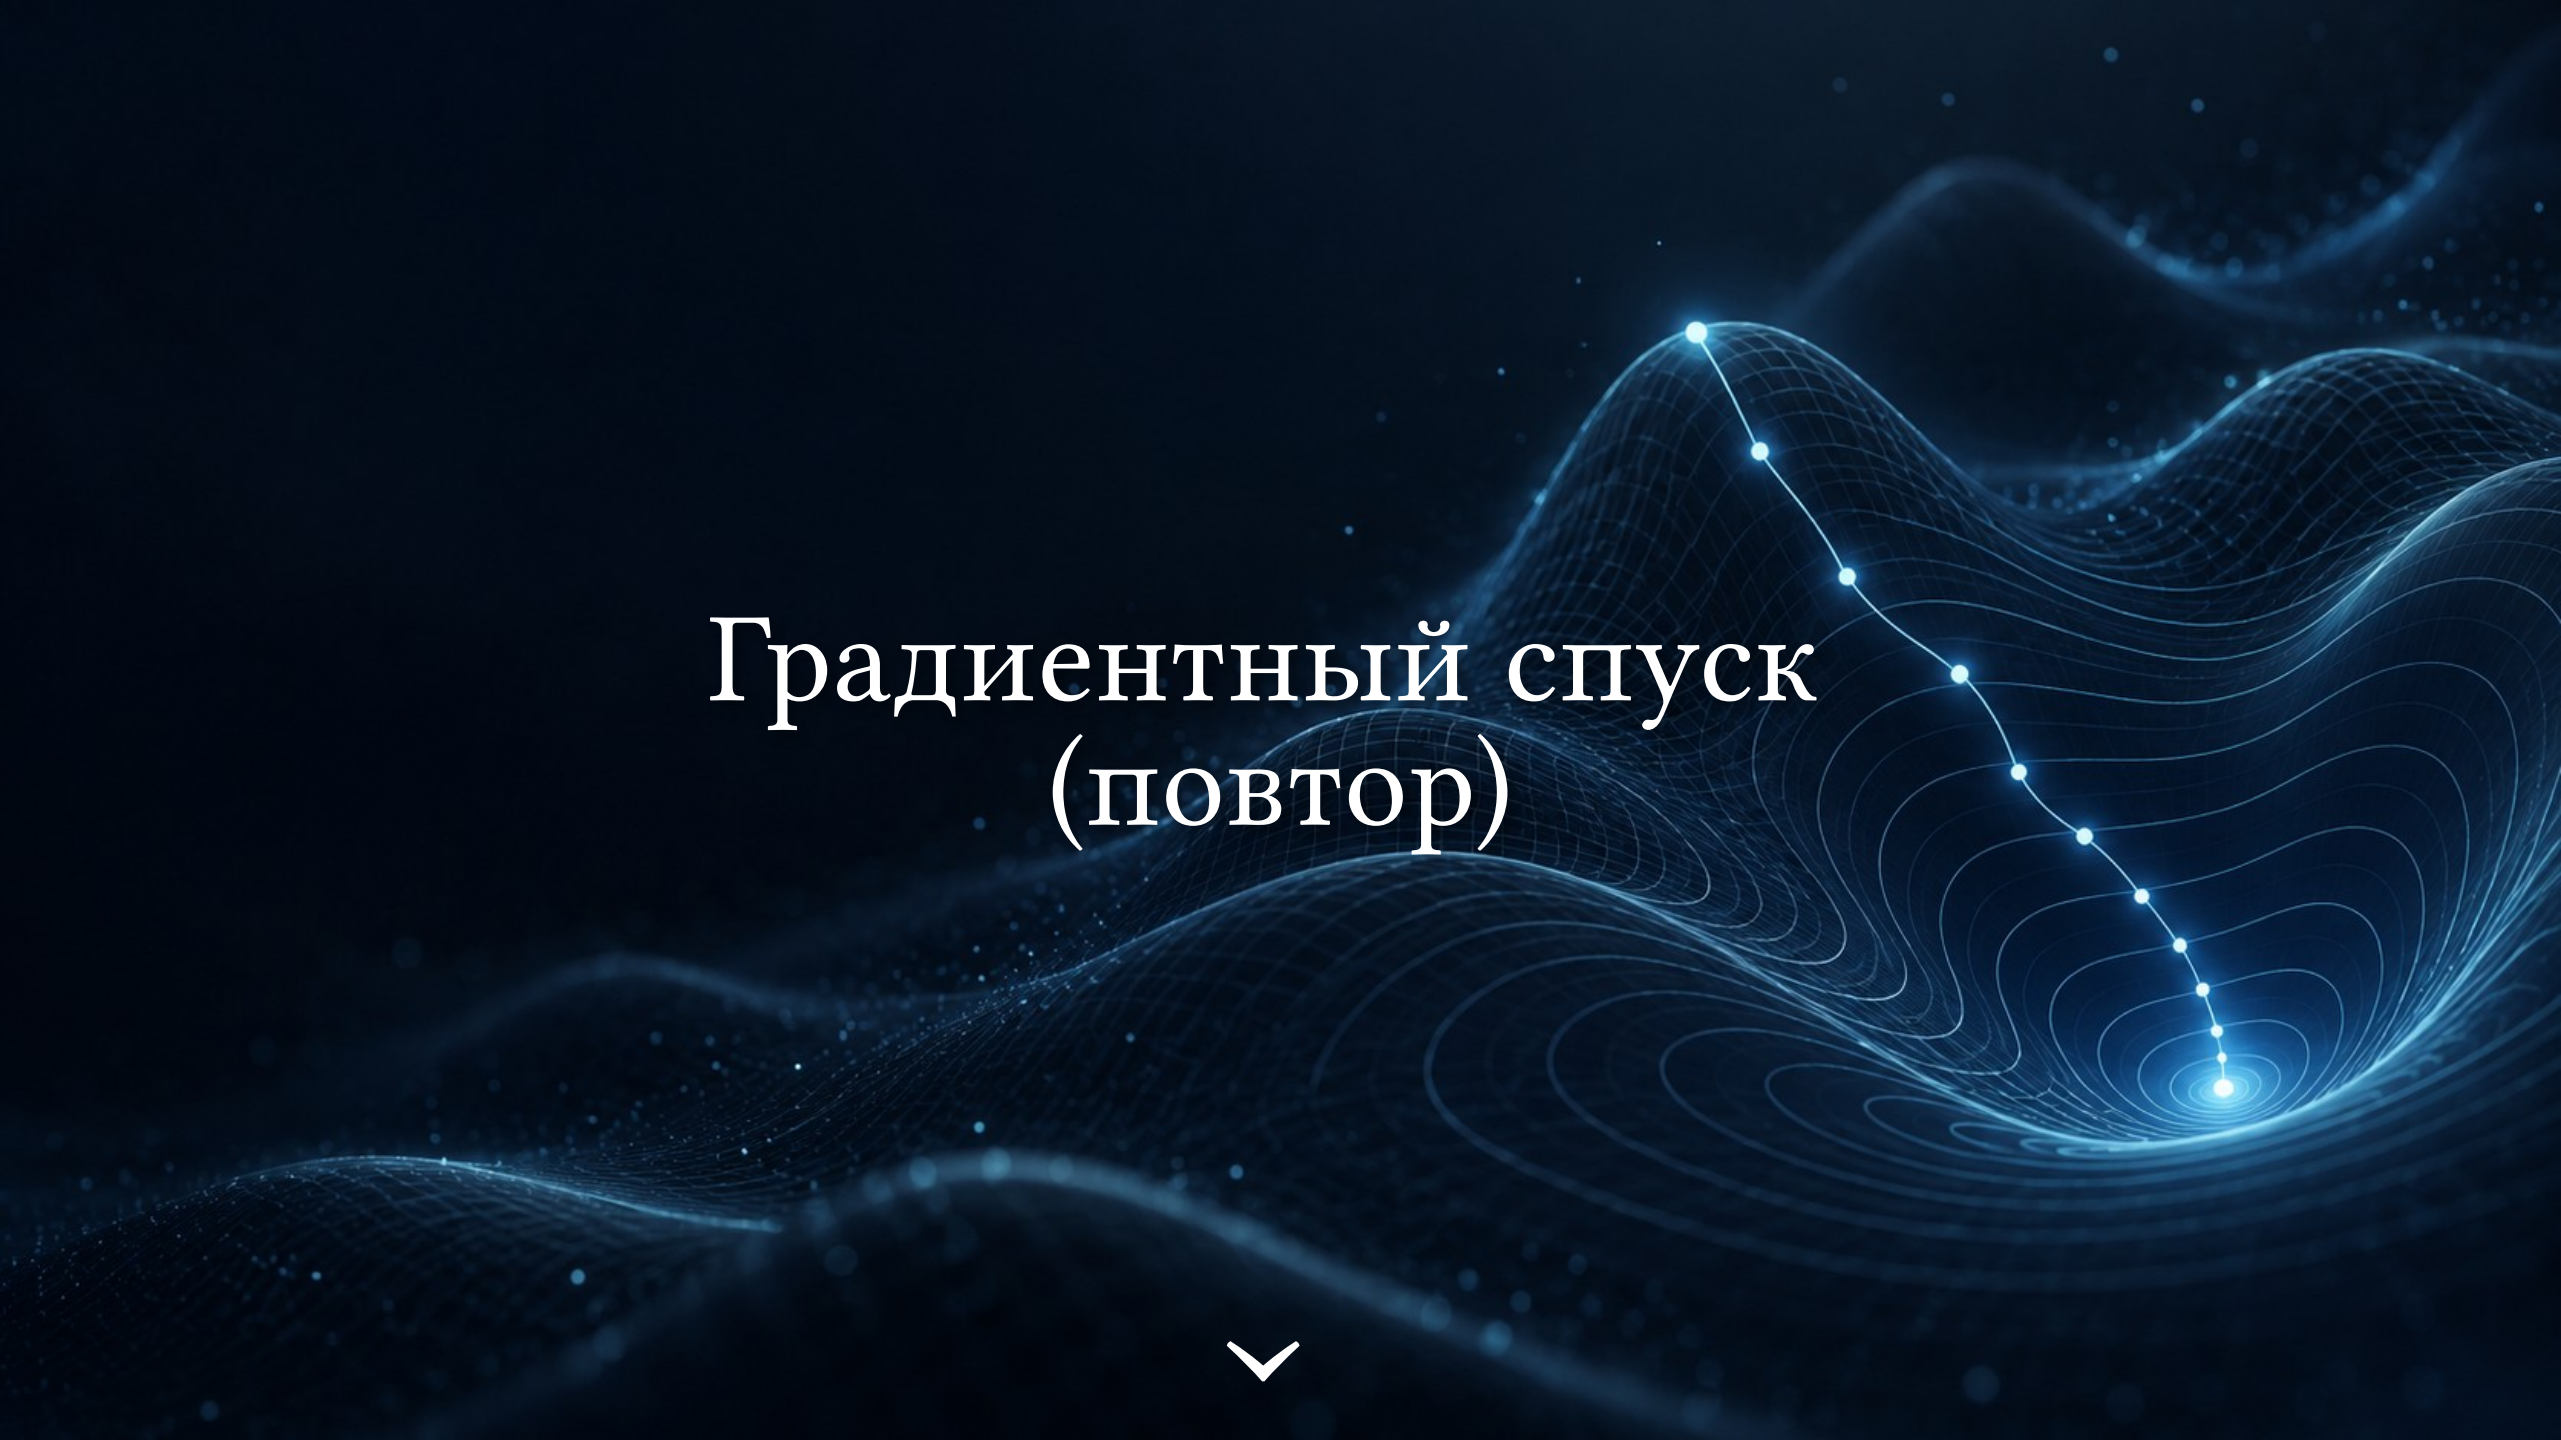
$$\hat{y}(x) = \frac{1}{K}\sum_{k=1}^{K} b_k(x)$$

# Пример




Источник: https://inria.github.io/scikit-learn-mooc/python_scripts/ensemble_bagging.html


Градиентный спуск
(повтор)

# Повтор

- Модель логистической регрессии:

$$\hat{y}_i = \sigma(x_i^T w)$$

- Функция потерь log-loss:

$$L = -\frac{1}{n}\sum_{i=1}^{n}(y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i))$$

- Мы хотим минимизировать $L$:

$$L \to \min_w$$

- Градиентный спуск:

$$w^{(k+1)} = w^{(k)} - \eta \frac{\partial L(w^{(k)})}{\partial w}$$

# Несколько шагов спуска для весов

$$w^{(1)} = w^{(0)} - \eta \frac{\partial L(w^{(0)})}{\partial w}$$

$$w^{(2)} = w^{(1)} - \eta \frac{\partial L(w^{(1)})}{\partial w}$$

$$w^{(3)} = w^{(2)} - \eta \frac{\partial L(w^{(2)})}{\partial w}$$

Можем объединить их так:

$$w^{(3)} = w^{(0)} - \eta \frac{\partial L(w^{(0)})}{\partial w} - \eta \frac{\partial L(w^{(1)})}{\partial w} - \eta \frac{\partial L(w^{(2)})}{\partial w}$$

Т.е. от начальных весов отнимаем градиенты функции потерь в разных точках

# Градиентный спуск для весов

- Веса модели обновляются в процессе градиентного спуска
- Веса определяют прогноз модели
- Как меняется прогноз в процессе градиентного спуска?

# Градиентный спуск для прогнозов

- Модель логистической регрессии:

$$\hat{y}_i = \sigma\left(x_i^T w\right)$$

- Тогда прогноз:

$$\hat{y}_i^{(0)} = \sigma\left(x_i^T w^{(0)}\right)$$

$$\hat{y}_i^{(1)} = \sigma\left(x_i^T w^{(1)}\right), \qquad w^{(1)} = w^{(0)} - \eta \frac{\partial L(w^{(0)})}{\partial w}$$

$$\hat{y}_i^{(2)} = \sigma\left(x_i^T w^{(2)}\right), \qquad w^{(2)} = w^{(1)} - \eta \frac{\partial L(w^{(1)})}{\partial w}$$

$$\hat{y}_i^{(3)} = \sigma\left(x_i^T w^{(3)}\right), \qquad w^{(3)} = w^{(2)} - \eta \frac{\partial L(w^{(2)})}{\partial w}$$

- Можем записать изменение прогнозов как-то иначе?

# Градиентный спуск для прогнозов

$$\hat{y}_i^{(1)} = \hat{y}_i^{(0)} - \eta \frac{\partial L(\hat{y}_i^{(0)})}{\partial \hat{y}}$$

$$\hat{y}_i^{(2)} = \hat{y}_i^{(1)} - \eta \frac{\partial L(\hat{y}_i^{(1)})}{\partial \hat{y}}$$

$$\hat{y}_i^{(3)} = \hat{y}_i^{(2)} - \eta \frac{\partial L(\hat{y}_i^{(2)})}{\partial \hat{y}}$$

Можем объединить их так:

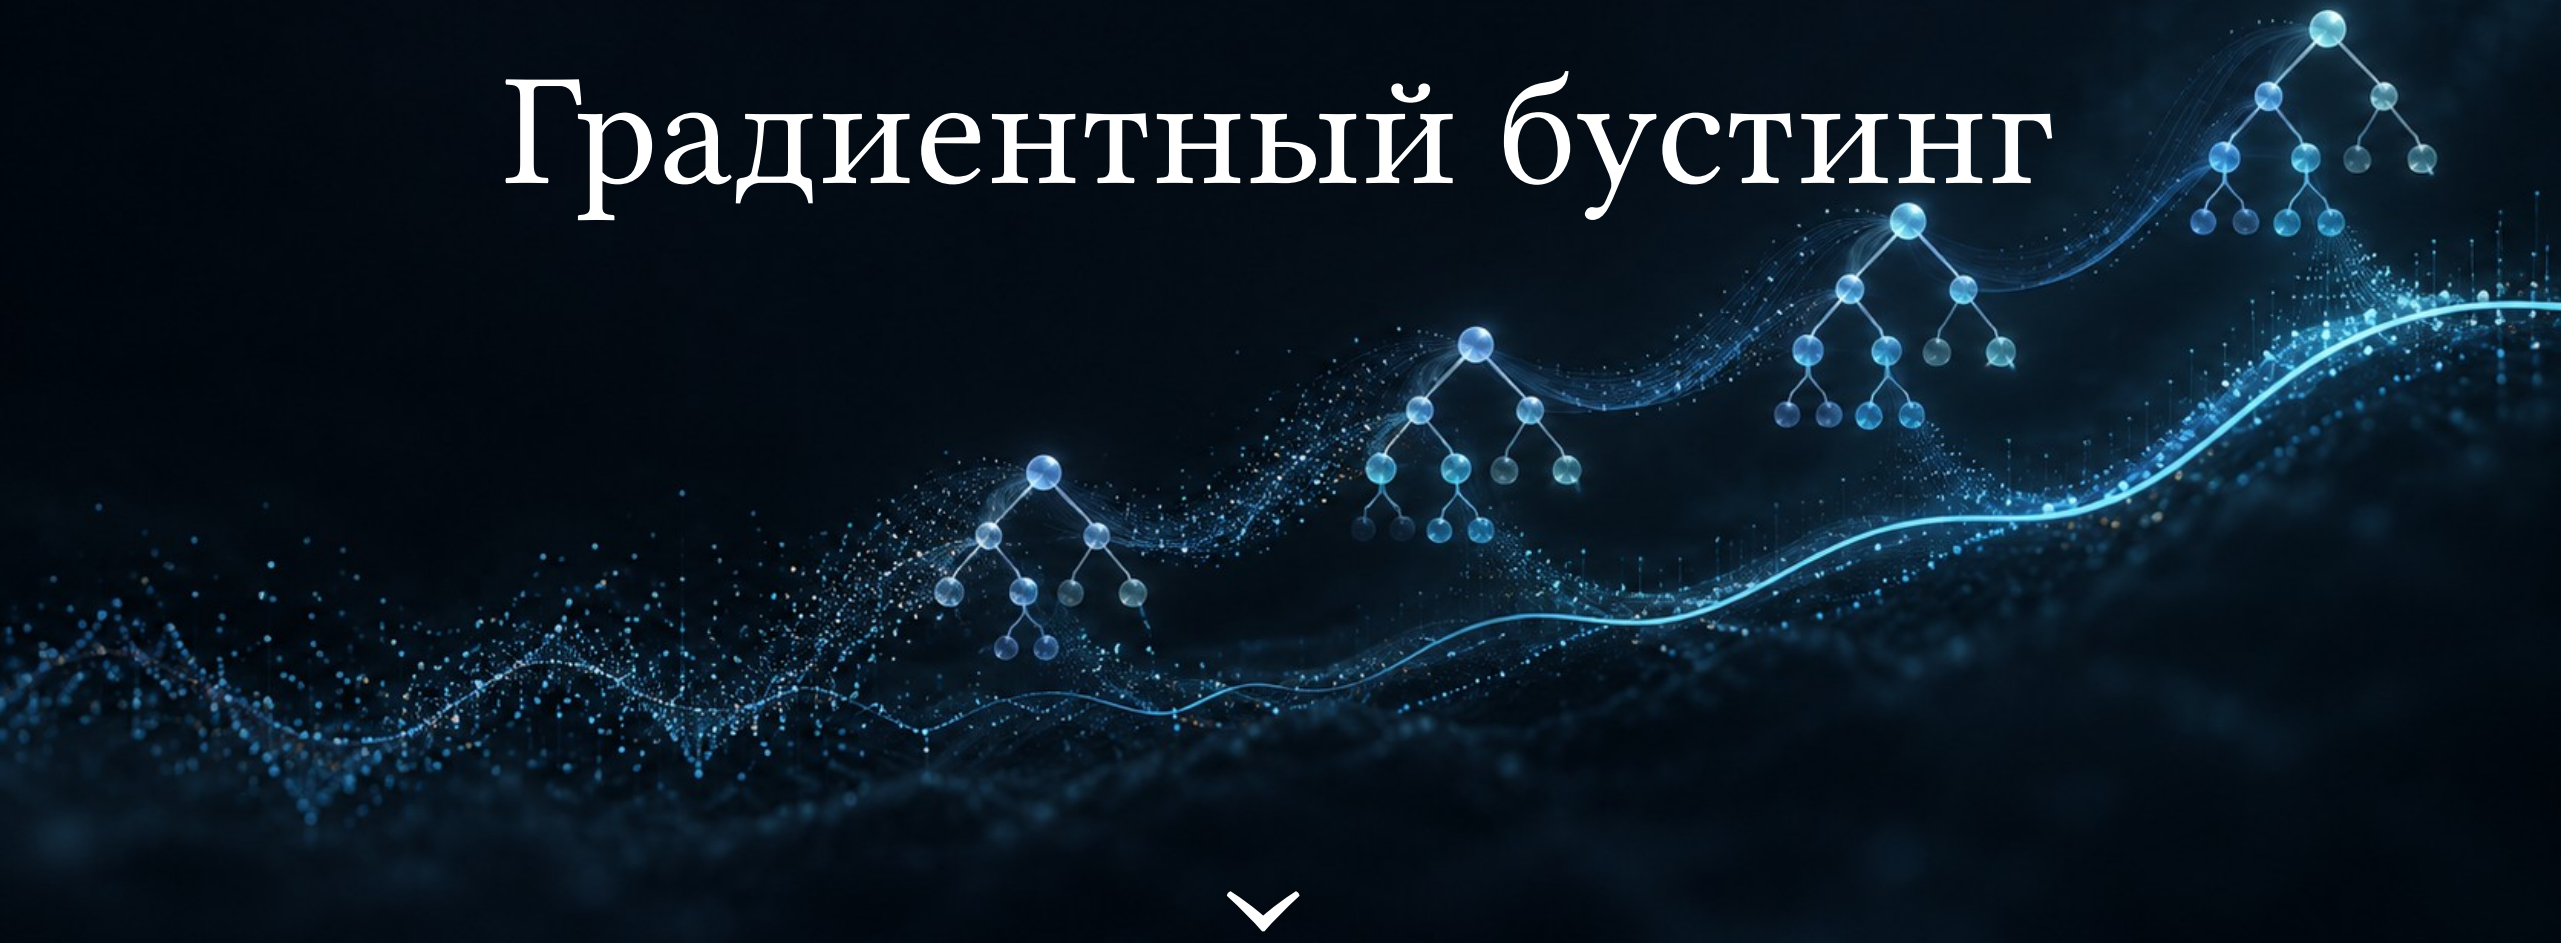
$$\hat{y}_i^{(3)} = \hat{y}_i^{(0)} - \eta \frac{\partial L(\hat{y}_i^{(0)})}{\partial \hat{y}} - \eta \frac{\partial L(\hat{y}_i^{(1)})}{\partial \hat{y}} - \eta \frac{\partial L(\hat{y}_i^{(2)})}{\partial \hat{y}}$$

От начальных весов отнимаем градиенты функции потерь по прогнозам в разных точках

# Градиентный спуск для прогнозов

- Прогнозы модели зависят от весов
- Прогнозы так же обновляются в процессе обновления весов
- Вместо весов мы можем обновлять сразу прогнозы с помощью того же градиентного спуска
- Только градиенты функции потерь будем брать про прогнозам, а не по весам

# Градиентный бустинг



# Задача

- Дана выборка данных $X \in R^{(n \times d)}, y^n$
- Будем строить композицию $K$ моделей:

$$a_K(x) = b_0(x) + \sum_{k=1}^{K} \gamma_k b_k(x)$$

  - где $b_0(x)$ - начальный прогноз. Например, константа.
- Хотим, чтобы $a_K(x)$ минимизировала нашу функцию потерь:

$$L\big(y, a_K(X)\big) \to \min_{\gamma, b}$$

# Вопросы

- Как минимизировать функцию потерь?
- Как обучать модели в композиции?

# Идея решения

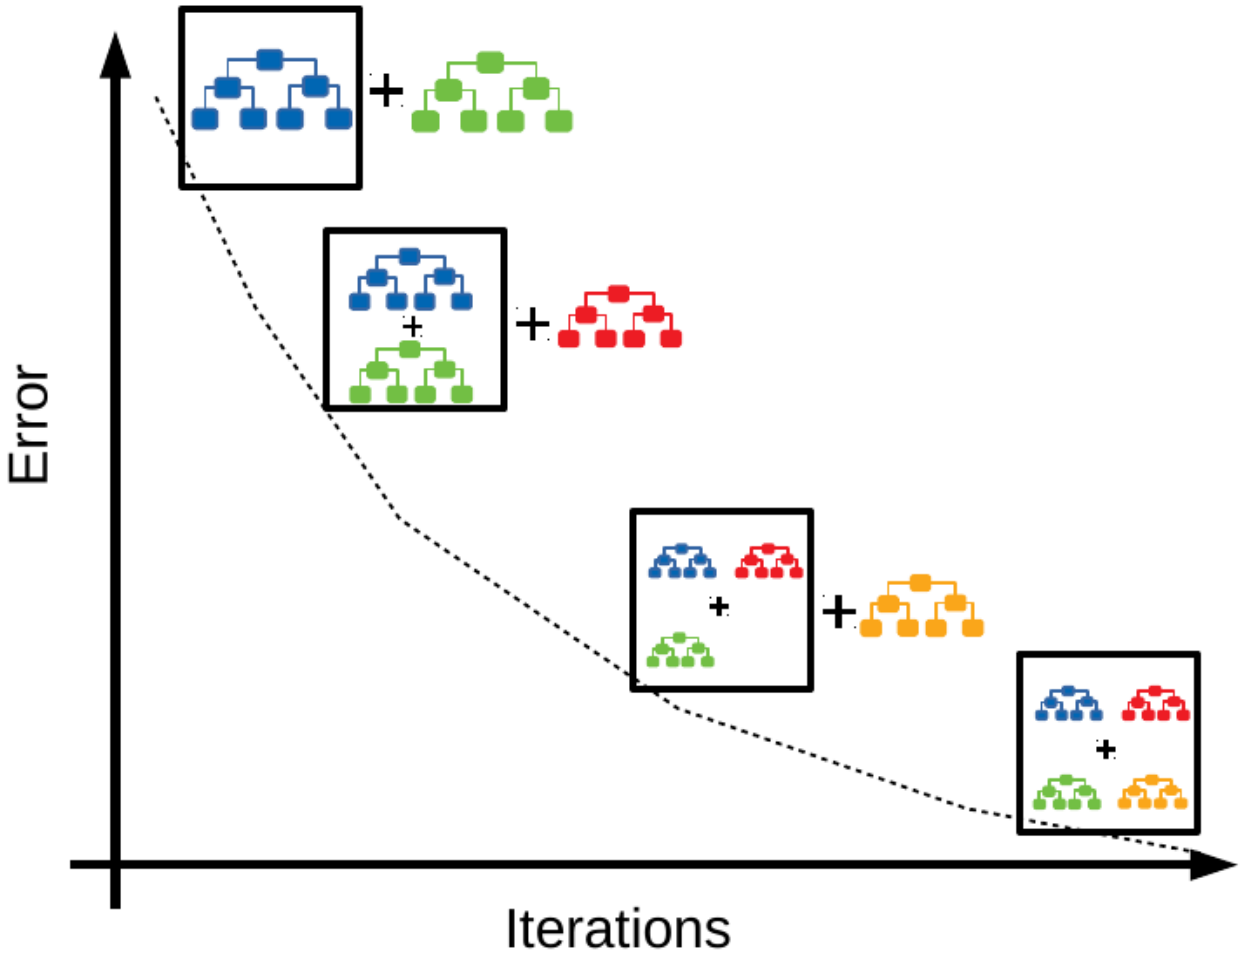
- Воспользуемся градиентным спуском, только вместо $w^{(k)}$ подставим $a_k(X)$
- Тогда, для минимизации функции потерь получаем:

$$a_k(X) = a_{k-1}(X) - \eta \frac{\partial L(a_{k-1}(X))}{\partial a}$$

- Как обучить новую модель $\boldsymbol{b_k(X)}$, чтобы $a_k(X) = a_{k-1}(X) + \gamma_k \boldsymbol{b_k(X)}$?

# Идея решения

На каждой итерации градиентного спуска добавляем в композицию новую модель, которая учится на ошибках прогноза текущей композиции моделей



# Алгоритм градиентного бустинга

- Дана выборка данных $X \in R^{(n \times d)}, y^n$
- Делаем начальный прогноз $a_0(X) = b_0(X)$
- Для каждого k = 1 … K:
  - Методом **бутстрапа** генерируем подвыборку $X^{(k)}, y^{(k)}$
  - Считаем вектор производных функции потерь (**остатки, сдвиги**):

$$s = -\frac{dL\left(y^{(k)}, a_{k-1}\left(X^{(k)}\right)\right)}{da}$$

  - Обучаем модель **регрессии** $b_k\left(X^{(k)}\right)$ с MSE функцией потерь:

$$\left(b_k\left(X^{(k)}\right) - s\right)^T \left(b_k\left(X^{(k)}\right) - s\right) \rightarrow \min_{b_k}$$

  - Обновляем композицию алгоритмов:

$$a_k\left(X^{(k)}\right) = a_{k-1}\left(X^{(k)}\right) + \gamma_k b_k(X^{(k)})$$

# Градиентный бустинг для регрессии

- Функция потерь MSE для задачи регрессии:

$$L\big(y, a(X)\big) = \frac{1}{n}\big(y - a(X)\big)^T\big(y - a(X)\big) \to \min$$

- Для каждого k = 1 … K:
  - Методом **бутстрапа** генерируем подвыборку $X^{(k)}, y^{(k)}$
  - Считаем вектор производных функции потерь (**остатки, сдвиги**):

$$s = -\frac{dL\left(y^{(k)}, a_{k-1}\big(X^{(k)}\big)\right)}{da} = -\frac{2}{n}\big(\boldsymbol{y^{(k)}} - \boldsymbol{a_{k-1}}\big(\boldsymbol{X^{(k)}}\big)\big)$$

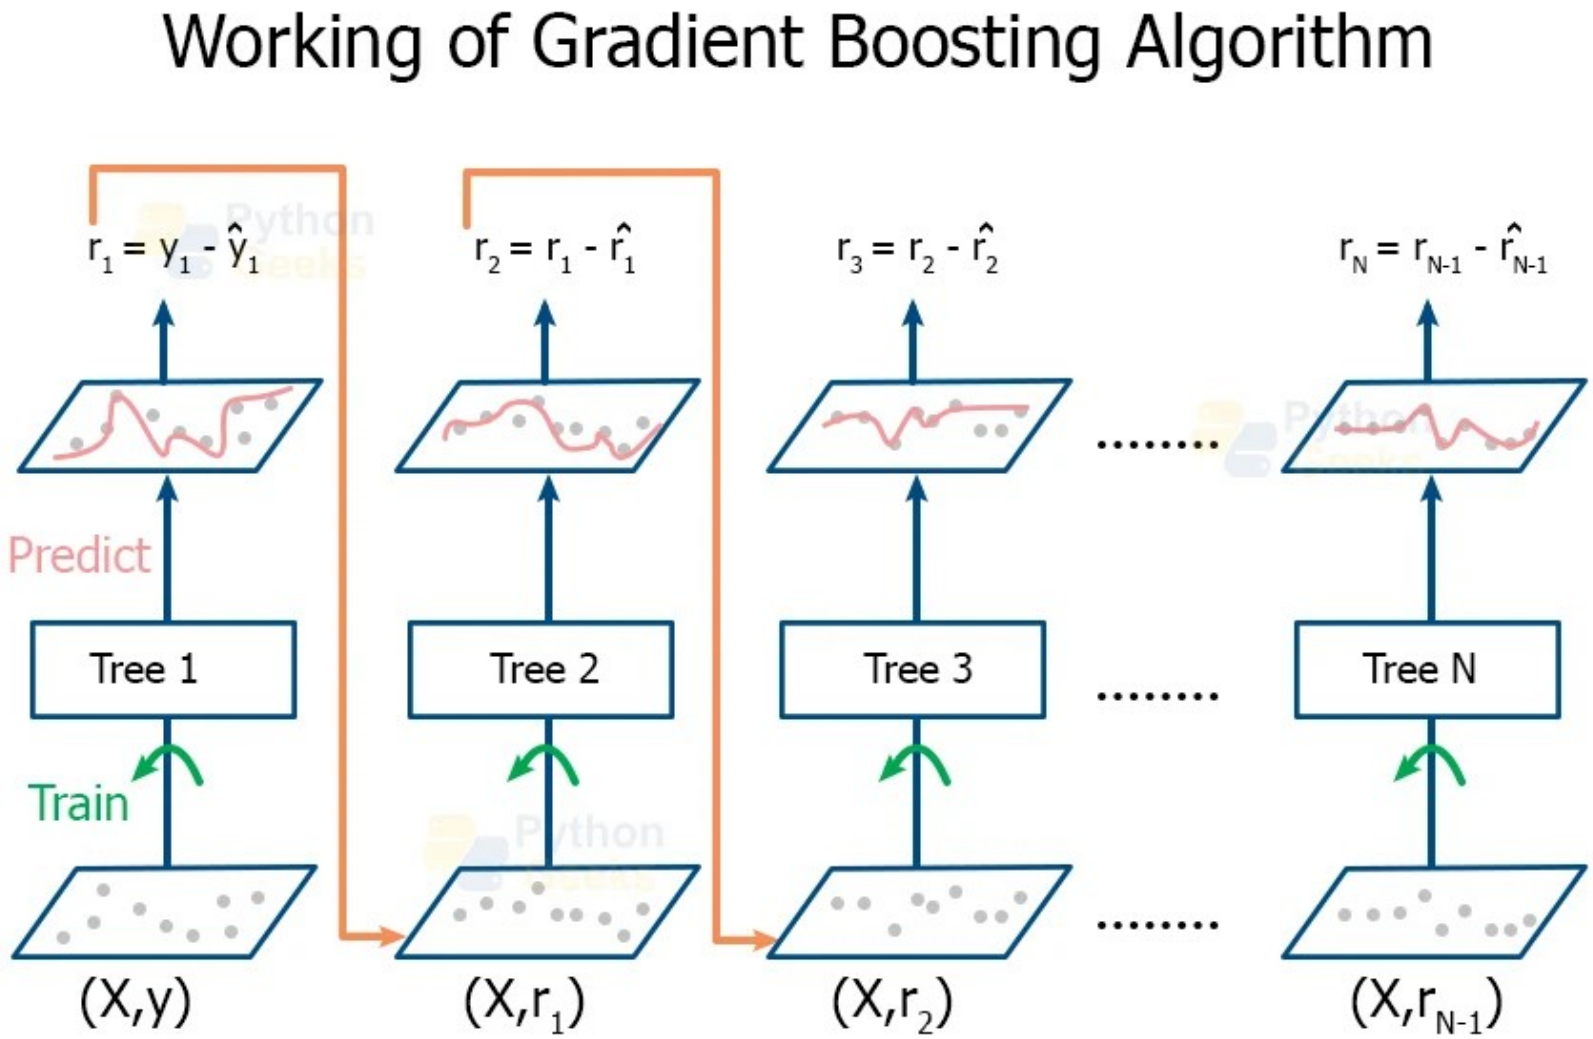
  - Обучаем модель **регрессии** $b_k\big(X^{(k)}\big)$ с MSE функцией потерь предсказывать остатки:

$$\big(b_k\big(X^{(k)}\big) - s\big)^T\big(b_k\big(X^{(k)}\big) - s\big) \to \min_{b_k}$$

  - Обновляем композицию алгоритмов:

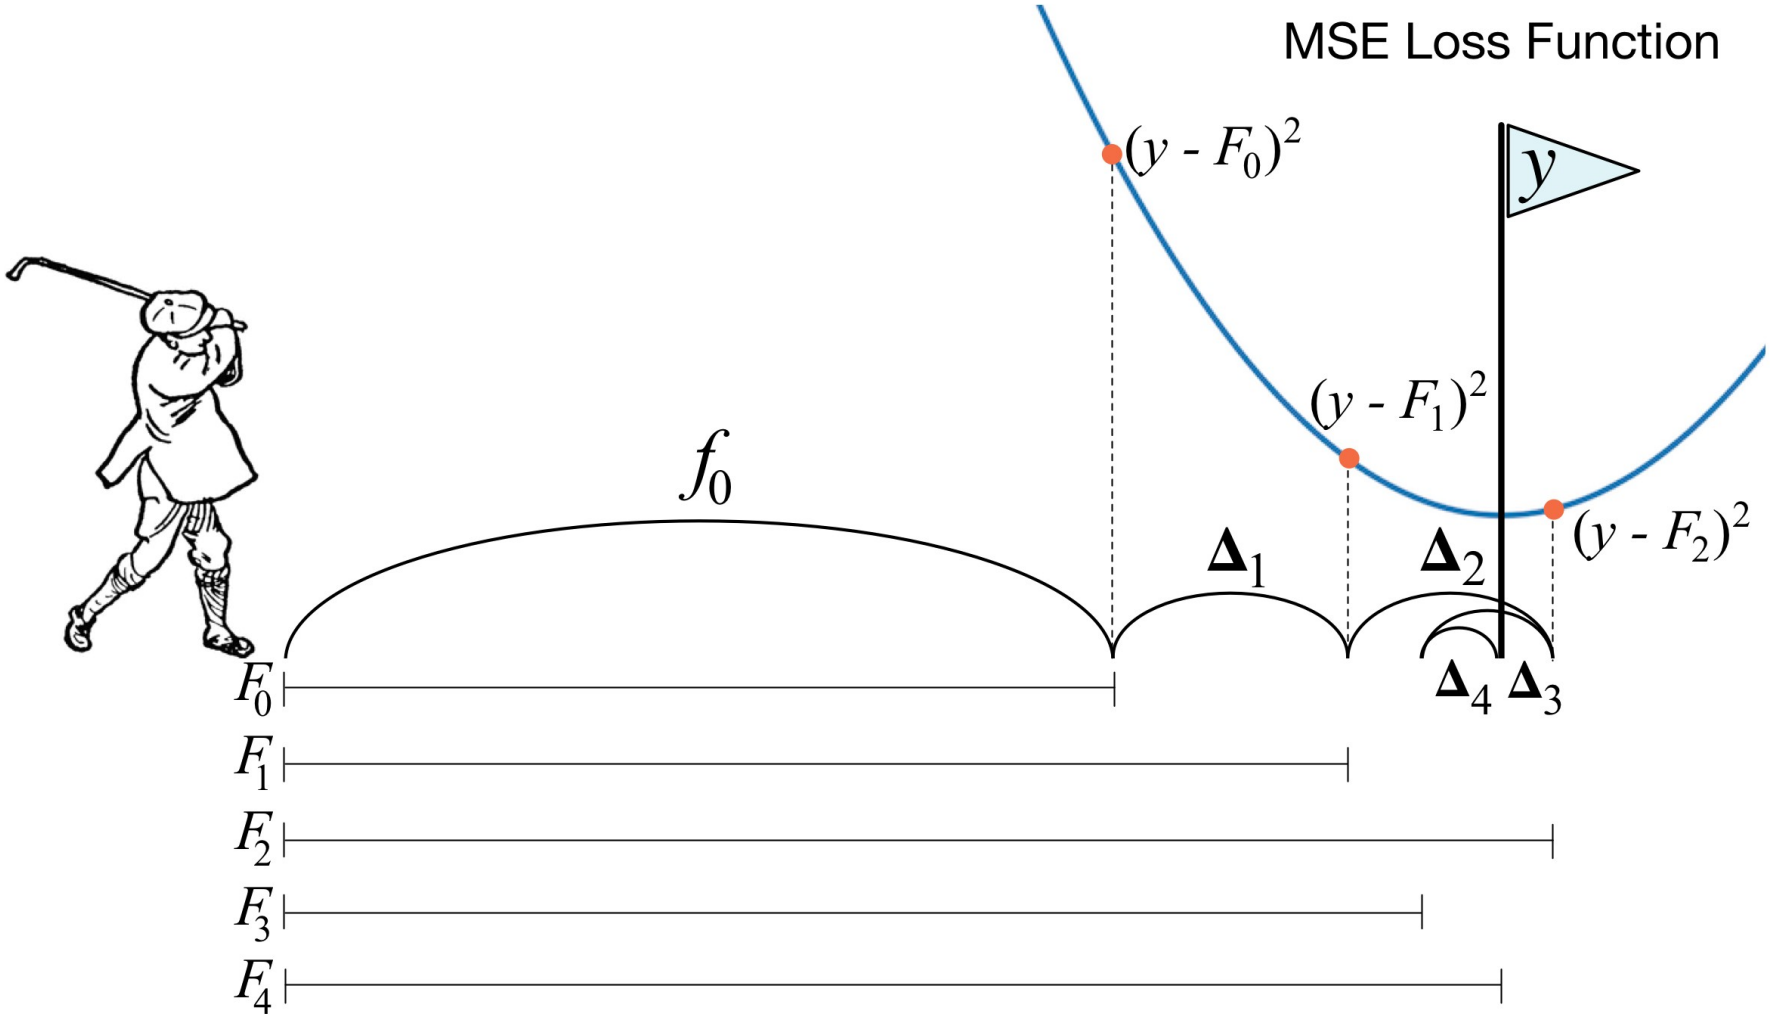
$$a_k\big(X^{(k)}\big) = a_{k-1}\big(X^{(k)}\big) + \gamma_k b_k\big(X^{(k)}\big)$$

# Градиентный бустинг для регрессии

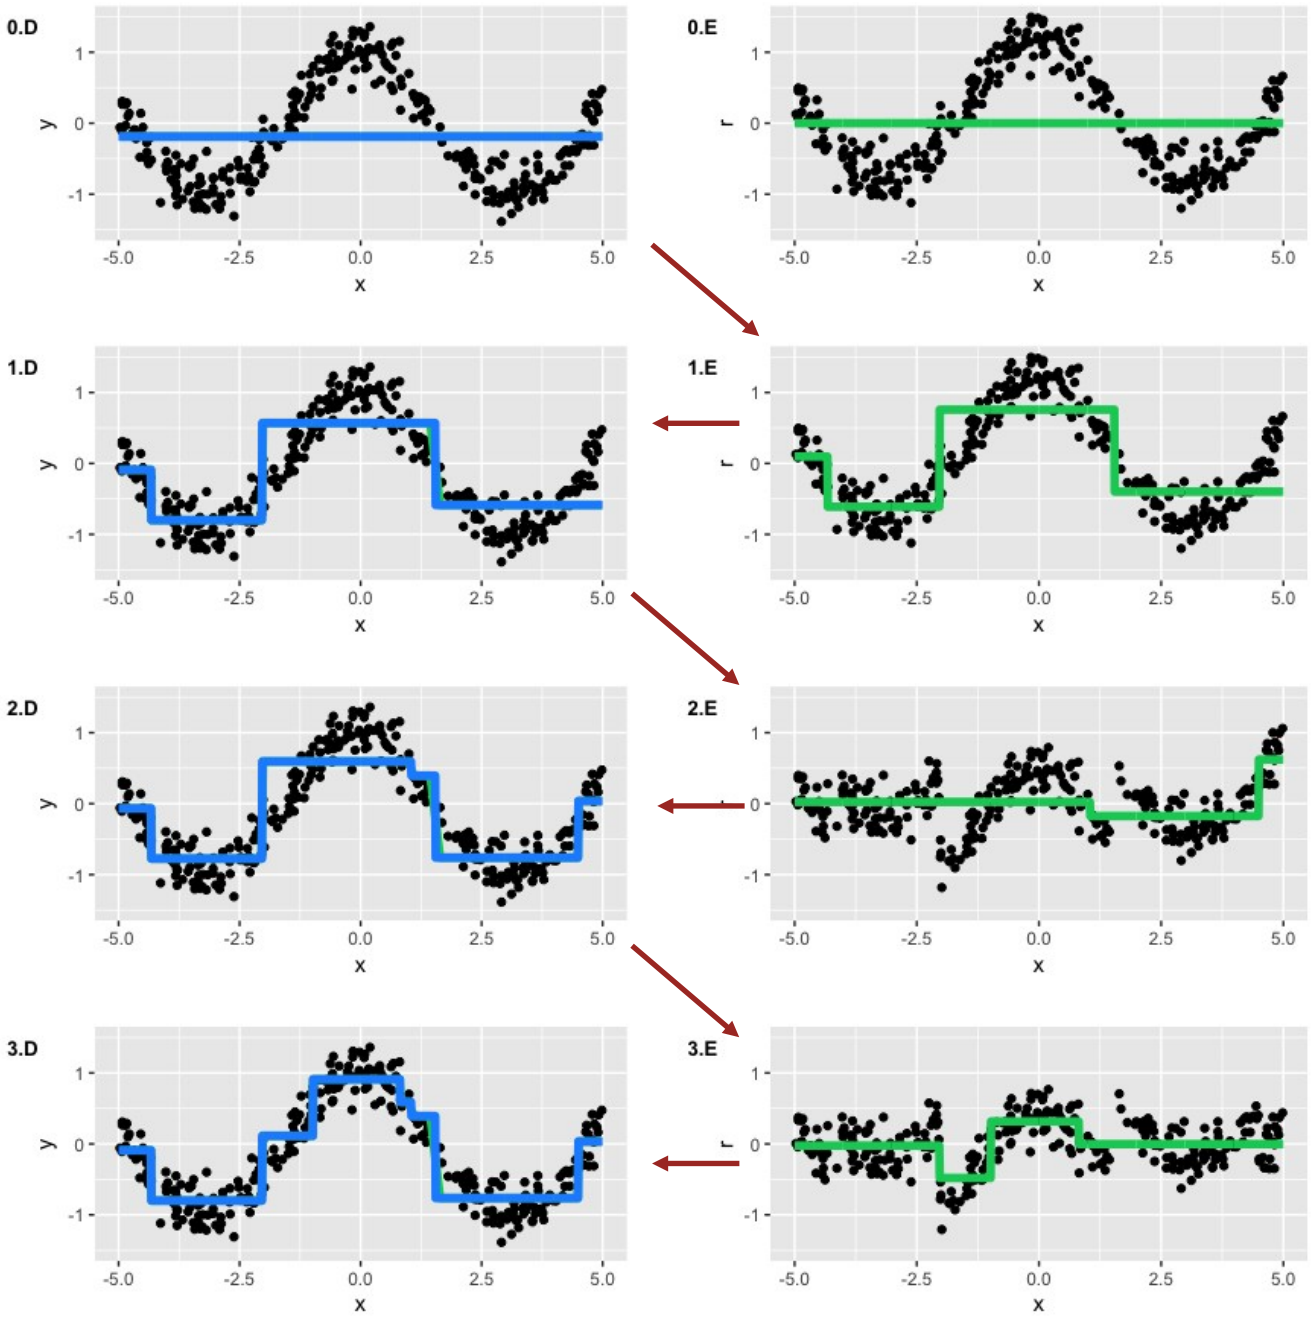



Источник: https://pythongeeks.org/gradient-boosting-algorithm-in-machine-learning/

# Градиентный бустинг для регрессии



# Пример




$$a_k(X) = a_{k-1}(X) + \gamma_k b_k(X)$$

$$s = -\left.\frac{dL(y,z)}{dz}\right|_{z=a_{k-1}(X)}$$

# Градиентный бустинг с оптимальным шагом

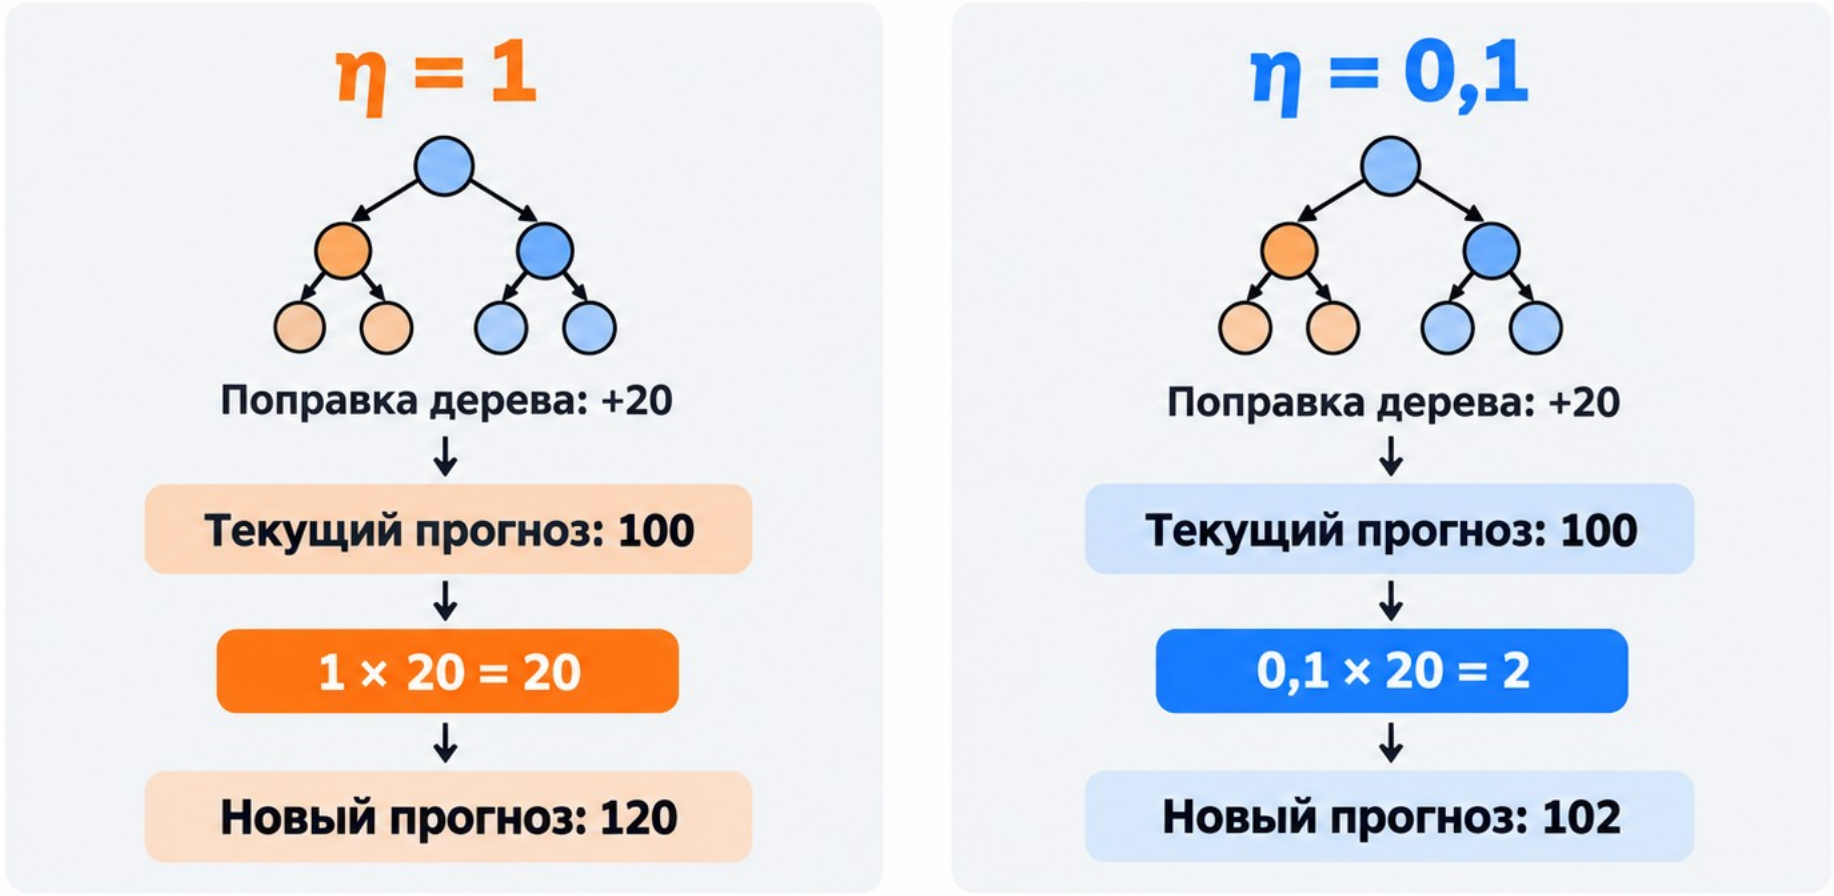
- Делаем начальный прогноз $a_0(X) = b_0(X)$
- Для каждого k = 1 … K:
  - Методом **бутстрапа** генерируем подвыборку $X^{(k)}, y^{(k)}$
  - Считаем вектор **остатков (сдвигов)** $s = -\frac{dL\left(y^{(k)}, a_{k-1}\left(X^{(k)}\right)\right)}{da}$
  - Обучаем модель **регрессии** $b_k\left(X^{(k)}\right)$ предсказывать остатки
  - Обновляем композицию алгоритмов:

$$L\left(y, a_{k-1}\left(X^{(k)}\right) + \gamma_k b_k\left(X^{(k)}\right)\right) \to \min_{\gamma_k}$$

$$a_k\left(X^{(k)}\right) = a_{k-1}\left(X^{(k)}\right) + \eta\gamma_k b_k\left(X^{(k)}\right)$$

  - $\gamma_k$ - оптимальный шаг градиентного бустинга
  - $\eta \in [0, 1)$ – коэффициент сокращения шага (механизм регуляризации)

# Сокращение шага



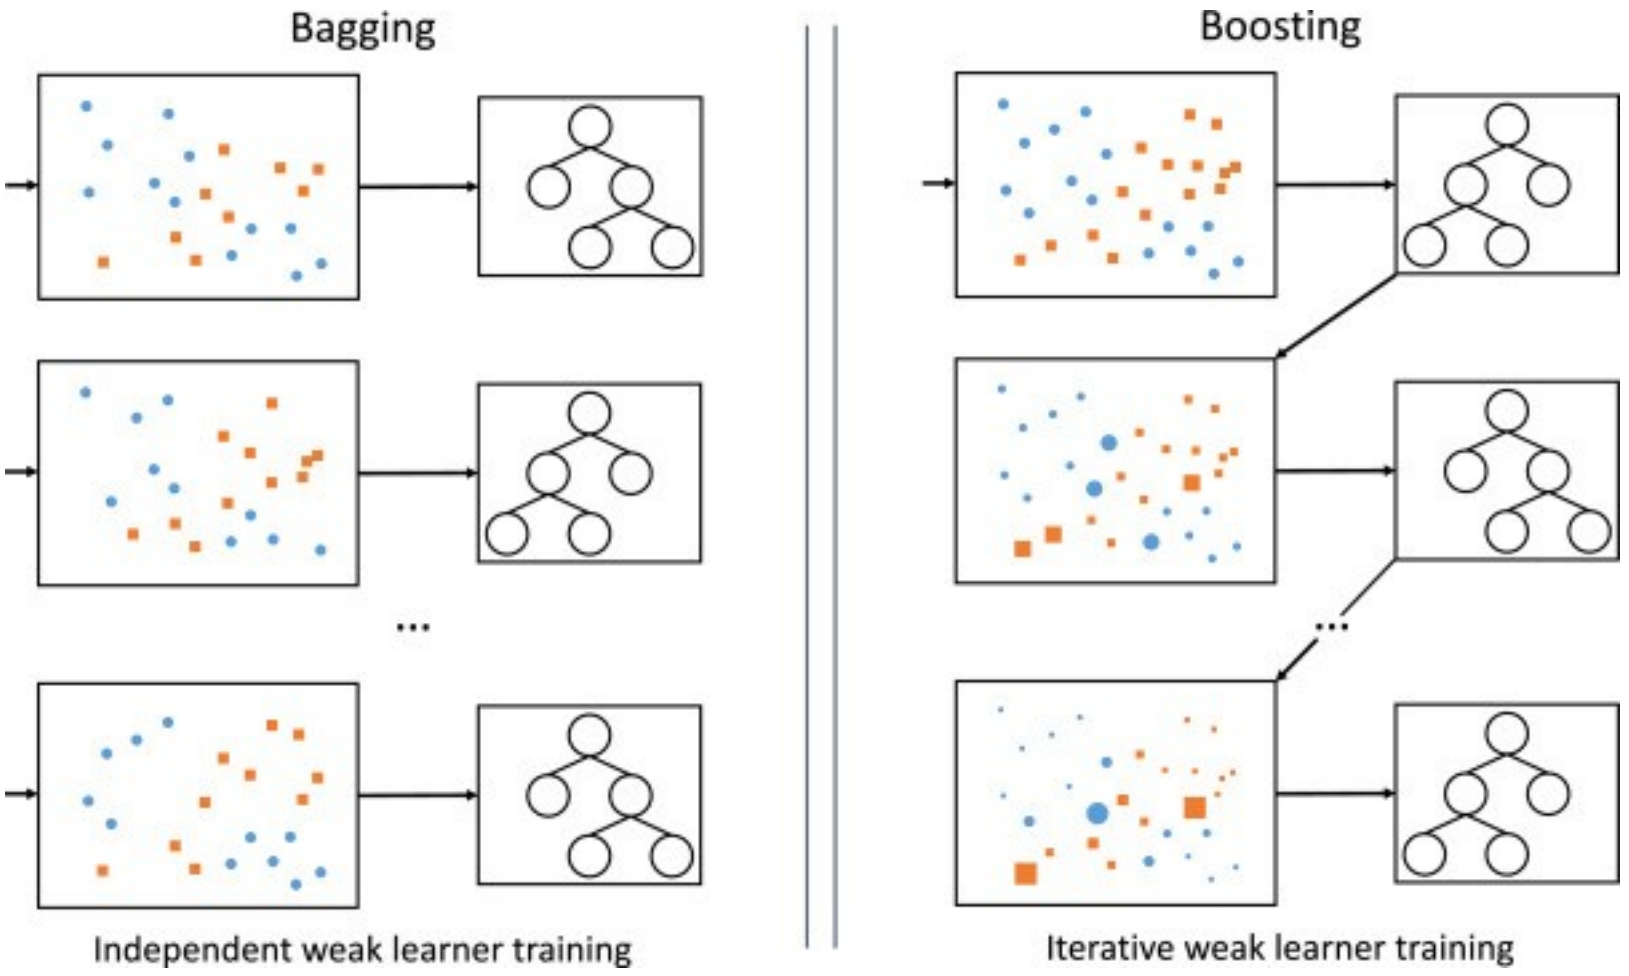

**Меньше шаг — осторожнее обновление модели**

# Сокращение шага

**Зачем сокращать шаг в градиентном бустинге:**

- **Простые деревья** лишь приближённо воспроизводят антиградиент, поэтому большой шаг может приводить к неточным обновлениям.
- **Глубокие деревья** могут быстро подстраиваться под шум в обучающих данных и приводить к переобучению.
- **Сокращение шага** уменьшает вклад каждого дерева и делает обновления модели более осторожными.
- **Компромисс:** меньший шаг обычно требует большего числа деревьев; оба параметра подбирают по качеству на валидации.

# Бэггинг и бустинг




Источник: https://www.sciencedirect.com/science/article/pii/S1 566 253 520 303 195

# Важные замечания

- Неважно какую задачу вы решаете, классификацию или регрессию, в градиентном бустинге **всегда** используются модели **регрессии**
- Обычно в градиентном бустинге используют решающие деревья
- Популярные библиотеки:
  - sklearn
  - XGBoost
  - CatBoost
  - LighGBM

# Демо

- https://arogozhnikov.github.io/2016/07/05/gradient_boosting_playground.html
- https://arogozhnikov.github.io/2016/06/24/gradient_boosting_explained.html

# Заключение

# Вопросы

- Опишите алгоритм построения композиции методом градиентного бустинга. Что такое сдвиги (остатки)?
- Что такое сокращение шага в градиентном спуске и для чего оно используется?